EEE 017 Confiabilidade de Sistemas

2-Revisão Estatística

Parte C - Distribuições

Michel Bessani
https://orcslab.github.io/
Departamento de Engenharia Elétrica - DEE

Engenharia de Sistemas

UFMG
UNIVERSIDADE FEDERAL
DE MINAS GERAIS

Belo Horizonte

Sumário

1. Introdução
1.1 Amostra Aleatória
1.2 Função de Distribuição de Probabilidade e de Distribuição Cumulativa
2. Algumas Distribuições de Probabilidade
2.1 Distribuição Uniforme
2.2 Distribuição Normal
2.3 Teorema Central do Limite (TCL)
2.4 Graus de Liberdade
2.5 Distribuição t-Student
2.6 Distribuição χ^2
2.7 Distribuição F
2.8 Outras Distribuições
3. Referências

Introdução

As **grandezas populacionais** são, na maior parte dos casos, **desconhecidas**.

Geralmente, após coletarmos os **dados** em um experimento, podemos:

1. Fazer um **ajuste de uma distribuição de probabilidade** que modela o comportamento da variável aleatória de forma satisfatória.
2. Utilizar um **estimador amostral** para descrever os dados, lembrando que um estimador amostral é uma **variável aleatória**.
   - Pode-se ainda realizar uma **inferência** sobre essa variável aleatória.

Introdução:
Amostra Aleatória

As possibilidades de ajustar um modelo ou inferir alguma informação a partir de um experimento são dependentes de que as **observações amostradas** sejam, **simultaneamente**:

1. **Independentes**: o próximo valor a ser observado não depende dos valores observados anteriormente;

2. **Identicamente distribuídas**: todos os valores seguem uma mesma distribuição de probabilidade.

Caso as observações sejam simultaneamente independentes e identicamente distribuídas, elas são chamadas de iid.

Amostra Aleatória

Um conjunto de observações a cerca de um processo é uma **amostra aleatória**, *se e somente se*, as observações são **iid**.

Qualquer **número calculado** a partir de uma amostra aleatória é uma **estatística**.

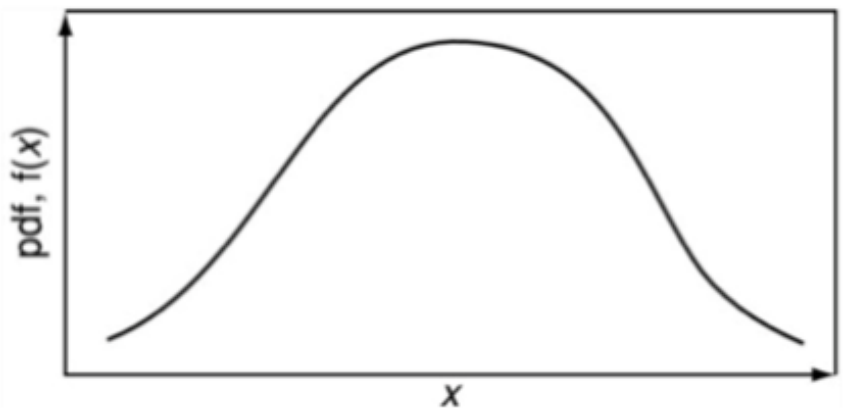
A distribuição de probabilidade de uma **estatística** é chamada de **Distribuição Amostral**.

Introdução:
Função de Distribuição de Probabilidade e de Distribuição Cumulativa

A **Função de Distribuição de Probabilidade** (PDF, *probability distribution function*) permite avaliar a probabilidade de observarmos realizações de uma variável aleatória em qualquer intervalo de pontos, $(x_1,\ x_2)$, no domínio de interesse.

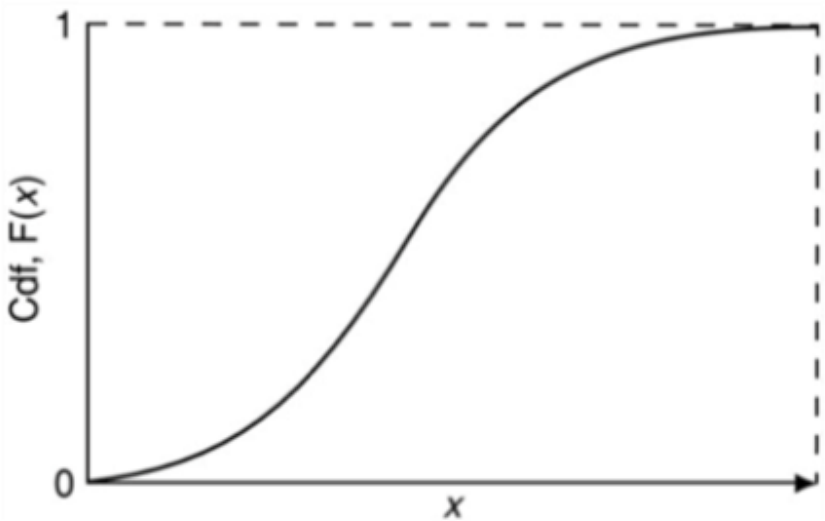
$$\int_{-\infty}^{\infty} f(x)dx = 1$$

$$P(x_1 < X < x_2) = \int_{x_1}^{x_2} f(x)dx$$



A **Função de Distribuição Cumulativa** (CDF, *cumulative distribution function*) avalia a probabilidade de observarmos realizações de uma variável aleatória menor ou igual do que um valor x no domínio de interesse, $P(X \leq x) = F(x)$.

$$P(X \leq x) = F(x) = \int_{-\infty}^{x} f(x)dx$$



Algumas Distribuições de Probabilidade

Veremos:

- Uniforme;
- Normal;
- t-Student;
- χ^2;
- F.

Existem muitas outras.

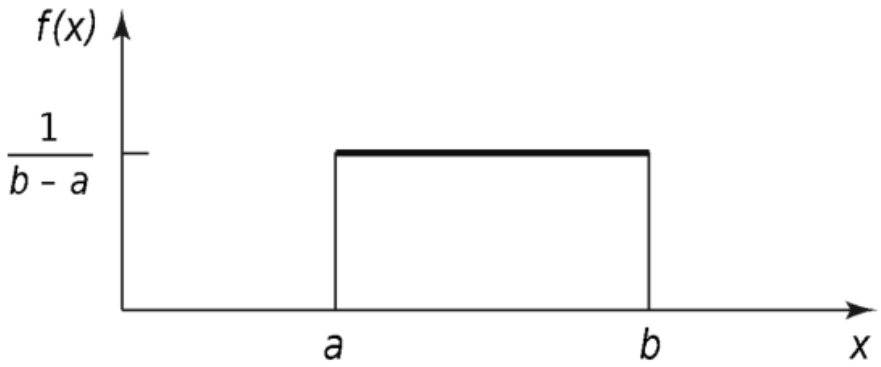
Algumas Distribuições de Probabilidade: Distribuição Uniforme

Probabilidade igual para qualquer valor dentro de um intervalo $(a,\ b)$:

$$f(x) = \frac{1}{b-a}, \quad x \in [a,\ b]$$

$$\mu = \frac{a+b}{2}$$

$$\sigma^2 = \frac{(b-a)^2}{12}$$



Utilizada para:

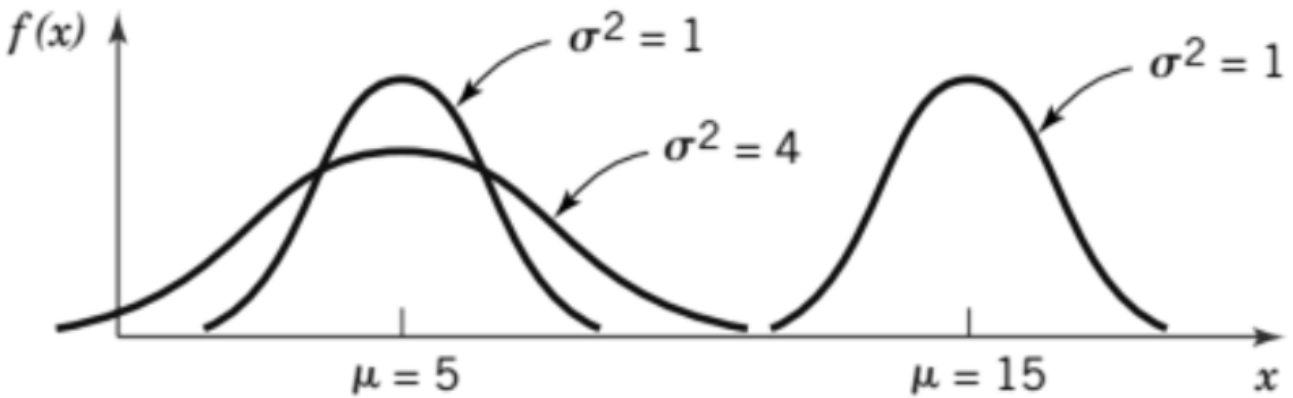
- Representar tolerâncias;
- Amostrar outras distribuições.

Algumas Distribuições de Probabilidade: Distribuição Normal

Possui dois parâmetros, μ e σ:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad x \in \mathbb{R}$$

$$\mathrm{E}[X] = \mu, \ \mathrm{V}[X] = \sigma^2$$



Amplamente utilizada em diversas áreas do conhecimento:

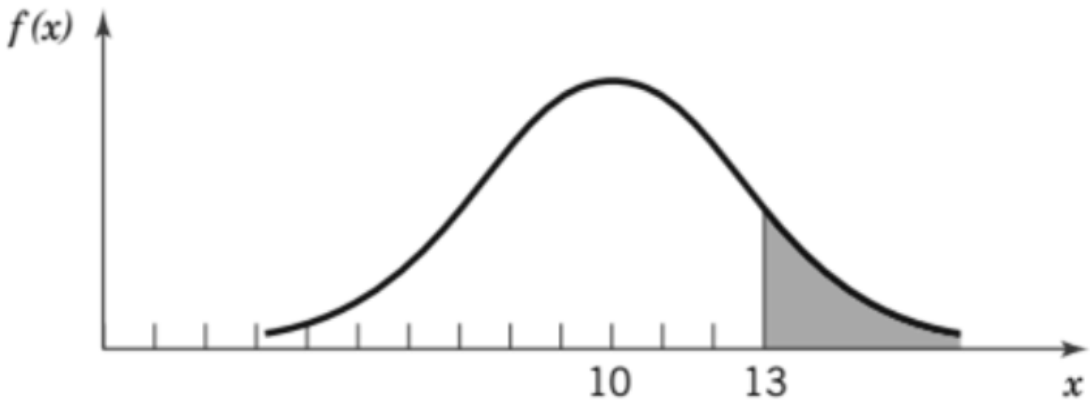
- Biologia;
- Sociologia;
- Hidrologia;
- Engenharia.

Fundamental para Inferência Estatística:

- Testes de Hipóteses;
- Intervalos de Confiança.

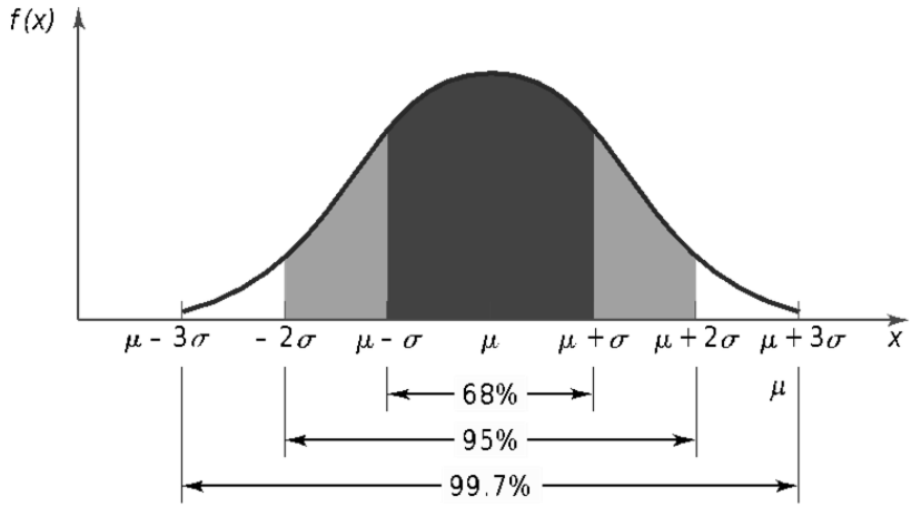
Ilustrando: Qual a probabilidade de uma variável aleatória normalmente distribuída com média 10 e variância 4, $X \sim \mathcal{N}(10, 4)$, assumir um valor maior do que 13.

$P(X > 13) = 1 - P(X \leq 13) = 1 - F(13)$ e sabendo que
$X \sim \mathcal{N}(10, 4)$.



Distribuição que possui características que são amplamente conhecidas:

$$P(\mu - \sigma < X < \mu + \sigma) = 0.6827$$
$$P(\mu - 2\sigma < X < \mu + 2\sigma) = 0.9545$$
$$P(\mu - 3\sigma < X < \mu + 3\sigma) = 0.9973$$



Quando uma variável aleatória (v.a.) possui

$$\mu = 0 \text{ e } \sigma^2 = 1$$

ela é chamada de **Normal Padrão** (Z).

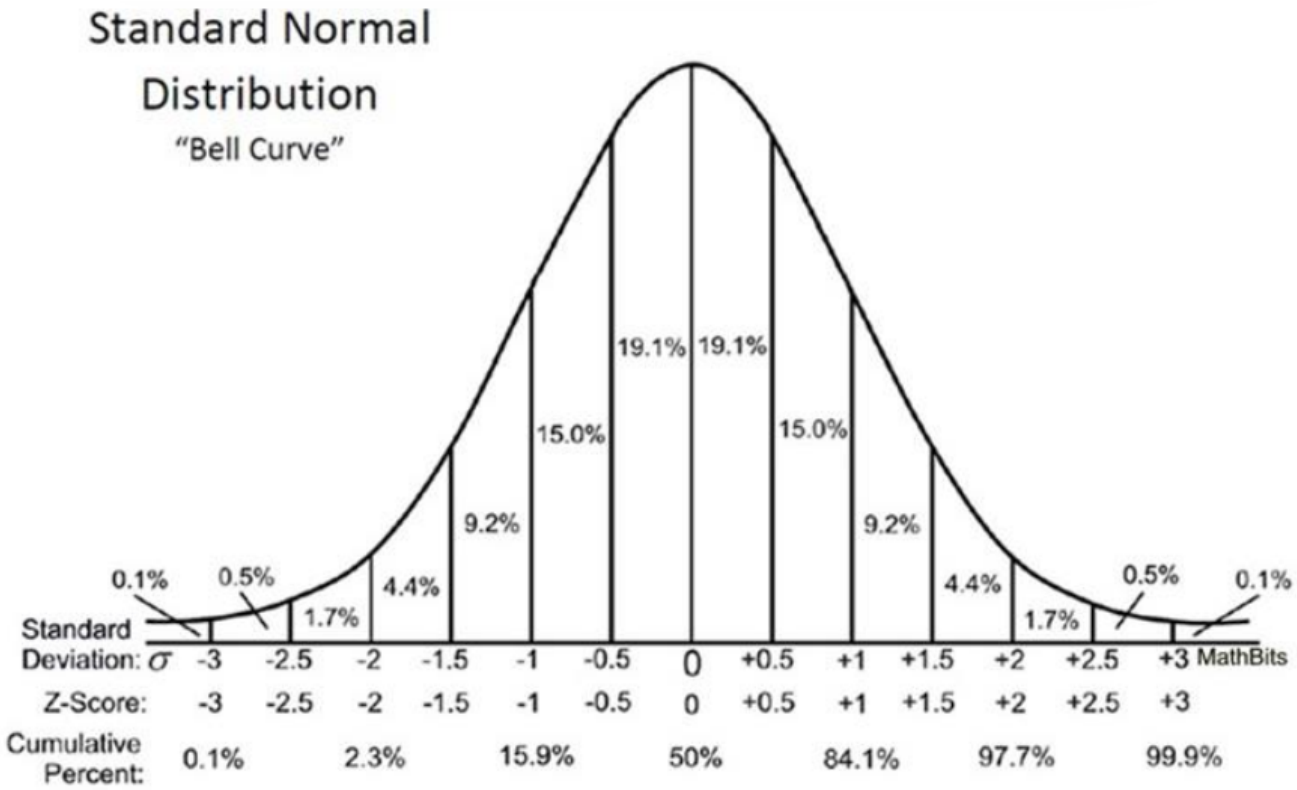
A sua Função de Distribuição Cumulativa (CDF) é representada da seguinte forma:

$$\Phi(z) = P(Z \leq z)$$

Para uma v.a. X com quaisquer valores de μ e σ^2, a v.a. transformada Z é uma Normal Padrão:

$$Z = \frac{X - \mu}{\sigma}$$

A Normal Padrão ($Z \sim \mathcal{N}(0,1)$) possui seus valores conhecidos e tabelados e representados através de $\Phi(z)$:



Algumas Distribuições de Probabilidade: Teorema Central do Limite (TCL)

Dada uma amostra aleatória (iid) de tamanho n, $\mathbf{X} = \{x_1, ..., x_n\}$, de uma população com média μ e variância σ^2, ambas finitas.

A estatística (variável aleatória)

$$Z_n = \frac{\overline{X} - \mu}{\sigma / \sqrt{n}}$$

converge para uma distribuição Normal Padrão ($\mathcal{N}(0, 1)$) quando $n \to \infty$.

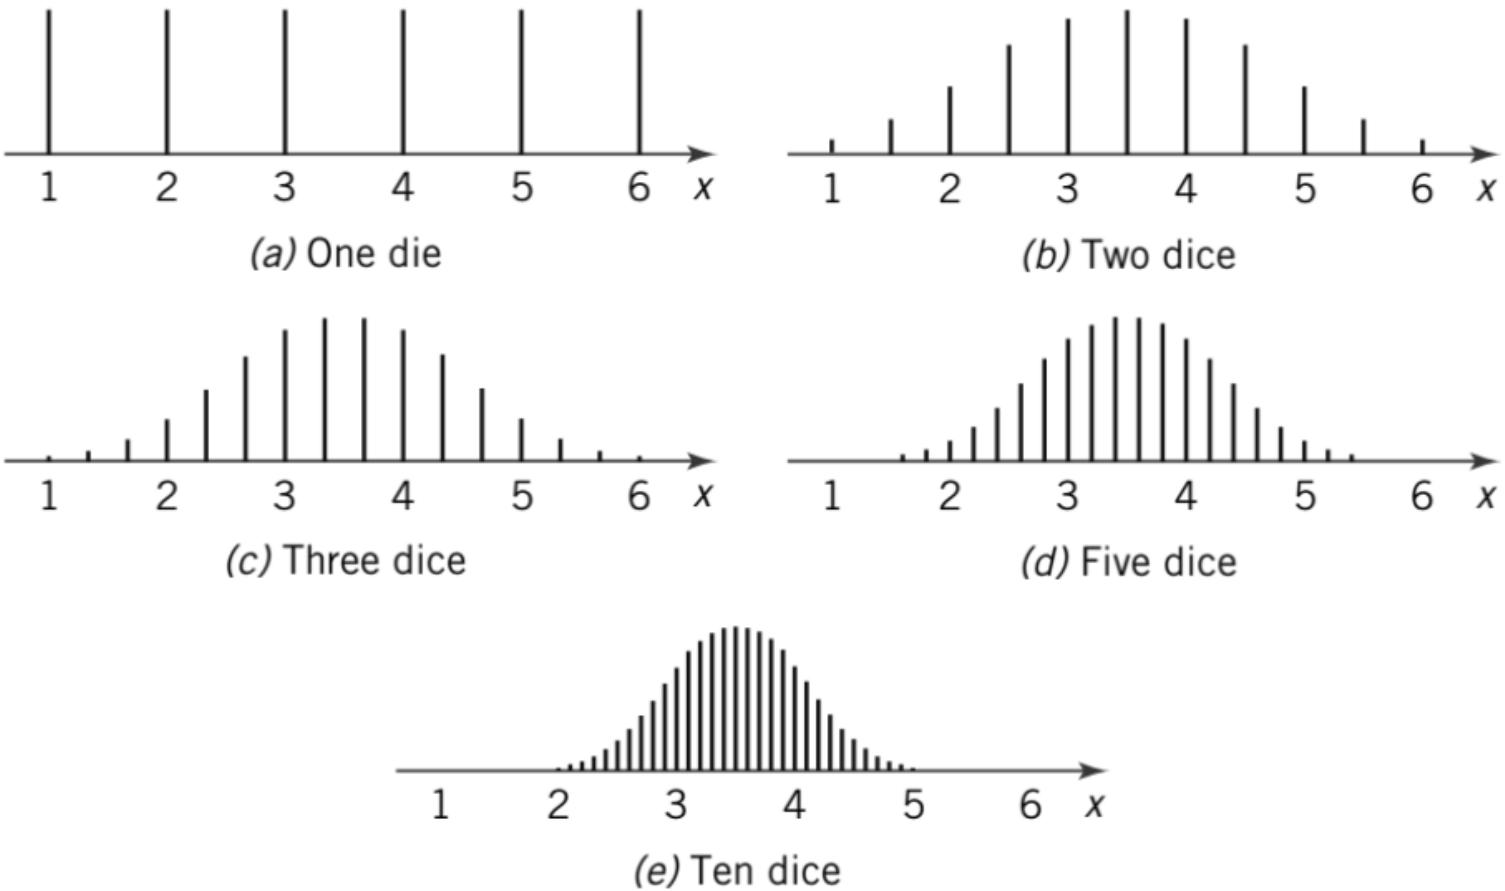
O TCL é válido para n grande e para qualquer amostra aleatória (observações iid).

- Normalmente se considera um $n > 30$ satisfatório;
- Amostras menores ($n < 30$) são suficientes apenas quando a PDF da variável aleatória que gera a amostra aleatória seja normal, ou pelo menos simétrica.

Umas das consequências do TCL, é que o estimador média amostral converge para uma distribuição normal de média μ e variância σ^2/n.

Em outras palavras, a distribuição amostral das médias amostrais $\overline{X}$ de um conjunto de N amostras aleatórias de tamanho n grande se aproxima da distribuição normal a medida que $N \to \infty$.

Exemplo: Distribuição da média dos valores obtidos no lançamentos de N dados de 6 faces.



Sejam duas populações **independentes**, com médias μ_1 e μ_2 e variâncias σ_1^2 e σ_2^2.

Sejam ainda $\overline{X}_1$ e $\overline{X}_2$ as médias amostrais de **amostras aleatórias independentes** de tamanho n_1 e n_2, extraídas das populações 1 e 2 respectivamente. A variável aleatória:

$$Z_n = \frac{\left(\overline{X}_1 - \overline{X}_2\right) - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}}$$

segue uma distribuição que aproxima a normal padrão se as condições do TCL forem respeitadas.

Se as duas populações são normais, então a distribuição amostral de Z_n é exatamente a normal padrão.

Algumas Distribuições de Probabilidade: Graus de Liberdade

Graus de liberdade podem ser interpretados como a quantidade de informação disponível na amostra aleatória para se estimar os valores de parâmetros populacionais desconhecidos.

O número de graus de liberdade (d) é calculado como a diferença entre o número de observações na amostra (n) e o número de parâmetros (p) que devem ser estimados para um modelo.

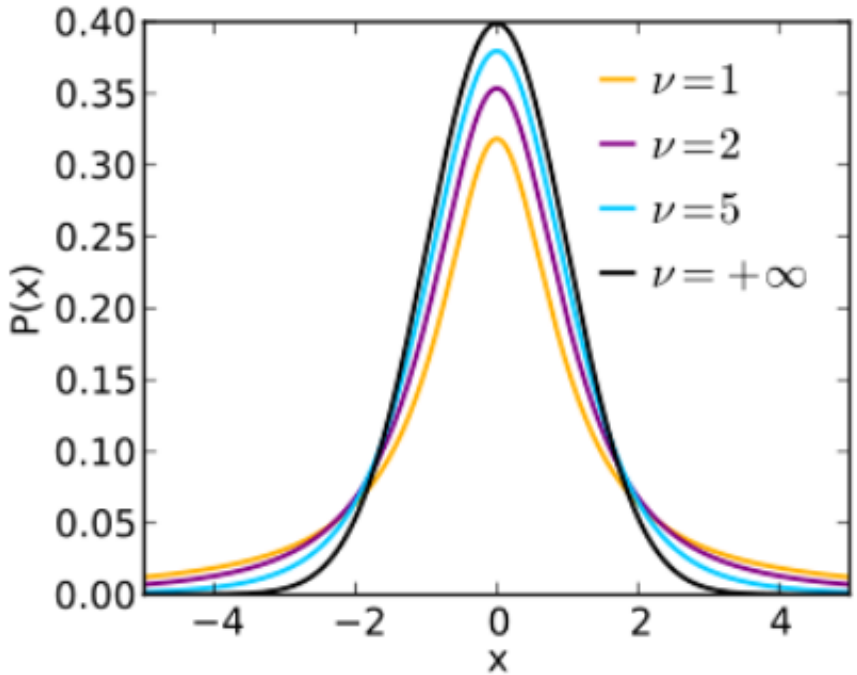
$$d = n - p$$

Algumas Distribuições de Probabilidade: Distribuição t-Student

Possui um único parâmetro: v - graus de liberdade.

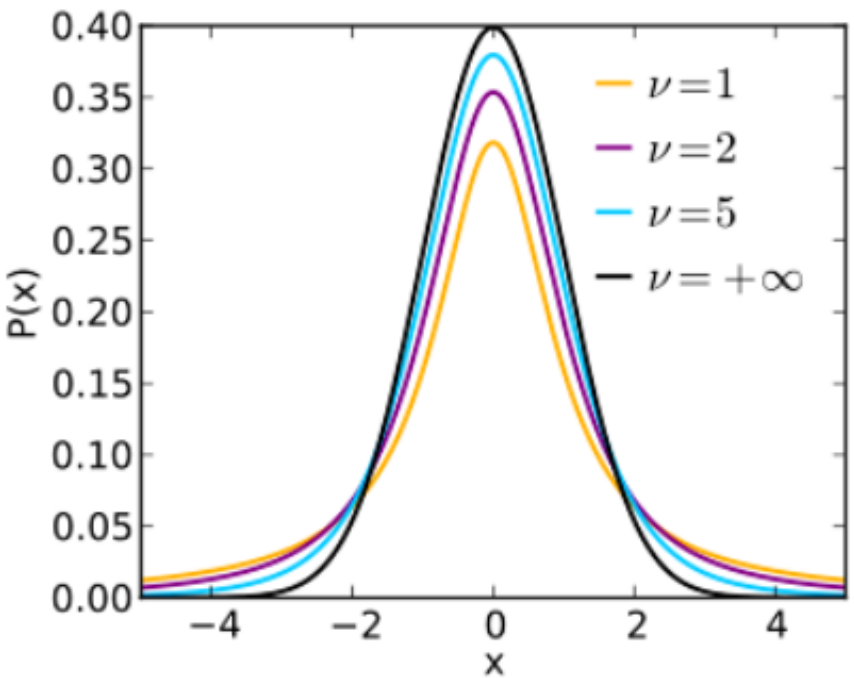
$$f(t) = \frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\nu\pi}\,\Gamma(\frac{\nu}{2})}\left(1+\frac{t^2}{\nu}\right)^{-(\frac{\nu+1}{2})}$$

Função Gama - $\Gamma(n) = (n-1)!$ se $n \in \mathbb{N}^*$



Tem comportamento similar à distribuição normal padrão, sendo mais conservadora (maior variância).

A distribuição t de Student se aproxima da normal com o aumento do número de graus de liberdade (v).



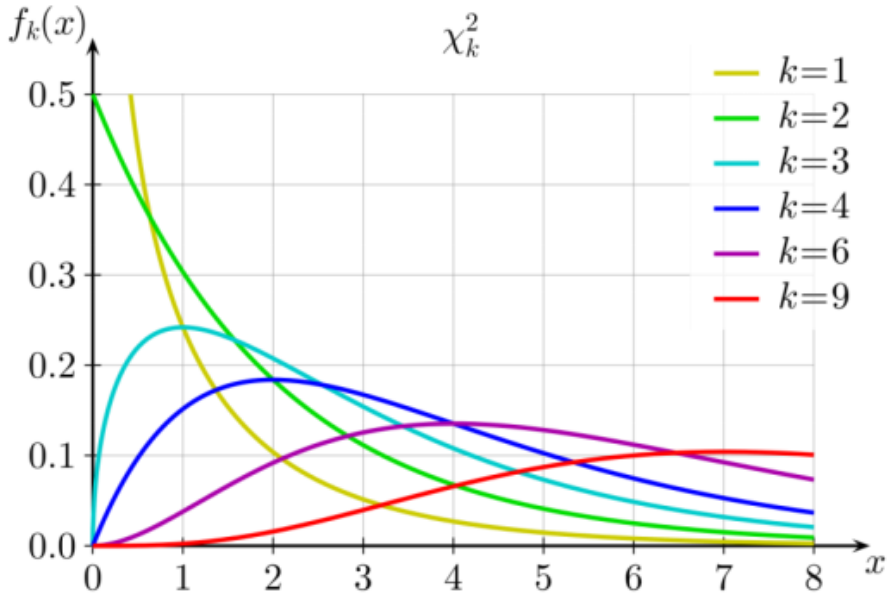
Tem grande relevância em análises estatísticas:

- Inferência para populações normais com variância desconhecida;
- Derivação de intervalos de confiança;
- Análise de regressões.

Algumas Distribuições de Probabilidade: Distribuição χ^2

Possui um único parâmetro: k - graus de liberdade

$$f(x,k) = \begin{cases} \dfrac{x^{k/2-1}e^{-x/2}}{2^{k/2}\Gamma(k/2)}, & x > 0; \\ 0 & \text{c. c.} \end{cases}$$



- Utilizada na estimação de intervalos de confiança e inferência.

Sejam $X_i \sim \mathcal{N}(0,1), i = 1, \ldots, k$ distribuições normais e independentes. A soma dos seus quadrados:

$$Q = Z_1^2 + \ldots + Z_k^2 = \sum_{i=1}^{k} Z_i^2$$

é distribuída de acordo com uma distribuição χ^2 com k graus de liberdade. Por consequência, o estimador variância amostral será proporcional à uma distribuição χ^2:

$$s^2 = \frac{\sum_{i=1}^{n} (x_i - \bar{x})^2}{n-1}$$

Utilizada em:

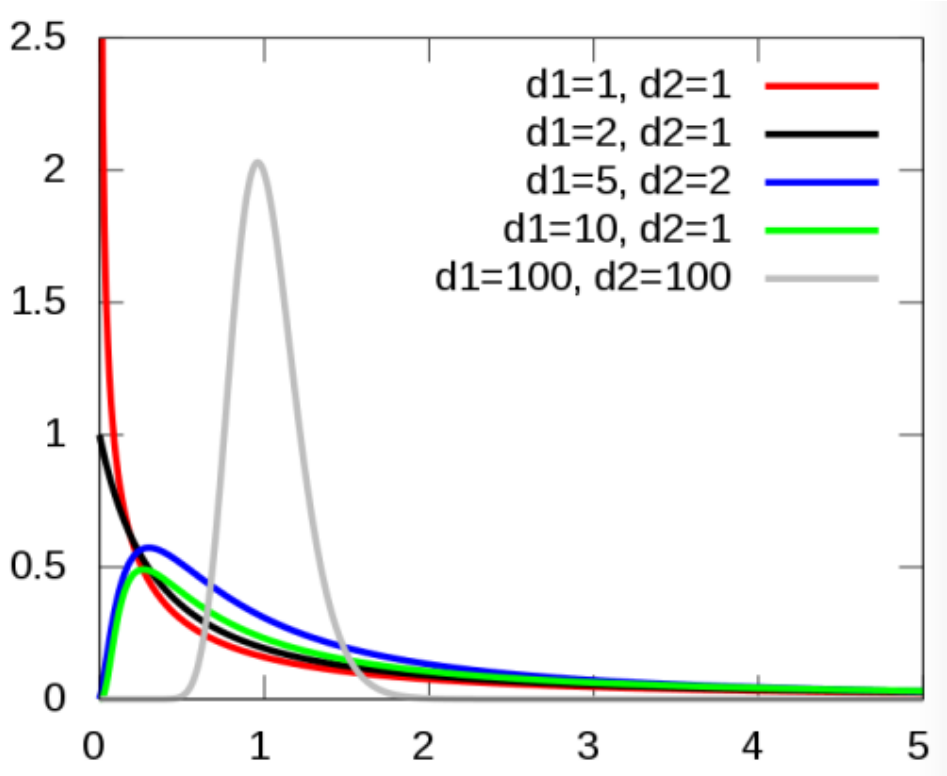
- Teste de hipóteses para as variâncias;
- Teste de independência;
- Teste da razão da verossimilhança.

Algumas Distribuições de Probabilidade: Distribuição F

Distribuição que descreve a razão entre as variâncias de duas populações normais.

$$f(x, d_1, d_2) = \frac{\sqrt{\frac{(d_1\,x)^{d_1}\;d_2^{d_2}}{(d_1\,x+d_2)^{d_1+d_2}}}}{x\,\mathrm{B}\left(\frac{d_1}{2}, \frac{d_2}{2}\right)}$$

onde d_1 e d_2 são os graus de liberdade e $\mathrm{B}(\cdot)$ é a função Beta.



Utilizada para verificar a hipótese de igualdade de variâncias e no teste ANOVA.

Algumas Distribuições de Probabilidade: Outras Distribuições

- Beta;
- Gama;
- Logística;
- Rayleigh;
- Gumbel;
- Exponencial*;
- Generalizada de valores extremos*;
- Lognormal*;
- Weibull*;

*Distribuições relevantes para Confiabilidade

Muitas outras: `https://docs.scipy.org/doc/scipy/reference/stats.html#continuous-distributions`

Referências

- D. C. Montgomery & G. C. Runger, *Applied statistics and probability for engineers*, 6th ed., Willey, 2013;

- P. D. T. O'Connor; A. Kleyner. *Practical Reliability Engineering*, 5a Ed., Wiley, 2012;