EEE 017 Confiabilidade de Sistemas

4a - Análise de Sobrevivência
Modelos de Tempo até o Evento

Michel Bessani
https://orcslab.github.io/
Departamento de Engenharia Elétrica - DEE

Engenharia de Sistemas

UFMG
UNIVERSIDADE FEDERAL
DE MINAS GERAIS

Belo Horizonte

Sumário

1. Introdução

2. Análise de Sobrevivência

3. Tipos de Dados de Sobrevivência

4. Ajuste por Ranqueamento

5. Ajuste por Métodos Computacionais

6. Referências

Introdução

Confiabilidade

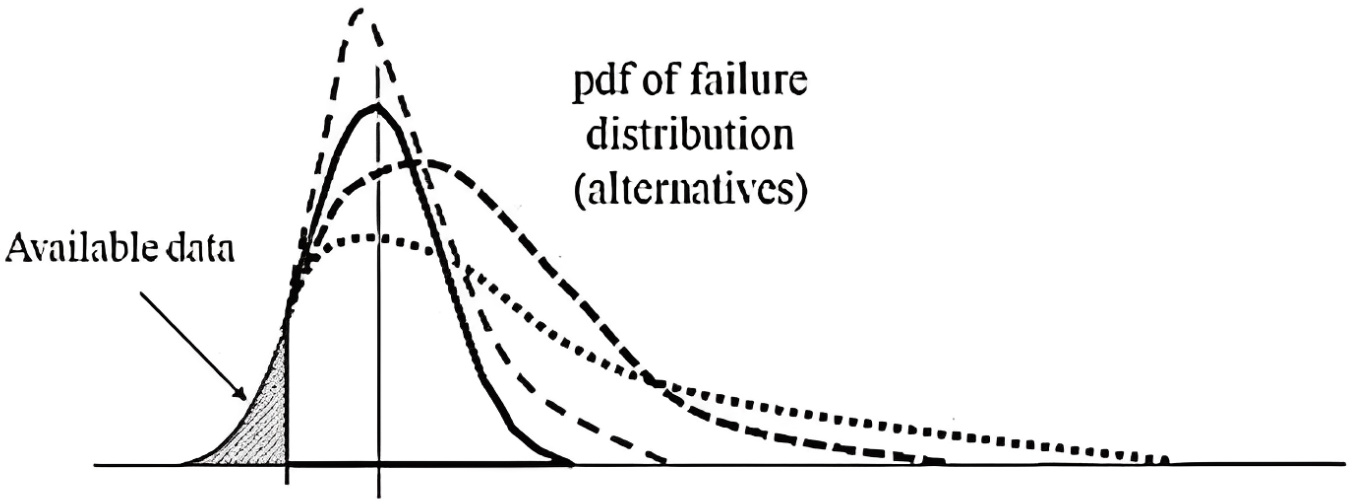
É a **probabilidade** de um item realizar uma **função desejada** sem falhas por um **período de tempo determinado**, sob **condições pré-estabelecidas**.

Em problemas de Engenharia de Confiabilidade teremos diferentes observações de **tempos até falha**, ou até outros eventos de interesse, **para um sistema** específico, o que será a nossa amostra aleatória (observações i.i.d.).

$$\mathbf{t} = \{t_1, \ldots, t_n\}$$

Dada uma amostra aleatória $\mathbf{t} = \{t_1, \ldots, t_n\}$, o processo de determinar **qual distribuição melhor descreve estes tempos** e quais os parâmetros de tal distribuição é chamado de **análise de sobrevivência** ou **modelos de tempo até o evento**.

A ideia geral é reconstruir uma função de distribuição de probabilidade para o tempo até o evento utilizando os dados disponíveis.



Análise de Sobrevivência

Na prática, tentaremos reconstruir a CDF, a qual é estritamente crescente, que melhor se ajusta aos dados.

Uma das formas mais simples é estimar, de forma manual, os parâmetros da distribuição utilizando as folhas de probabilidade.

Cada distribuição possui uma folha específica em que os eixos são ajustados de tal forma que observações seguindo a distribuição formem uma reta:

1. Plota-se os dados na folhas específica de uma distribuição;
2. Se as observações resultarem em uma reta, então pode-se inferir que a distribuição da folha utilizada é uma boa representação do processo

Gráfico ajustado para a distribuição Normal:

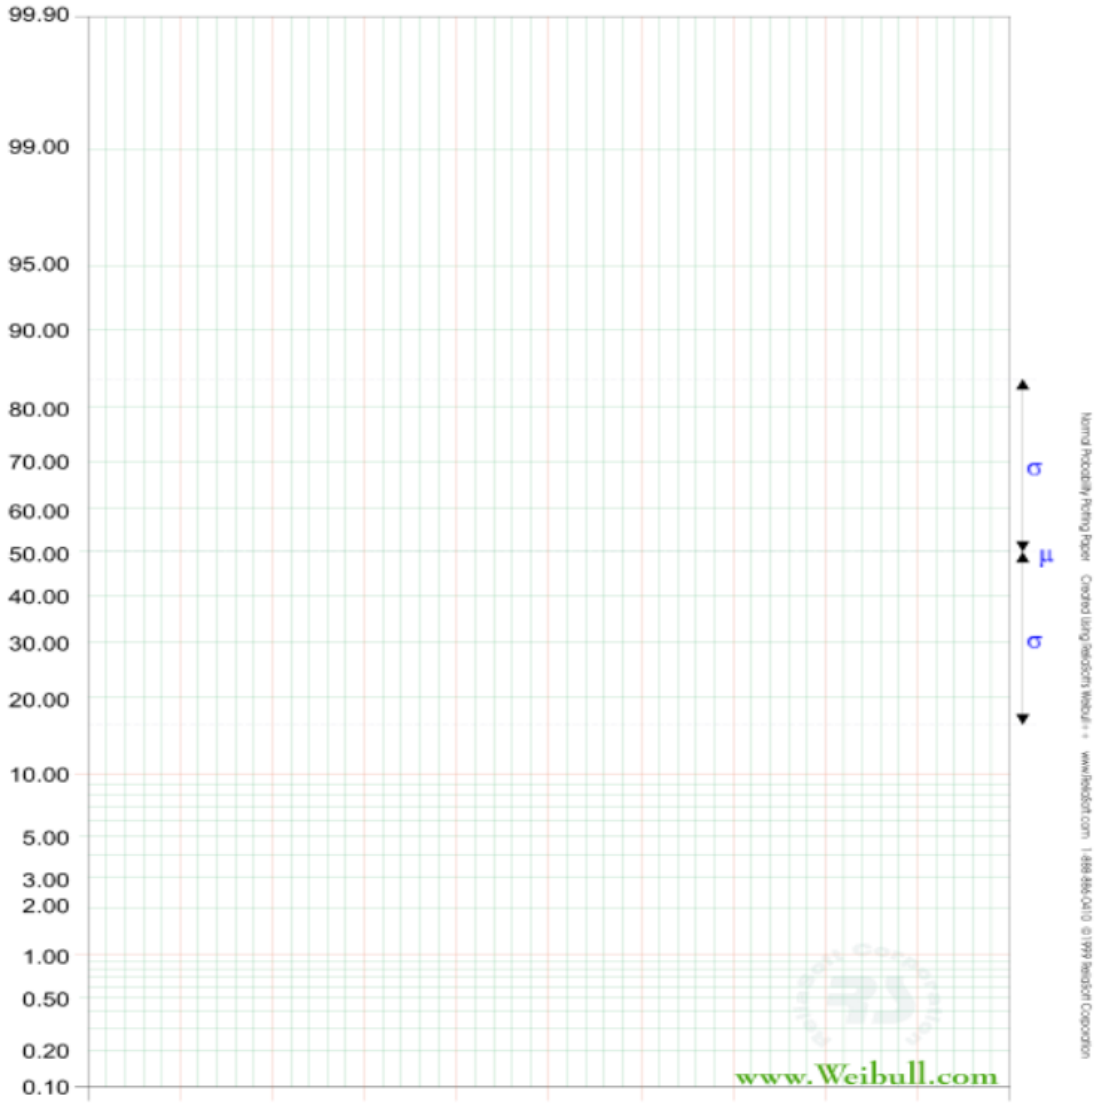


Gráfico ajustado para a distribuição Exponencial:

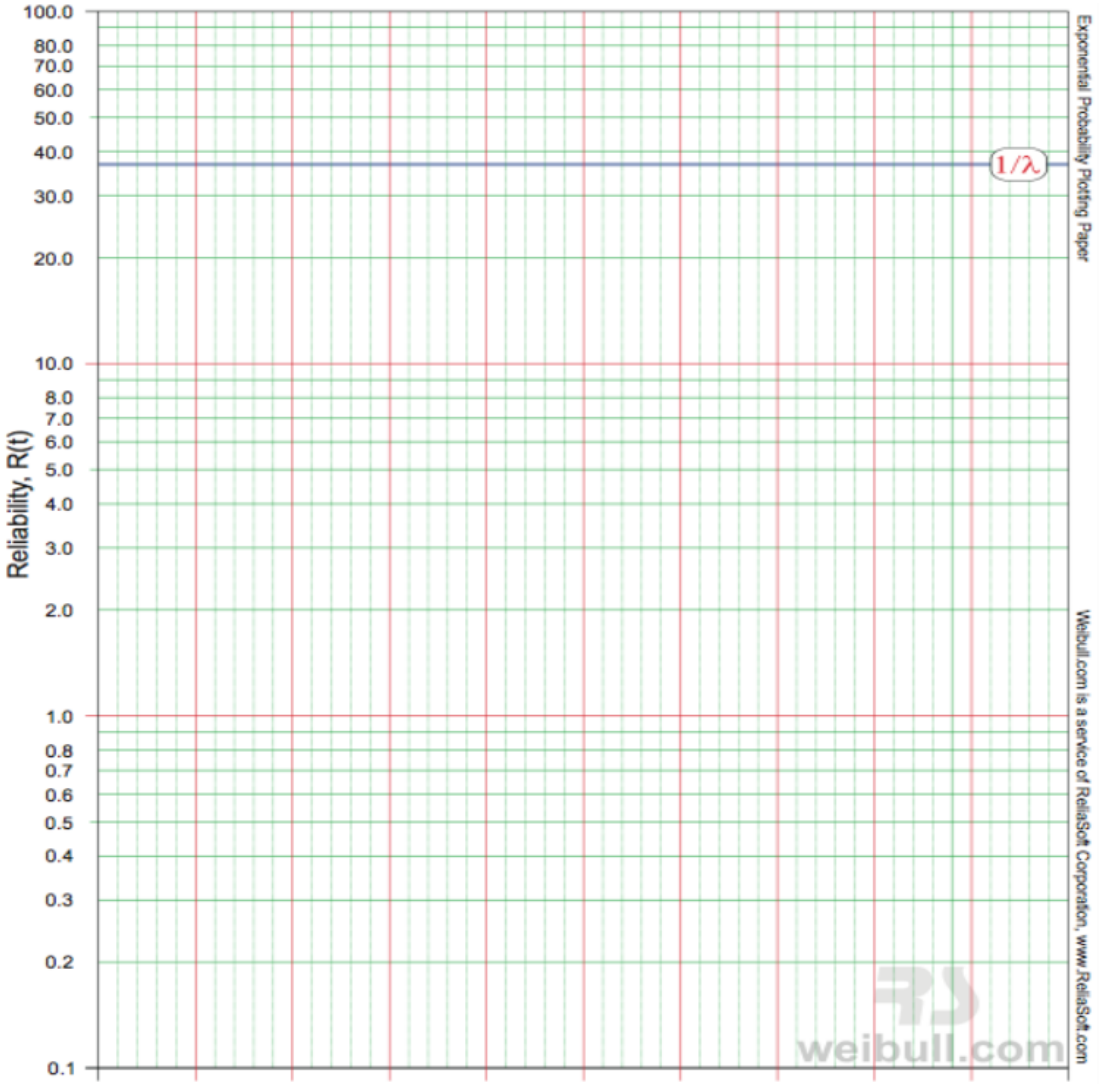


Gráfico ajustado para a distribuição LogNormal:

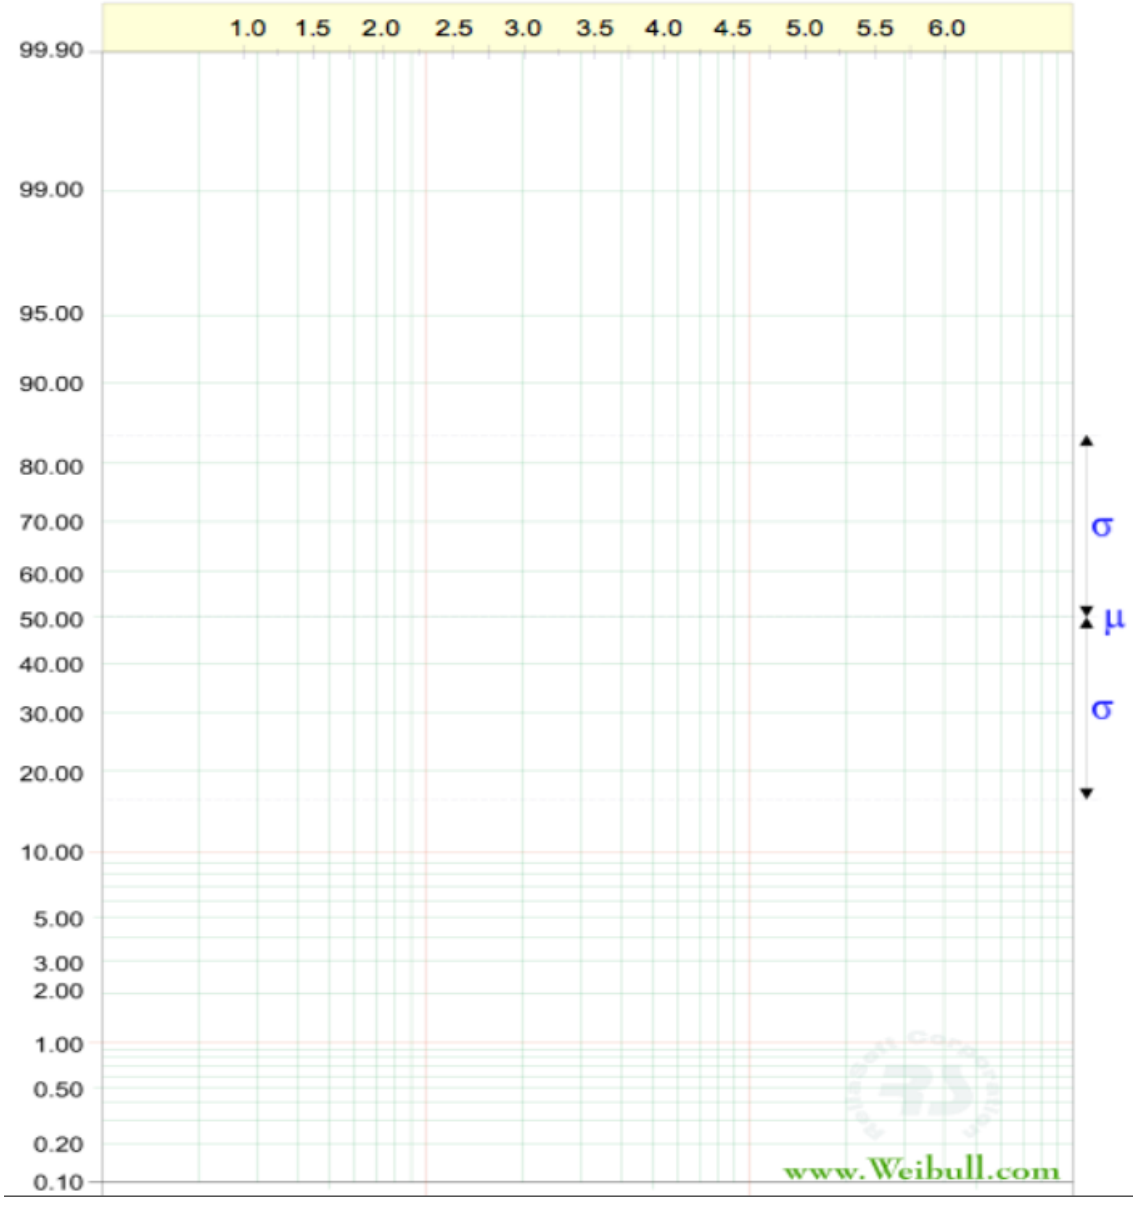
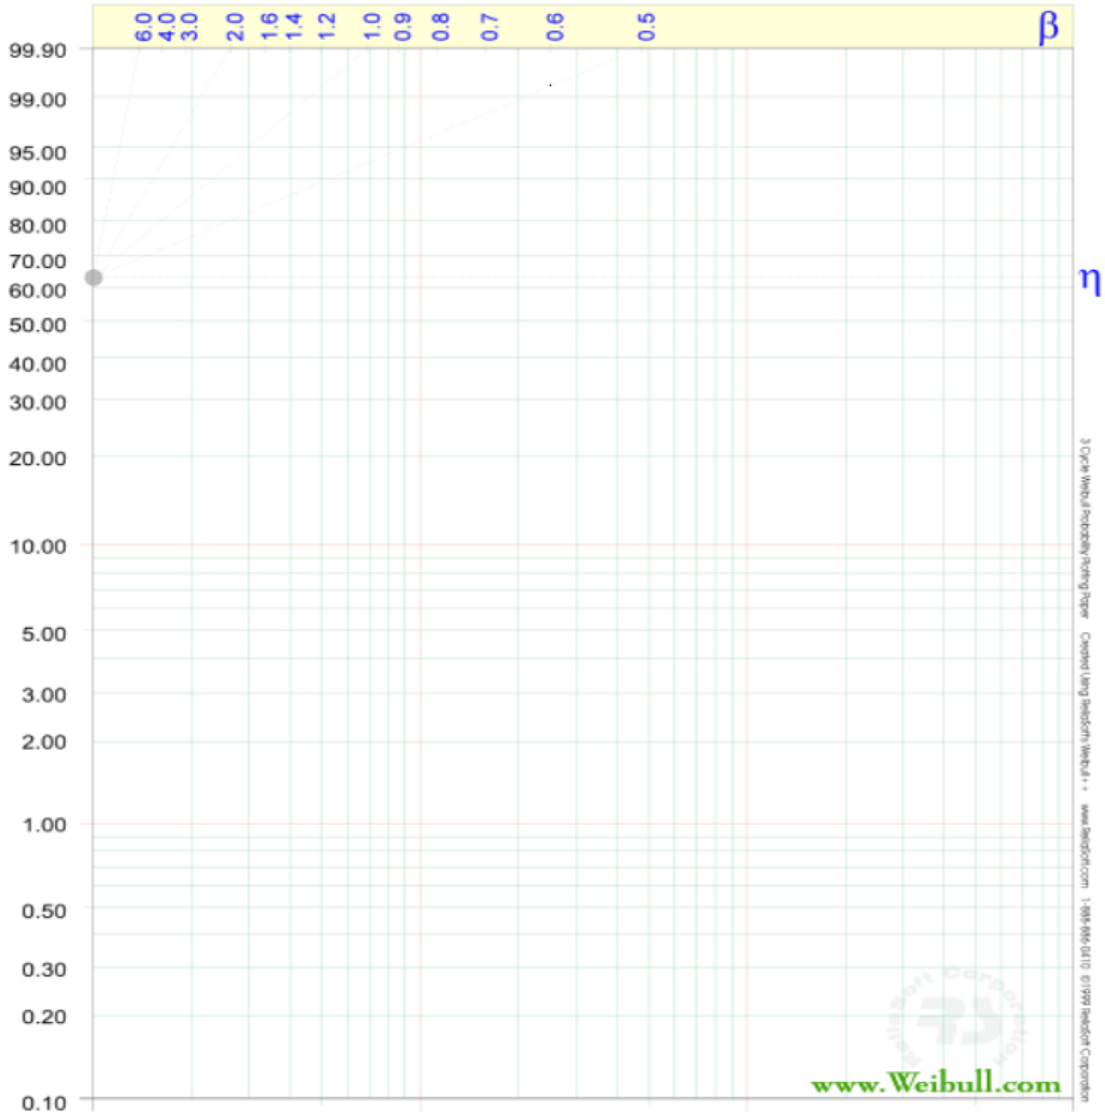


Gráfico ajustado para a distribuição Weibull:



Outra forma é utilizar de ferramentas computacionais para:

- Podemos construir os gráficos de probabilidade;
- Estimar os parâmetros que resultam no melhor ajuste.
  - Matlab
  - **R**
  - **Python**
  - Minitab
  - Reliasoft Weibull++

Atenção: Apesar da distribuição Weibull ser a mais popular para análise de dados de sobrevivência, existem situações em que outras distribuições como lognormal, distribuição de valores extremos e a exponencial se ajustam muito bem ou acabam sendo uma escolha mais adequada.

A escolha da distribuição mais adequada deve se basear em:

1. Medidas de qualidade de ajuste das distribuições;
2. Conhecimento prévio sobre o problema;
3. Julgamento do engenheiro de confiabilidade.

A análise de sobrevivência possui quatro etapas fundamentais:

1. **Coleta de Dados**: Obter os tempos de vida (até falha) do sistema;
2. **Análise e Modelagem**: Determinar qual o melhor modelo para os dados (ajuste da distribuição de probabilidade);
3. **Resultados**: Estimar tempo de vida médio, taxa de falha, ou qualquer outra estatística de interesse.
4. **Conclusões**:
   - Substituição do item?
   - Alterações do plano de manutenção? Por exemplo, adotar estratégias preventivas, preditivas ou prescritivas.
   - Buscar novos fornecedores?

Tipos de Dados de Sobrevivência

Em confiabilidade, assim como outros estudos de tempo até um evento, a sobrevivência de um dado sistema pode estar associada a diferentes variáveis:

- Tempo;
- Distância percorrida;
- Número de ligamentos ou desligamentos;
- Ciclos de operação;
- ...

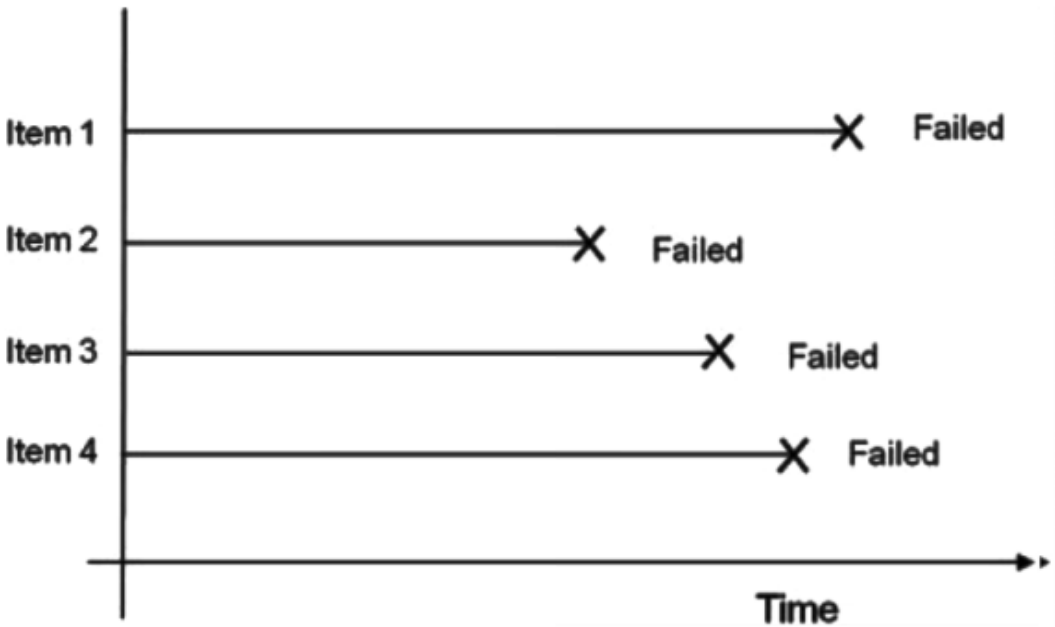
A assertividade e a credibilidade de qualquer estimativa é fortemente dependente da qualidade, precisão e completude dos dados utilizados.

Classificação de dados de tempos até falha (ou tempo até qualquer outro evento):

1. Dados completos;
2. Dados censurados à direita;
3. Dados censurados em intervalo;
4. Dados censurados à esquerda.

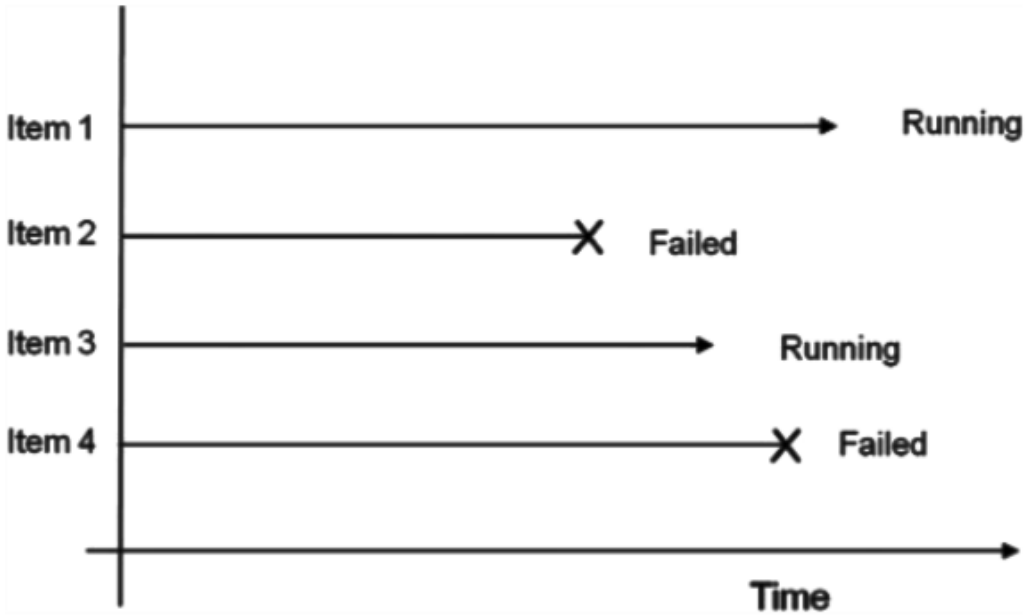
1. Dados completos

- Todas as observações da variável de interesse são conhecidas de forma exata.
- No caso específico de confiabilidade, os dados são completos quando todos os tempos até falha em uma amostra foram observados.



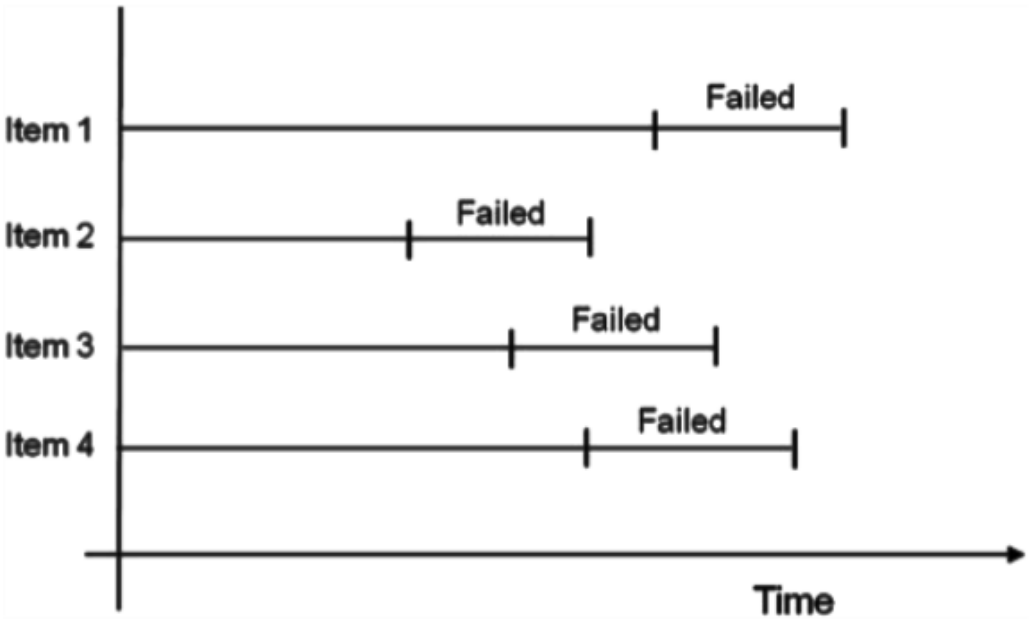
2. Dados censurados à direita

- Tipo mais comum de dados censurados;
- Ocorre quando não observamos o evento de interesse para uma ou mais observação, ou seja, significa que o evento de interesse está à direita do valor observado. Exemplo: Não ocorreu falha até o final do teste.



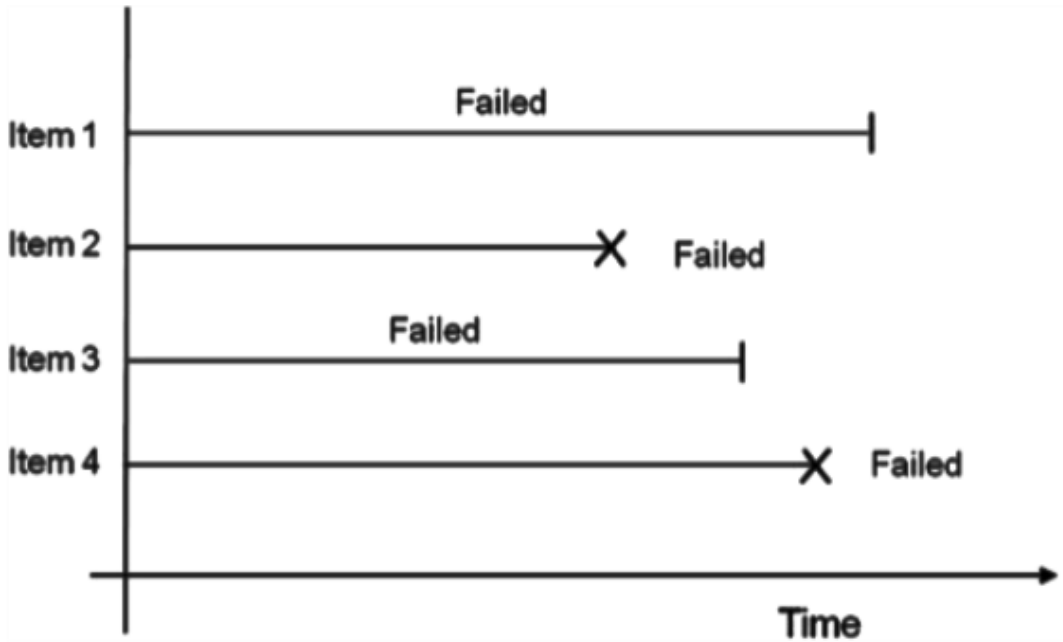
3. Dados censurados em intervalo

- Refletem a incerteza com relação ao instante de ocorrência do evento.
- Ocorre em situações onde a ocorrência do evento não é monitorada constantemente mas sim de forma periódica. Por exemplo, funcionamento monitorado de hora em hora.



4. Dados censurados à esquerda

- Sabe-se apenas que a falha ocorreu antes de um determinado tempo (ou a esquerda do ponto de observação).
- Este tipo de dado é equivalente ao dado censurado em intervalo se for considerado que o intervalo de censura começa em 0.



Algumas considerações sobre dados censurados:

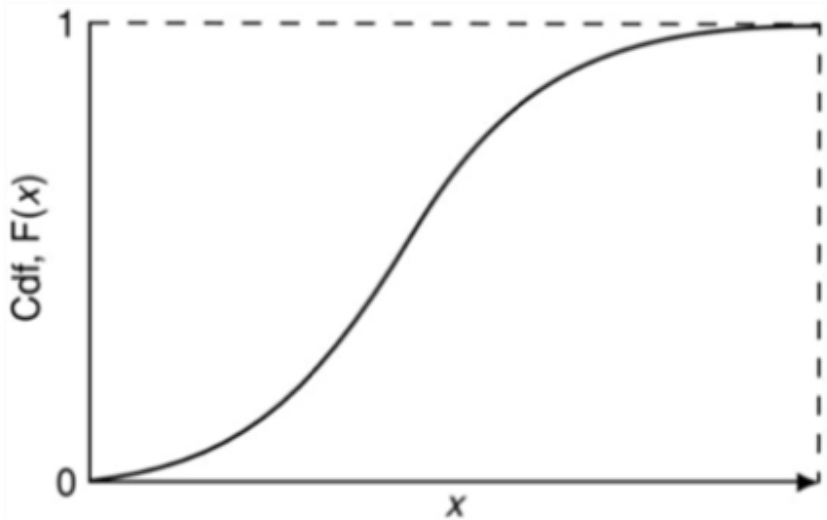
- Dados censurados possuem um maior nível de incerteza;
- Dados completos são mais facilmente tratados que dados censurados, visto que envolvem um menor nível de incerteza;
- Dados completos e dados censurados à direita geralmente podem ser avaliados utilizando métodos gráficos;
- Já dados censurados à esquerda e dados censurados em intervalo demandam abordagens mais sofisticadas, sendo geralmente tratados por **software**.

Ajuste por Ranqueamento

A estimativa das curvas de probabilidade é feita com base na relação entre a variável de interesse (tempo, distância, ciclos) e a probabilidade de falha acumulada (CDF).

Dessa forma, se faz necessário ordenar os dados e calcular a probabilidade cumulativa de cada ponto $\hat{F}(x)$ para posterior ajuste da $F(x)$.

$$P(X \leq x) = F(x) = \int_{-\infty}^{x} f(x)dx$$



O ranqueamento de dados fornece uma estimativa de qual proporção da população é representada por uma determinada amostra.

O ranqueamento de dados constitui uma alternativa ao uso de histogramas, tendo em vista que, em engenharia, geralmente se lida com amostras pequenas.

Ajuste por Ranqueamento: Ranqueamento Ingênuo (Naive ranking)

Considere um teste de cinco itens onde observou-se os seguintes tempos de falha $\mathbf{t} = \{200, 100, 500, 400, 300\}$.

O Ranqueamento Ingênuo é calculado como $r_n(i) = i/N$, onde i é o índice do valor no vetor ordenado ($\mathbf{t} = \{100, 200, 300, 400, 500\}$) e N é o tamanho da amostra aleatória.

Podemos estimar os seguintes ranques: $r_n(1) = 20\%$, $r_n(2) = 40\%$, $r_n(3) = 60\%$, $r_n(4) = 80\%$ e $r_n(5) = 100\%$.

- Este resultado implica que 20% da população falha até $t_1 = 100$ h e 100% da população falha em até $t_5 = 500$ h, o que provavelmente não é realista.

Ajuste por Ranqueamento: Ranqueamento Médio

O cálculo do ranqueamento médio é feito utilizando $N + 1$ no denominador.

Considerando a mesma amostra aleatória de tempos de falha
$\mathbf{t} = \{100, 200, 300, 400, 500\}$.

Ranqueamento Médio:

$$r_{avg}(i) = \frac{i}{N+1}$$

$$r_{avg}(1) = 1/6 = 0.167$$
$$r_{avg}(2) = 2/6 = 0.333$$
$$r_{avg}(3) = 3/6 = 0.500$$
$$r_{avg}(4) = 4/6 = 0.667$$
$$r_{avg}(5) = 5/6 = 0.833$$

Ajuste por Ranqueamento: Ranqueamento Mediano

O ranqueamento **mediano** é o método mais utilizado para esboçar gráficos de probabilidade.

- Este método é particularmente útil se a distribuição dos dados não é normal.
- O ranqueamento mediano pode ser definido como a proporção acumulada da população que é inferior a uma dada amostra, com 50% de confiança.
- O cálculo do ranqueamento mediano pode ser feito de diferentes formas.

Pode-se utilizar a Distribuição Binomial para calcular o ranqueamento mediano ($P = 0.50$):

$$P = \sum_{k=i}^{N} \frac{N!}{k!(N-k)!} Z^k (1-Z)^{N-k}$$

Nesse caso, resolve-se a equação da Binomial para encontrar o valor de Z para cada i-ésima falha na amostra aleatória ordenada.

O Ranqueamento mediano será o valor de Z, i.e., $r_{med}(i) = Z(i)$.

O ranqueamento mediano pode ser encontrado utilizando tabelas ou softwares específicos.

Existe também uma aproximação algébrica, conhecida como Aproximação de Bernard, para obter um **ranqueamento mediano aproximado**:

$$r_{med}(i) = \frac{i - 0.3}{N + 0.4}$$

Onde i é a posição da i-ésima falha observada após a ordenação dos tempos.

No nosso exemplo ilustrativo:

$$N = 5 \text{ e } t = [100, 200, 300, 400, 500]$$

	Observações				
Ranqueamentos	$i = 1$	$i = 2$	$i = 3$	$i = 4$	$i = 5$
$r_n(i)$	0.2000	0.400	0.600	0.800	1.000
$r_{avg}(i)$	0.1667	0.3333	0.5000	0.6667	0.8333
$r_{med}(i)$	0.1294	0.3147	0.5000	0.6853	0.8706
$r_{med}(i)$ (Aprox.)	0.1296	0.3148	0.5000	0.6852	0.8704

Ajuste por Ranqueamento: Ranqueamento de Dados Censurados

Ranqueamento de dados censurados.

O ranqueamento de dados censurados é mais complexo tendo em vista a incerteza relacionada a estes dados.

O caso mais simples é para dados censurados à direita:

- Os itens censurados (sem falha observada) não são considerados como observações para o gráfico de probabilidade;
- Mas a censura afeta o ranqueamento dos outros pontos;
- Portanto, se faz necessário atualizar o ranqueamento dos pontos com falhas observadas considerando a incerteza dos dados censurados.

Começamos ordenando os n itens que falharam ou foram censurados por ordem crescente de tempo de vida (t_i);

Para cada t_i observado (não censurado), determine:

1. O número ajustado de itens que falharam entre o instante atual de falha e o instante de falha anterior $i_{t_{i-1}}$;
2. O número de itens que falharam ou foram censurados anteriormente ($nfca$) e calcule N_{t_i}:
$$N_{t_i} = \frac{N + 1 - i_{t_{i-1}}}{N + 1 - nfca}$$
3. Para cada falha, calcule i_{t_i}: $i_{t_i} = i_{t_{i-1}} + N_{t_i}$

Com todos os i_{t_i} calculados, podemos calcular o ranqueamento mediano para cada i-ésimo item que falhou utilizando o ranqueamento mediano aproximado:

$$r_{med}(i) = \frac{i_{t_i} - 0.3}{N + 0.4}$$

Ilustrando: Vamos considerar os mesmos 5 itens, porém com os itens 2 e 4 censurados (não foram observadas as falhas e estes foram removidos do teste respectivamente com 200 e 400 horas):

$$N = 5 \text{ e } \mathbf{t} = \{100, 200^*, 300, 400^*, 500\}$$

Vamos calcular o ranqueamento ajustado para esta amostra aleatória com dados censurados.

$$N_{t_i} = \frac{N + 1 - i_{t_{i-1}}}{N + 1 - nfca} \qquad i_{t_i} = i_{t_{i-1}} + N_{t_i} \qquad r_{med}(i) = \frac{i_{t_i} - 0.3}{N + 0.4}$$

$$N = 5 \text{ e } t = [100, 200^*, 300, 400^*, 500]$$

A primeira observação não censurada é $t_1 = 100$:

$$N_{100} = \frac{5 + 1 - 0}{5 + 1 - 0} = 1.0$$
$$i_{100} = i_0 + N_{100} = 0 + 1.0$$
$$i_{100} = 0 + 1.0 = 1.0$$
$$r_{med}(i_{100}) = \frac{1 - 0.3}{5 + 0.4} = 0.1296$$

$$N_{t_i} = \frac{N+1-i_{t_{i-1}}}{N+1-nfca} \qquad i_{t_i} = i_{t_{i-1}} + N_{t_i} \qquad r_{med}(i) = \frac{i_{t_i}-0.3}{N+0.4}$$

Vamos fazer para as duas próximas observações não censuradas $t_3 = 300$ e $t_5 = 500$:

$$N_{300} = \frac{5+1-1}{5+1-2} = 1.25$$

$$i_{300} = i_{100} + N_{300}$$

$$i_{300} = 1.0 + 1.25 = 2.25$$

$$r_{med}(i_{300}) = \frac{2.25-0.3}{5+0.4} = 0.361$$

$$N_{500} = \frac{5+1-2.25}{5+1-4} = 1.875$$

$$i_{500} = i_{300} + N_{500}$$

$$i_{500} = 2.25 + 1.875 = 4.125$$

$$r_{med}(i_{500}) = \frac{4.125-0.3}{5+0.4} = 0.708$$

Comparação entre o ranqueamento considerando a censura e sem considerar:

i	t_i	Cens.	N_{t_i}	i_{t_i}	$r_{med}(i_{t_i})$	$r_{med}(i)$ sem os tempos cens.
1	100	Não	1.0	1.0	12.96%	20.59%
2	200	Sim	-	-	-	-
3	300	Não	1.25	2.25	36.11%	50%
4	400	Sim	-	-	-	-
5	500	Não	1.875	4.125	70.83%	79.41%

Ajuste por Ranqueamento: Exemplificando com a Weibull

Vamos ilustrar como utilizar os ranques estimados para estimar os parâmetros de uma distribuição Weibull.

Relembrando:

$$F(t) = 1 - \exp\left[-(t/\eta)^{\beta}\right]$$

Onde t é o tempo, β é o parâmetro de forma (*shape* ou *slope*) e η é o parâmetro de escala.

O η também é chamado de **tempo de vida característico**, pois ele indica o instante em que 63.2 % dos itens estarão em falha.

Vamos transformar $F(t)$ em uma expressão de uma reta: $y = ax + b$:

$$F(t) = 1 - \exp\left[-(t/\eta)^{\beta}\right]$$

$$1 - F(t) = \exp\left[-(t/\eta)^{\beta}\right]$$

$$\frac{1}{1 - F(t)} = \exp\left[(t/\eta)^{\beta}\right]$$

$$\ln\left(\frac{1}{1 - F(t)}\right) = (t/\eta)^{\beta}$$

$$\ln\ln\left(\frac{1}{1 - F(t)}\right) = \ln\left[(t/\eta)^{\beta}\right]$$

$$\underbrace{\ln\ln\left(\frac{1}{1 - F(t)}\right)}_{y} = \underbrace{\beta \ln t}_{ax} + \underbrace{(-\beta \ln \eta)}_{b}$$

No gráfico de probabilidade:

$$F(t) = 1 - \exp\left[-(t/\eta)^{\beta}\right]$$

$$\ln\ln\left(\frac{1}{1-F(t)}\right) = \beta \ln t - \beta \ln \eta$$

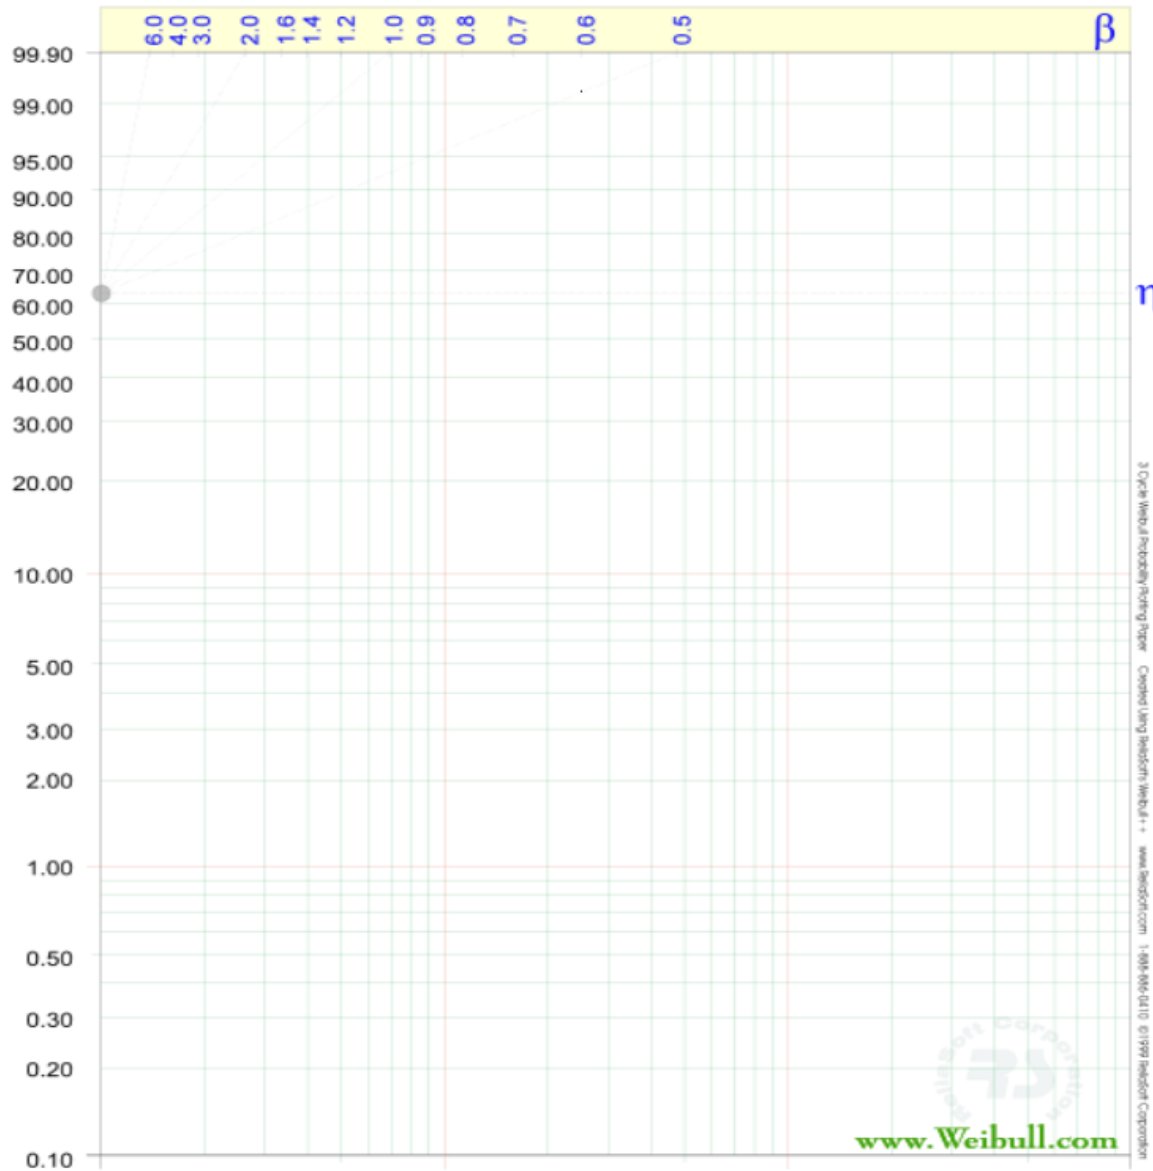
$$y = ax + b$$

$$y = \ln\ln\left(\frac{1}{1-F(t)}\right)$$

$a = \beta$, $x = \ln t$ e $b = -\beta \ln \eta$

$$F(\eta) = 1 - \exp\left[-(\eta/\eta)^{\beta}\right]$$

$$F(\eta) = 1 - \exp(-1) = 0.632$$



Vamos estimar os parâmetros da Weibull para o exemplo de cinco unidades que falharam em 100, 200, 300, 400 e 500 horas.

Primeiro calculamos o ranqueamento mediano:

$$r_{med}(i) = \frac{i - 0.3}{N + 0.4}$$

- 100 horas: 12.94%;
- 200 horas: 31.47%;
- 300 horas: 50.00%;
- 400 horas: 68.53%;
- 500 horas: 87.06%.

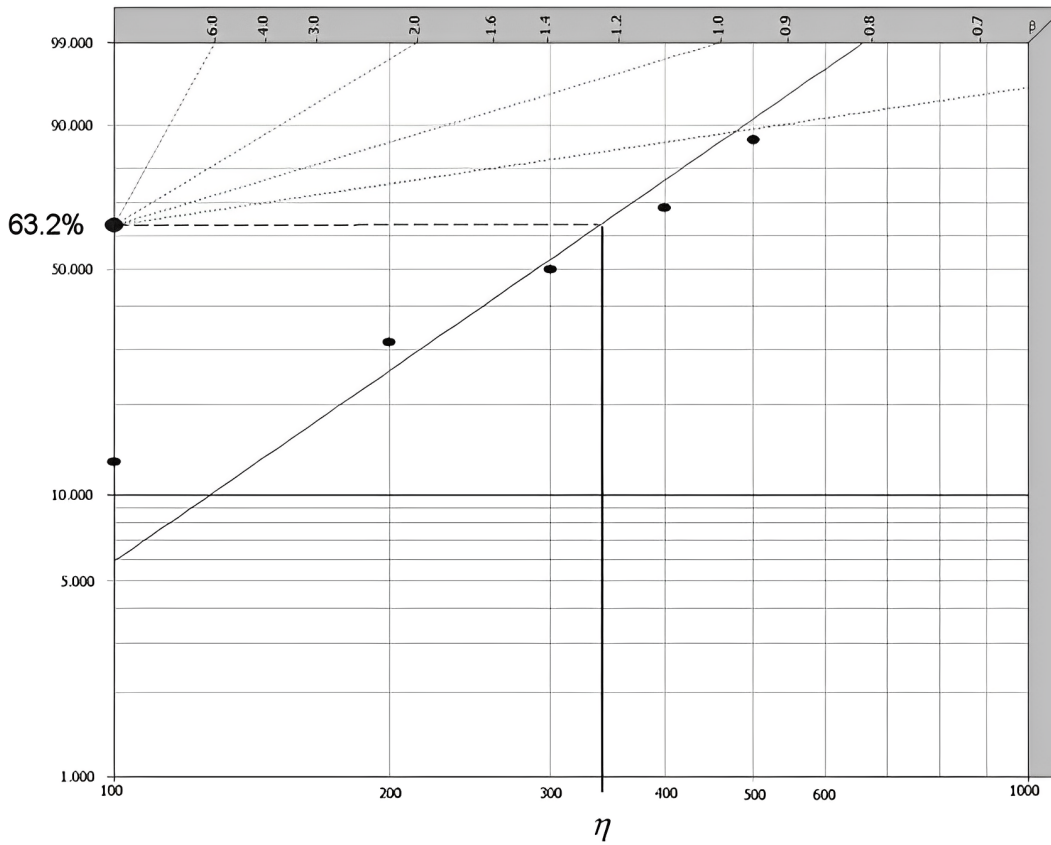
Marcar os pontos no gráfico Weibull e estimar os parâmetros:

- 100 horas: 12.94%;
- 200 horas: 31.47%;
- 300 horas: 50.00%;
- 400 horas: 68.53%;
- 500 horas: 87.06%.

$$y = ax + b$$

$$a = \beta$$

$$F(\eta) = 1 - \exp\left[-(\eta/\eta)^{\beta}\right] = 0.632$$



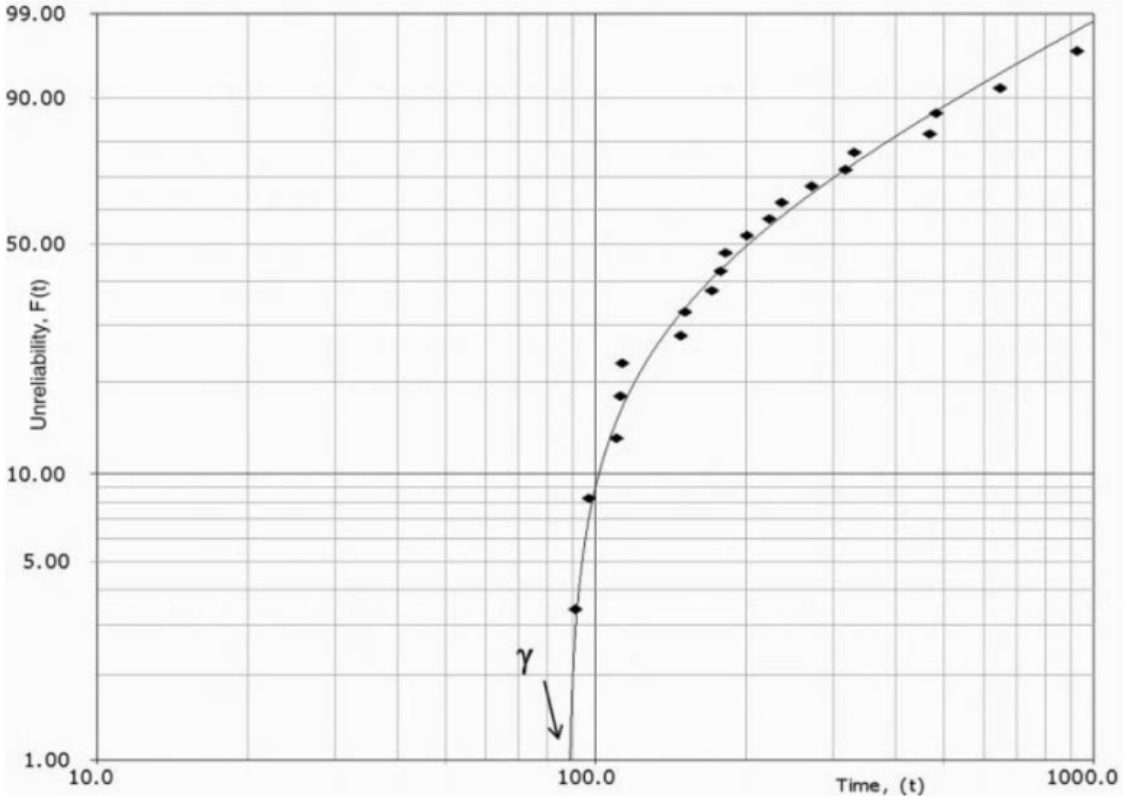
Weibull de Três Parâmetros:

$$F(t) = 1 - \exp\left[-\left(\frac{t-\gamma}{\eta}\right)^{\beta}\right]$$

Onde:

- t é o tempo;
- β é o parâmetro de forma, associado ao comportamento da função de risco;
- η é o parâmetro de escala, ou tempo de vida característico que é o instante em que 63.2% dos itens estão em falha;
- O parâmetro γ é um parâmetro de localização, conhecido como **tempo mínimo de vida esperado**.

Recomendada apenas se for possível afirmar, com muita segurança, que o sistema ou produto possui uma **vida mínima garantida** γ.



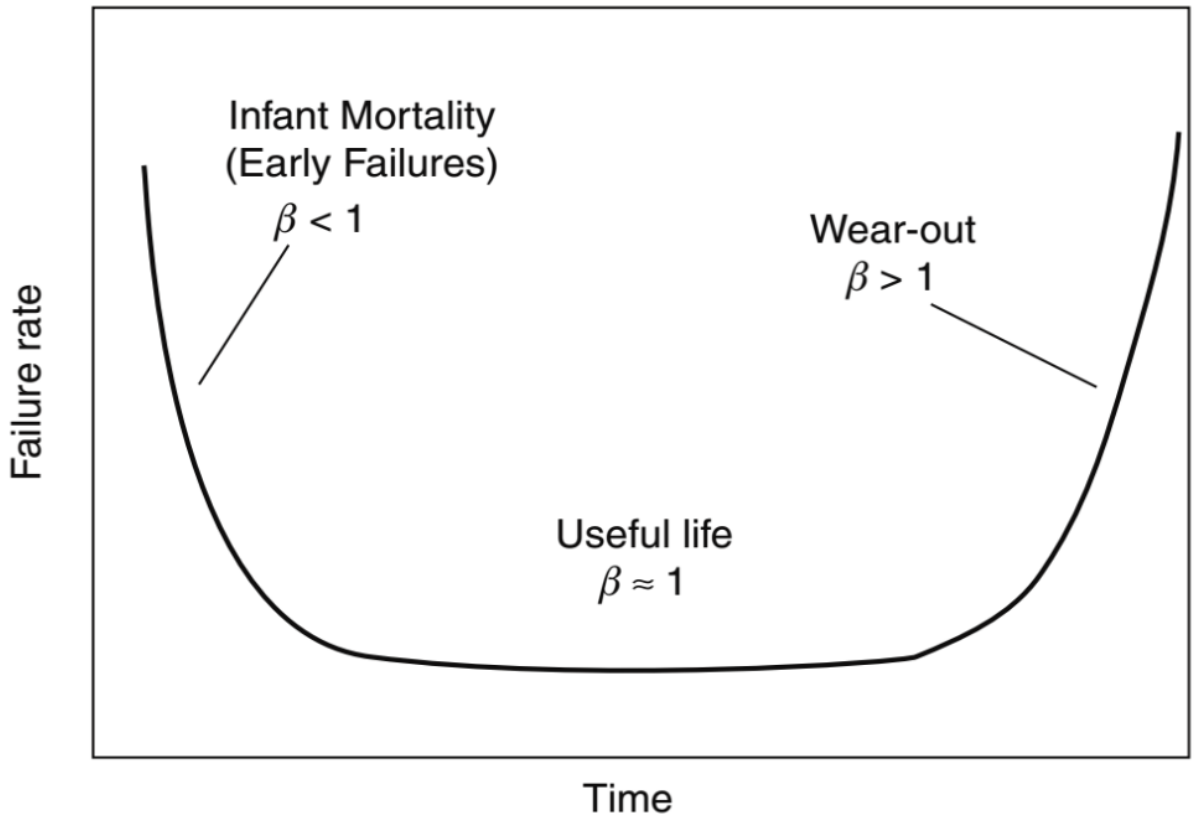
Situações onde ocorreram extensa inspeção previamente ao uso ou comercialização do sistema.

O β reflete o comportamento da taxa de falha, ou função de risco $h(t)$, esperada:

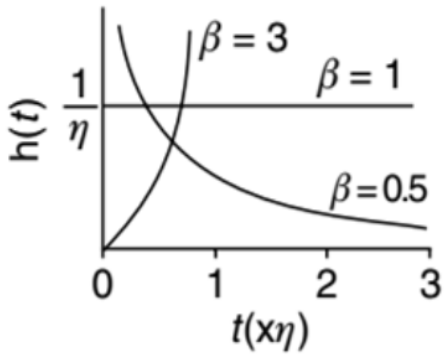
$$h(t) = \frac{f(t)}{R(t)} = \frac{f(t)}{1 - F(t)} \qquad h(t) = \frac{\beta}{\eta^{\beta}} t^{\beta - 1}$$

Uma vez estimado o β da Weibull, podemos inferir sobre o comportamento de falhas de uma população, em especial o estágio do ciclo de vida, através do valor ajustado $\hat{\beta}$.

Curva da Banheira



Weibull



$$h(t) = \frac{\beta(t-\gamma)^{\beta-1}}{\eta^{\beta}}$$

Ajuste por Métodos Computacionais

Os métodos computacionais utilizam os mesmos princípios discutidos anteriormente.

Queremos ajustar, de forma ótima, os parâmetros de uma distribuição de probabilidade (nosso modelo) para termos o melhor valor possível de alguma função de qualidade de ajuste.

Por exemplo:

- Minimizar o erro ao se representar as observações em um gráfico de probabilidade (**Mínimos Quadrados**);
- Maximizar a probabilidade de observar os dados com um conjunto de parâmetros (**Máxima Verossimilhança**).

Ajuste por Métodos Computacionais: Estimação por Mínimos Quadrados

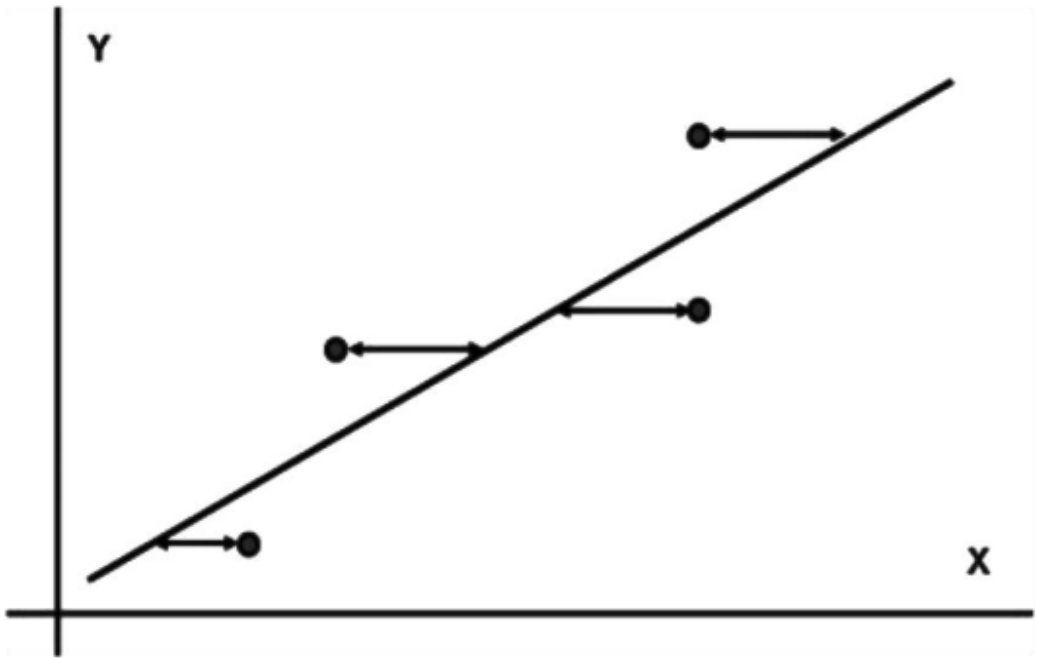
Regressão por Ranqueamento e Estimação por Mínimos Quadrados.

Quando fazemos a regressão por ranqueamento dos tempos, podemos ajustar diferentes retas que irão representar distribuições com diferentes parâmetros.

A forma mais aceita para ajustar tal reta é escolher os parâmetros que minimizam a soma dos quadrados dos desvios (erro quadrático) verticais ou horizontais.

- Princípio dos Mínimos Quadrados.

Considerando os pares de observações $(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$ obtidos e representados no gráfico, o princípio dos mínimos quadrados é ajustar uma reta que minimize a distância entre a reta e os pontos.



Regressão por Ranqueamento e Estimação por Mínimos Quadrados.

Ajustar uma reta:$x = \hat{a} + \hat{b}y$

Métrica de ajuste: $L = \sum_{i=1}^{n} \epsilon^2 = \sum_{i=1}^{n} \left(x_i - \hat{a} + \hat{b}y_i \right)^2$

Ajuste dos parâmetros a e b : $\frac{dL}{da} = 0$ e $\frac{dL}{db} = 0$

O que resulta em: $\hat{b} = \frac{\sum_{i=1}^{n} x_i y_i - \frac{\sum_{i=1}^{n} x_i \sum_{i=1}^{n} y_i}{n}}{\sum_{i=1}^{n} y_i^2 - \frac{\left(\sum_{i=1}^{n} y_i\right)^2}{n}}$

$$\hat{a} = \frac{\sum_{i=1}^{n} x_i}{n} - \hat{b}\frac{\sum_{i=1}^{n} y_i}{n} = \overline{x} - \hat{b}\overline{y}$$

Ajuste por Métodos Computacionais: Estimação por Máxima Verossimilhança

Continua na próxima aula - **4b_AnaliseSobrevivencia**.

Referências

Referências

- P. D. T. O'Connor; A. Kleyner, *Practical Reliability Engineering*, 5a Ed., Wiley, 2012;
- E. Colosimo; S. R. Giolo, *Análise de sobrevivência aplicada*, Blucher, 2006;
- D. C. Montgomery & G. C. Runger, *Applied statistics and probability for engineers*, 6th ed., Willey, 2013;
- U. Genschel & W. Q. Meeker, *A comparison of maximum likelihood and median-rank regression for Weibull estimation*, Quality Engineering, 22.4 (2010): 236-255.