EEE 017 Confiabilidade de Sistemas

4a - Análise de Sobrevivência
Modelos de Tempo até o Evento

Michel Bessani
https://orcslab.github.io/
Departamento de Engenharia Elétrica - DEE

Engenharia de Sistemas

UFMG
UNIVERSIDADE FEDERAL
DE MINAS GERAIS

Belo Horizonte

Sumário

1. Introdução

2. Análise de Sobrevivência

3. Tipos de Dados de Sobrevivência

4. Ajuste por Ranqueamento

5. Ajuste por Métodos Computacionais

6. Intervalos de Confiança

7. Escolha de uma Distribuição

8. Referências

Introdução

Confiabilidade

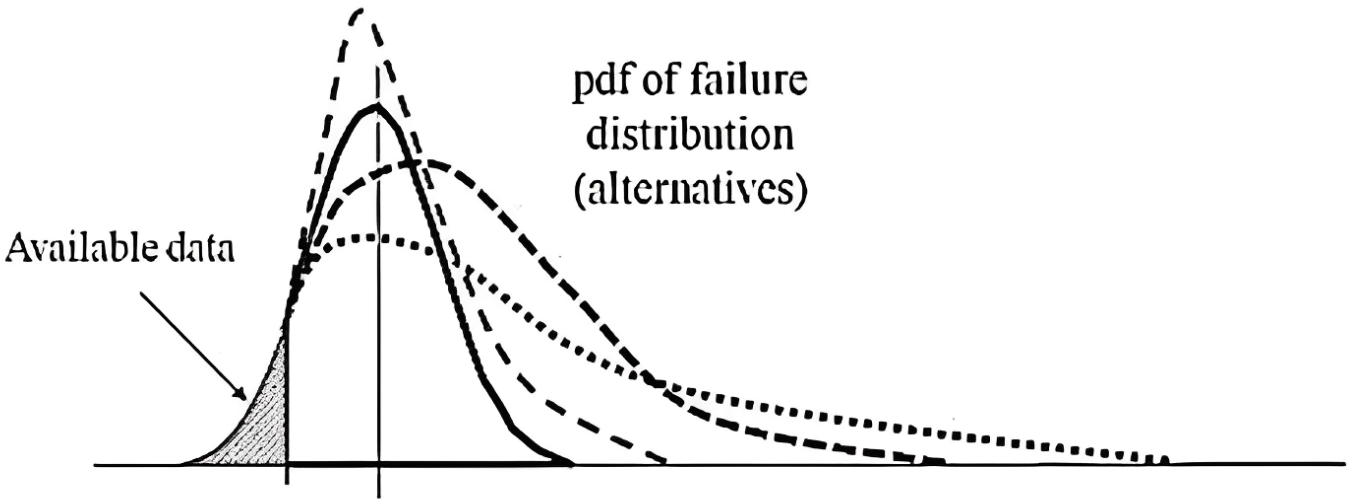
É a **probabilidade** de um item realizar uma **função desejada** sem falhas por um **período de tempo determinado**, sob **condições pré-estabelecidas**.

Em problemas de Engenharia de Confiabilidade teremos diferentes observações de **tempos até falha**, ou até outros eventos de interesse, **para um sistema** específico, o que será a nossa amostra aleatória (observações i.i.d.).

$$\mathbf{t} = \{t_1, \ldots, t_n\}$$

Dada uma amostra aleatória $\mathbf{t} = \{t_1, \ldots, t_n\}$, o processo de determinar **qual distribuição melhor descreve estes tempos** e quais os parâmetros de tal distribuição é chamado de **análise de sobrevivência** ou **modelos de tempo até o evento**.

A ideia geral é reconstruir uma função de distribuição de probabilidade para o tempo até o evento utilizando os dados disponíveis.



Análise de Sobrevivência

Na prática, tentaremos reconstruir a CDF, a qual é estritamente crescente, que melhor se ajusta aos dados.

Uma das formas mais simples é estimar, de forma manual, os parâmetros da distribuição utilizando as folhas de probabilidade.

Cada distribuição possui uma folha específica em que os eixos são ajustados de tal forma que observações seguindo a distribuição formem uma reta:

1. Plota-se os dados na folhas específica de uma distribuição;
2. Se as observações resultarem em uma reta, então pode-se inferir que a distribuição da folha utilizada é uma boa representação do processo

Gráfico ajustado para a distribuição Normal:

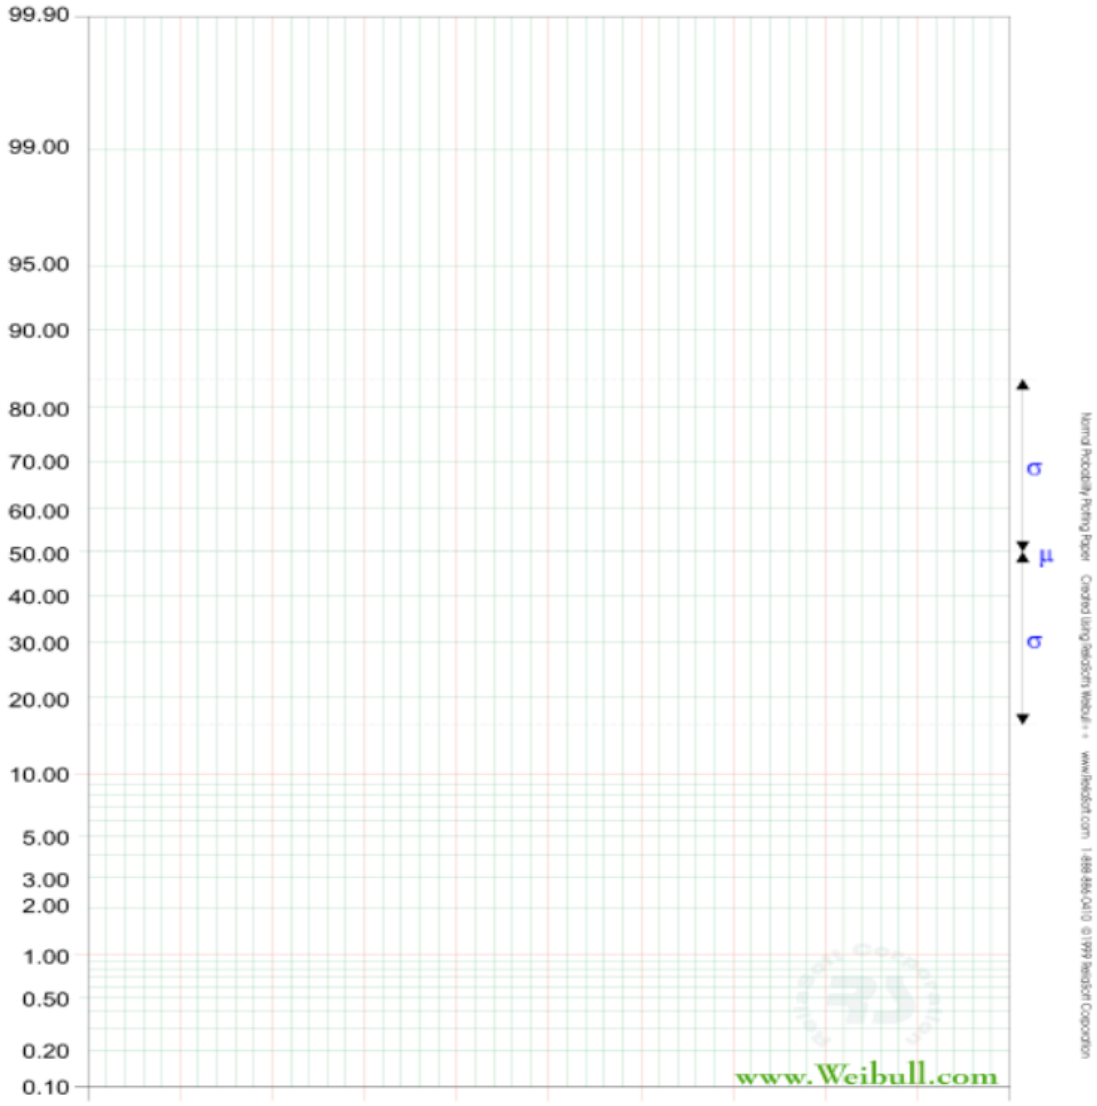


Gráfico ajustado para a distribuição Exponencial:

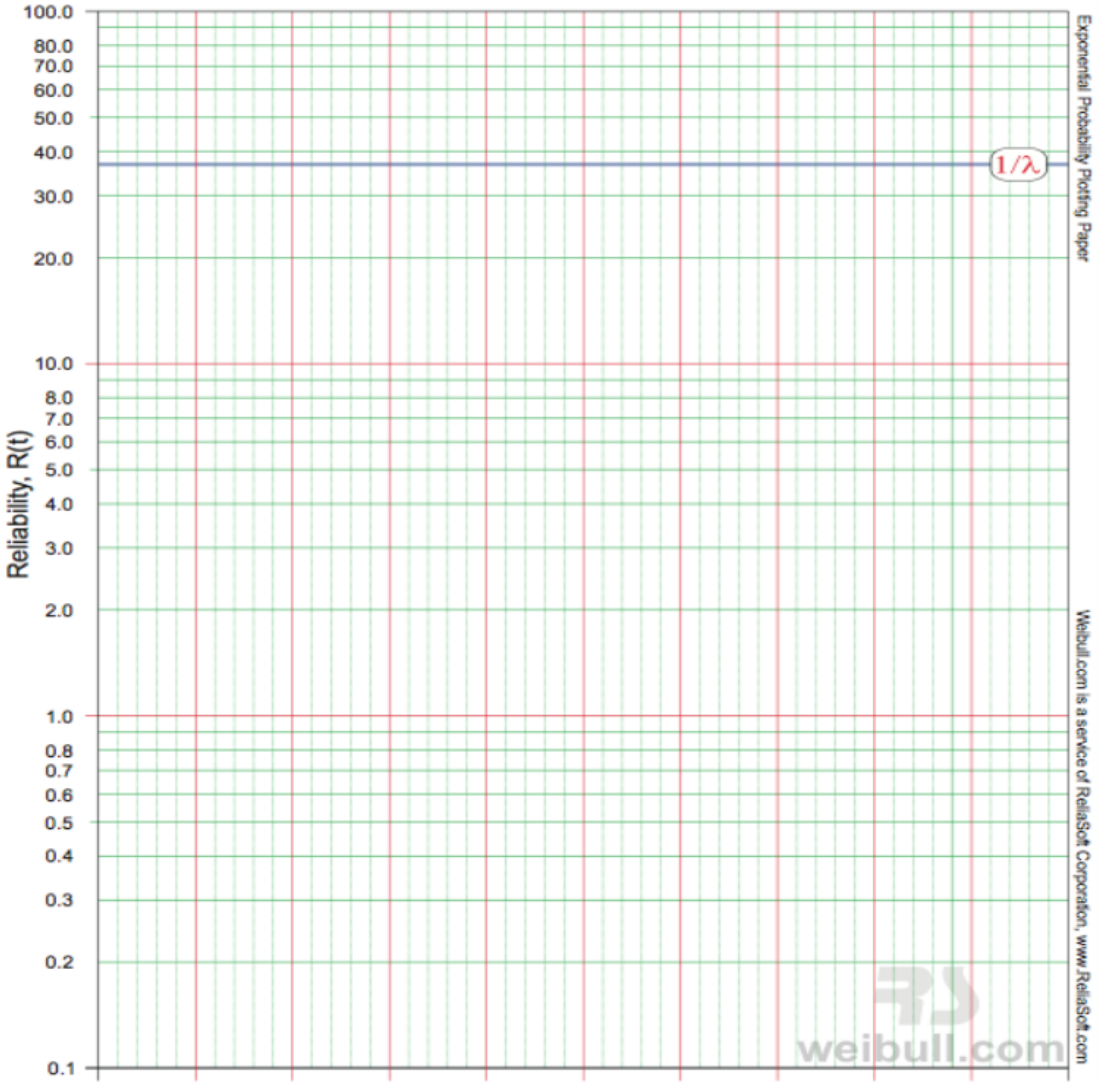


Gráfico ajustado para a distribuição LogNormal:

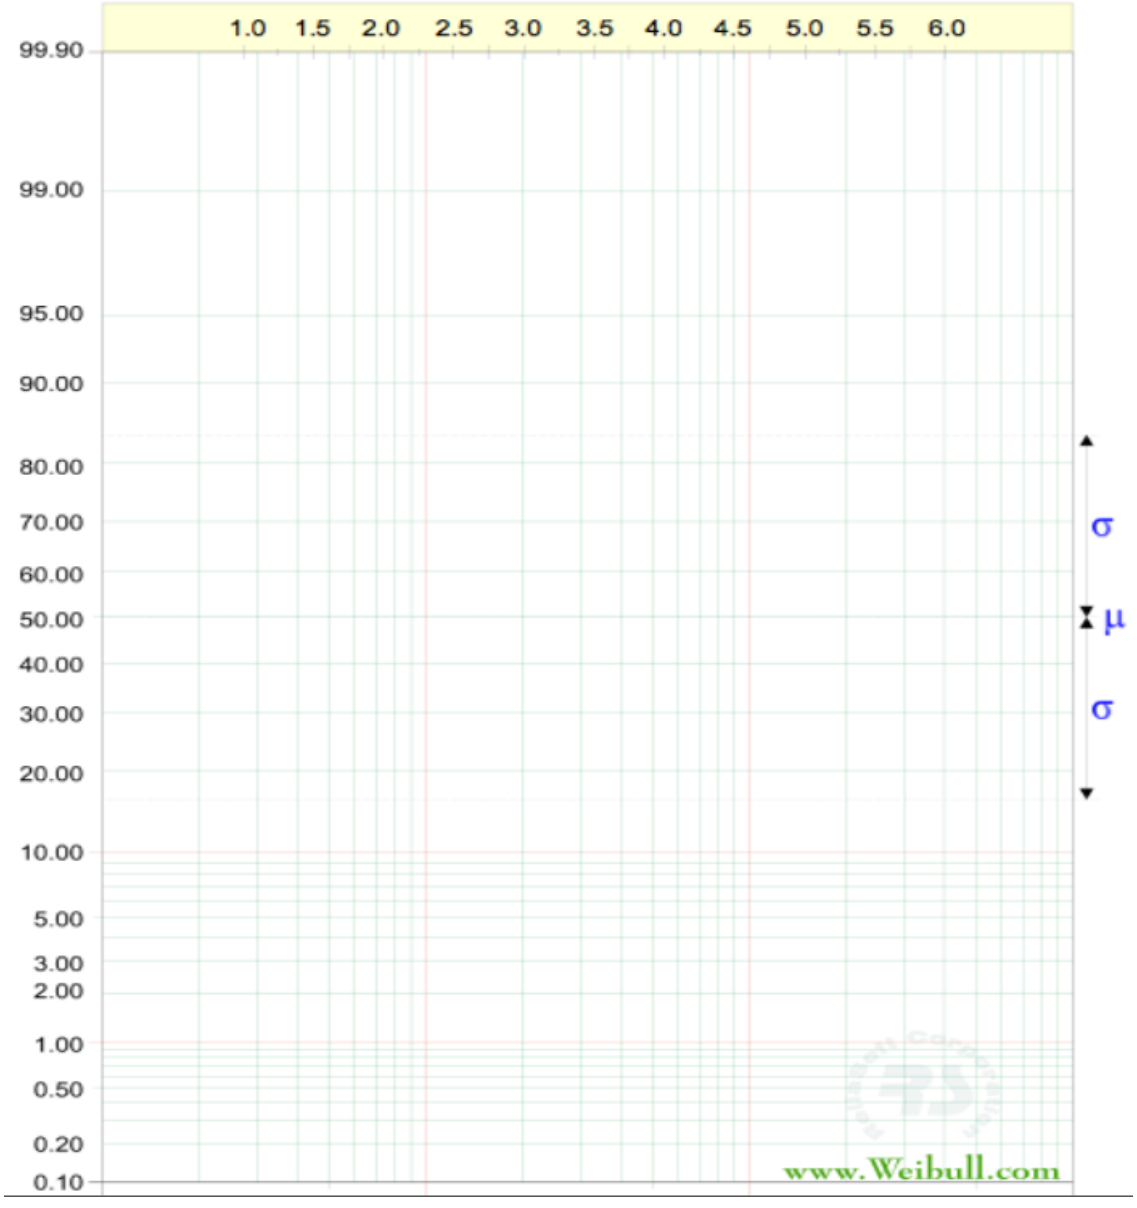
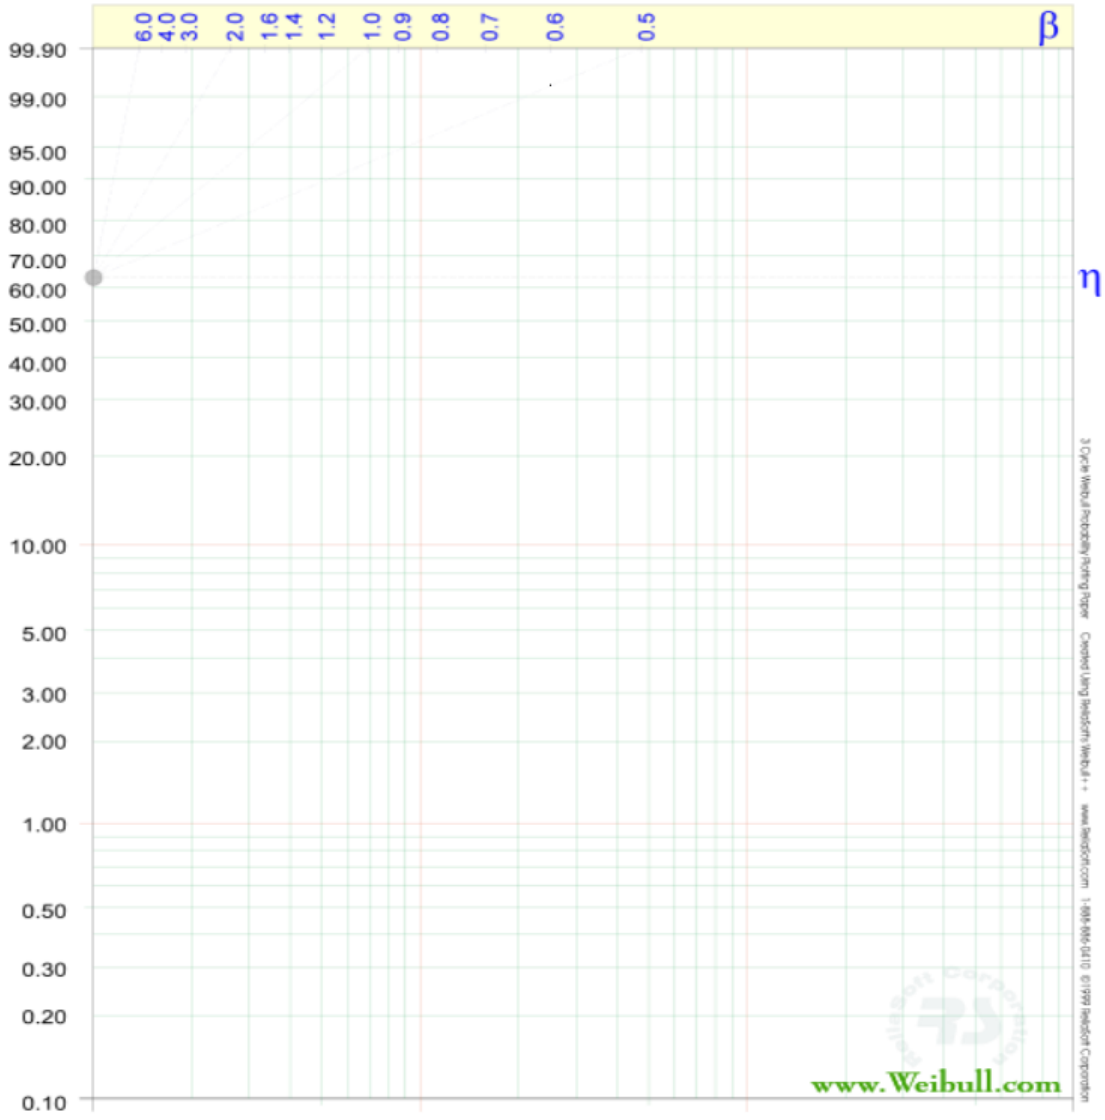


Gráfico ajustado para a distribuição Weibull:



Outra forma é utilizar de ferramentas computacionais para:

- Podemos construir os gráficos de probabilidade;
- Estimar os parâmetros que resultam no melhor ajuste.
  - Matlab
  - **R**
  - **Python**
  - Minitab
  - Reliasoft Weibull++

Atenção: Apesar da distribuição Weibull ser a mais popular para análise de dados de sobrevivência, existem situações em que outras distribuições como lognormal, distribuição de valores extremos e a exponencial se ajustam muito bem ou acabam sendo uma escolha mais adequada.

A escolha da distribuição mais adequada deve se basear em:

1. Medidas de qualidade de ajuste das distribuições;
2. Conhecimento prévio sobre o problema;
3. Julgamento do engenheiro de confiabilidade.

A análise de sobrevivência possui quatro etapas fundamentais:

1. **Coleta de Dados**: Obter os tempos de vida (até falha) do sistema;
2. **Análise e Modelagem**: Determinar qual o melhor modelo para os dados (ajuste da distribuição de probabilidade);
3. **Resultados**: Estimar tempo de vida médio, taxa de falha, ou qualquer outra estatística de interesse.
4. **Conclusões**:
   - Substituição do item?
   - Alterações do plano de manutenção? Por exemplo, adotar estratégias preventivas, preditivas ou prescritivas.
   - Buscar novos fornecedores?

Tipos de Dados de Sobrevivência

Em confiabilidade, assim como outros estudos de tempo até um evento, a sobrevivência de um dado sistema pode estar associada a diferentes variáveis:

- Tempo;
- Distância percorrida;
- Número de ligamentos ou desligamentos;
- Ciclos de operação;
- ...

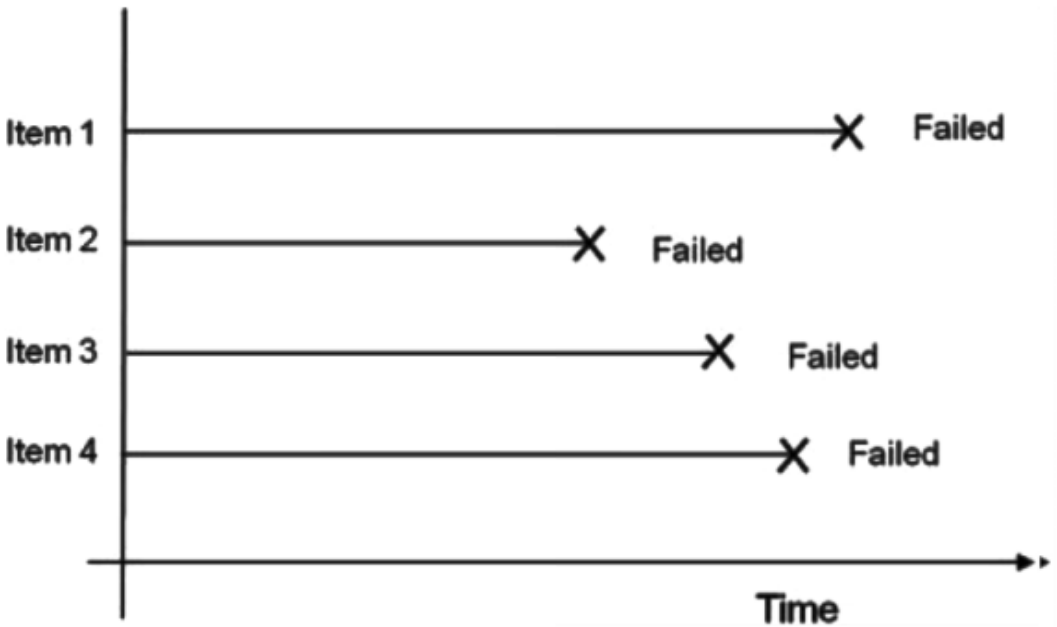
A assertividade e a credibilidade de qualquer estimativa é fortemente dependente da qualidade, precisão e completude dos dados utilizados.

Classificação de dados de tempos até falha (ou tempo até qualquer outro evento):

1. Dados completos;
2. Dados censurados à direita;
3. Dados censurados em intervalo;
4. Dados censurados à esquerda.

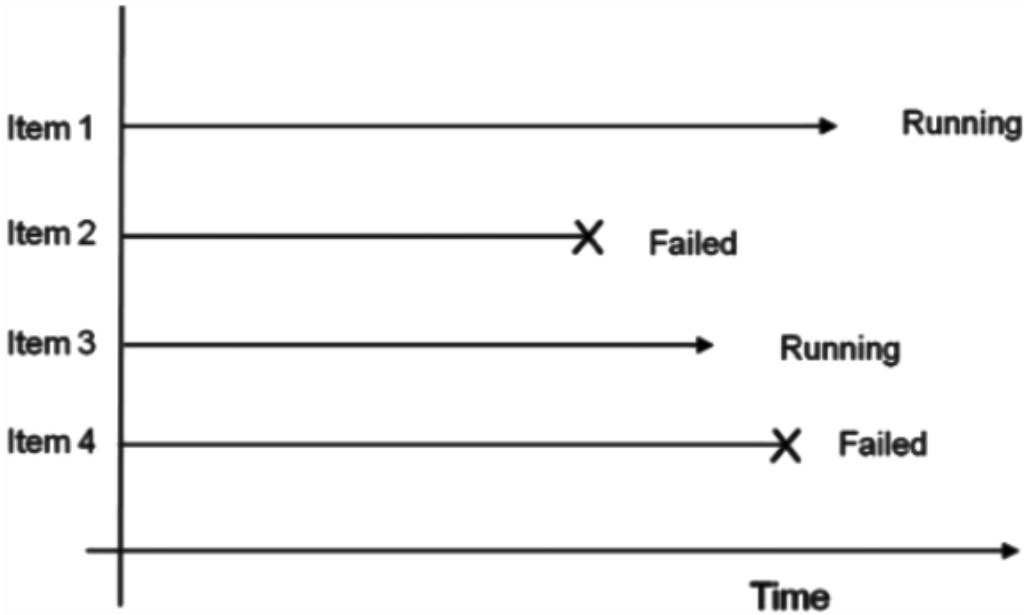
1. Dados completos

- Todas as observações da variável de interesse são conhecidas de forma exata.
- No caso específico de confiabilidade, os dados são completos quando todos os tempos até falha em uma amostra foram observados.



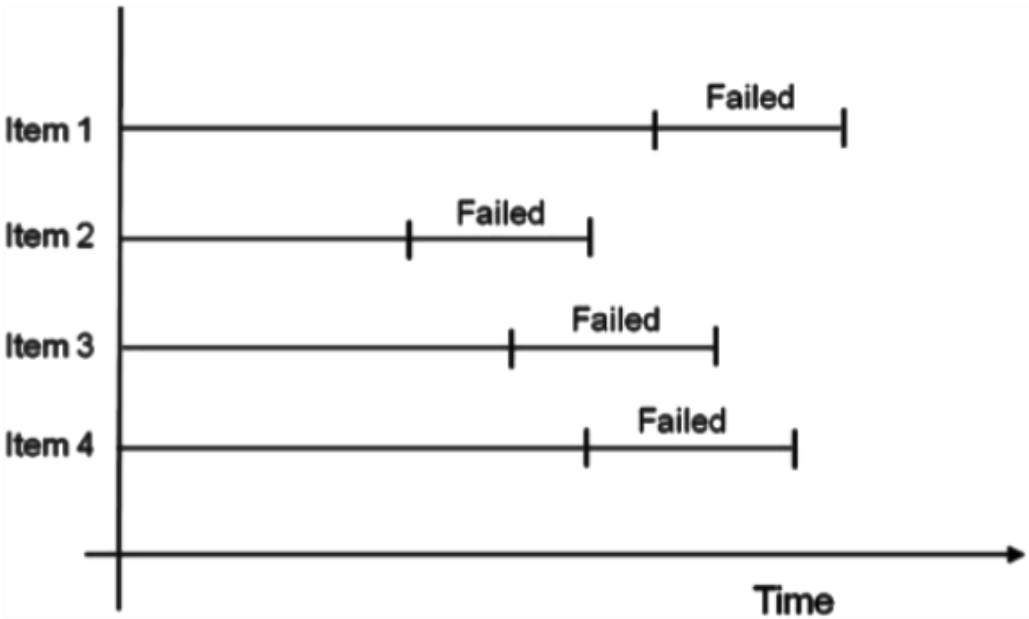
2. Dados censurados à direita

- Tipo mais comum de dados censurados;
- Ocorre quando não observamos o evento de interesse para uma ou mais observação, ou seja, significa que o evento de interesse está à direita do valor observado. Exemplo: Não ocorreu falha até o final do teste.



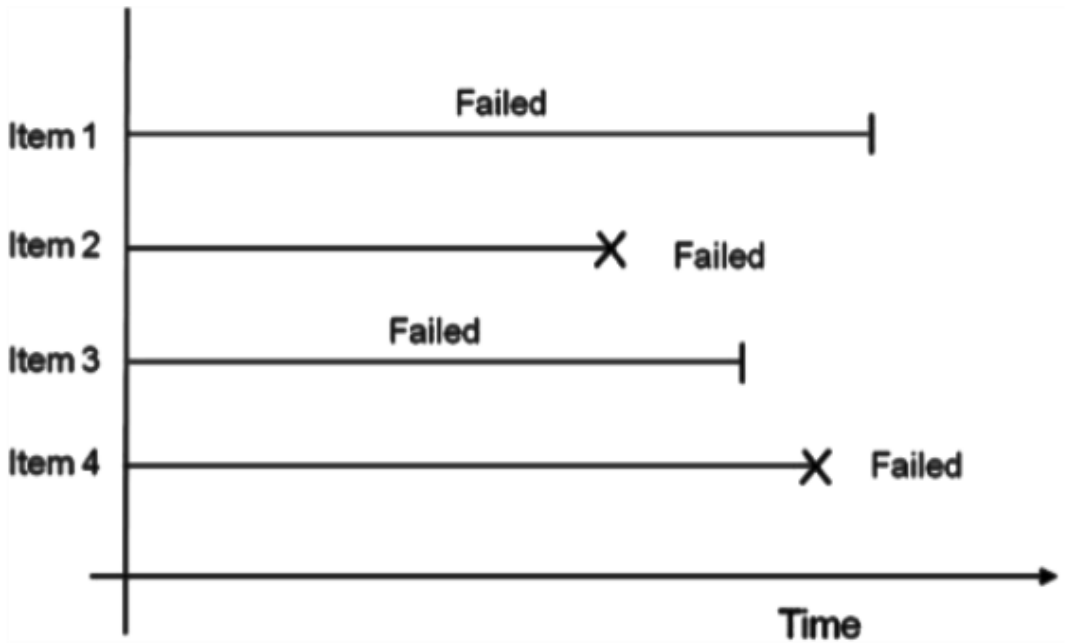
3. Dados censurados em intervalo

- Refletem a incerteza com relação ao instante de ocorrência do evento.
- Ocorre em situações onde a ocorrência do evento não é monitorada constantemente mas sim de forma periódica. Por exemplo, funcionamento monitorado de hora em hora.



4. Dados censurados à esquerda

- Sabe-se apenas que a falha ocorreu antes de um determinado tempo (ou a esquerda do ponto de observação).
- Este tipo de dado é equivalente ao dado censurado em intervalo se for considerado que o intervalo de censura começa em 0.



Algumas considerações sobre dados censurados:

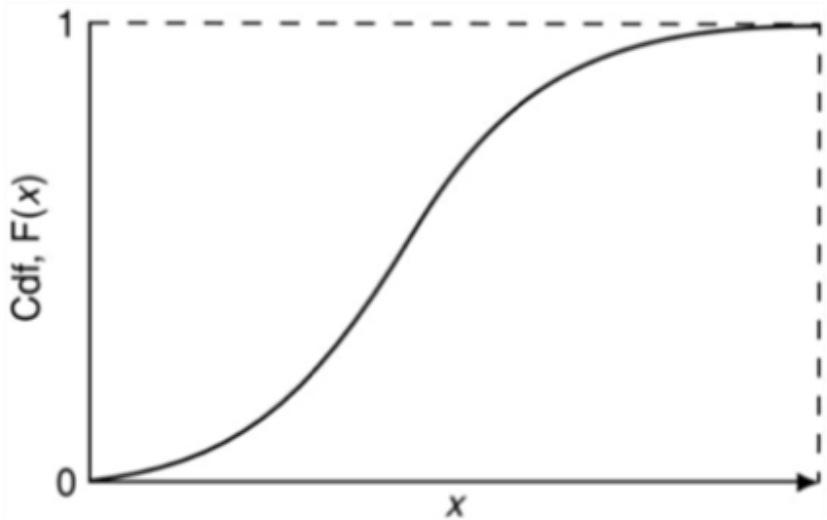
- Dados censurados possuem um maior nível de incerteza;
- Dados completos são mais facilmente tratados que dados censurados, visto que envolvem um menor nível de incerteza;
- Dados completos e dados censurados à direita geralmente podem ser avaliados utilizando métodos gráficos;
- Já dados censurados à esquerda e dados censurados em intervalo demandam abordagens mais sofisticadas, sendo geralmente tratados por **software**.

Ajuste por Ranqueamento

A estimativa das curvas de probabilidade é feita com base na relação entre a variável de interesse (tempo, distância, ciclos) e a probabilidade de falha acumulada (CDF).

Dessa forma, se faz necessário ordenar os dados e calcular a probabilidade cumulativa de cada ponto $\hat{F}(x)$ para posterior ajuste da $F(x)$.

$$P(X \leq x) = F(x) = \int_{-\infty}^{x} f(x)dx$$



O ranqueamento de dados fornece uma estimativa de qual proporção da população é representada por uma determinada amostra.

O ranqueamento de dados constitui uma alternativa ao uso de histogramas, tendo em vista que, em engenharia, geralmente se lida com amostras pequenas.

Ajuste por Ranqueamento: Ranqueamento Ingênuo (Naive ranking)

Considere um teste de cinco itens onde observou-se os seguintes tempos de falha $\mathbf{t} = \{200, 100, 500, 400, 300\}$.

O Ranqueamento Ingênuo é calculado como $r_n(i) = i/N$, onde i é o índice do valor no vetor ordenado ($\mathbf{t} = \{100, 200, 300, 400, 500\}$) e N é o tamanho da amostra aleatória.

Podemos estimar os seguintes ranques: $r_n(1) = 20\%$, $r_n(2) = 40\%$, $r_n(3) = 60\%$, $r_n(4) = 80\%$ e $r_n(5) = 100\%$.

- Este resultado implica que 20% da população falha até $t_1 = 100$ h e 100% da população falha em até $t_5 = 500$ h, o que provavelmente não é realista.

Ajuste por Ranqueamento: Ranqueamento Médio

O cálculo do ranqueamento médio é feito utilizando $N + 1$ no denominador.

Considerando a mesma amostra aleatória de tempos de falha
$\mathbf{t} = \{100, 200, 300, 400, 500\}$.

Ranqueamento Médio:

$$r_{avg}(i) = \frac{i}{N+1}$$

$$r_{avg}(1) = 1/6 = 0.167$$
$$r_{avg}(2) = 2/6 = 0.333$$
$$r_{avg}(3) = 3/6 = 0.500$$
$$r_{avg}(4) = 4/6 = 0.667$$
$$r_{avg}(5) = 5/6 = 0.833$$

Ajuste por Ranqueamento: Ranqueamento Mediano

O ranqueamento **mediano** é o método mais utilizado para esboçar gráficos de probabilidade.

- Este método é particularmente útil se a distribuição dos dados não é normal.
- O ranqueamento mediano pode ser definido como a proporção acumulada da população que é inferior a uma dada amostra, com 50% de confiança.
- O cálculo do ranqueamento mediano pode ser feito de diferentes formas.

Pode-se utilizar a Distribuição Binomial para calcular o ranqueamento mediano ($P = 0.50$):

$$P = \sum_{k=i}^{N} \frac{N!}{k!(N-k)!} Z^k (1-Z)^{N-k}$$

Nesse caso, resolve-se a equação da Binomial para encontrar o valor de Z para cada i-ésima falha na amostra aleatória ordenada.

O Ranqueamento mediano será o valor de Z, i.e., $r_{med}(i) = Z(i)$.

O ranqueamento mediano pode ser encontrado utilizando tabelas ou softwares específicos.

Existe também uma aproximação algébrica, conhecida como Aproximação de Bernard, para obter um **ranqueamento mediano aproximado**:

$$r_{med}(i) = \frac{i - 0.3}{N + 0.4}$$

Onde i é a posição da i-ésima falha observada após a ordenação dos tempos.

No nosso exemplo ilustrativo:

$$N = 5 \text{ e } t = [100, 200, 300, 400, 500]$$

	Observações				
Ranqueamentos	$i = 1$	$i = 2$	$i = 3$	$i = 4$	$i = 5$
$r_n(i)$	0.2000	0.400	0.600	0.800	1.000
$r_{avg}(i)$	0.1667	0.3333	0.5000	0.6667	0.8333
$r_{med}(i)$	0.1294	0.3147	0.5000	0.6853	0.8706
$r_{med}(i)$ (Aprox.)	0.1296	0.3148	0.5000	0.6852	0.8704

Ajuste por Ranqueamento: Ranqueamento de Dados Censurados

Ranqueamento de dados censurados.

O ranqueamento de dados censurados é mais complexo tendo em vista a incerteza relacionada a estes dados.

O caso mais simples é para dados censurados à direita:

- Os itens censurados (sem falha observada) não são considerados como observações para o gráfico de probabilidade;
- Mas a censura afeta o ranqueamento dos outros pontos;
- Portanto, se faz necessário atualizar o ranqueamento dos pontos com falhas observadas considerando a incerteza dos dados censurados.

Começamos ordenando os n itens que falharam ou foram censurados por ordem crescente de tempo de vida (t_i);

Para cada t_i observado (não censurado), determine:

1. O número ajustado de itens que falharam entre o instante atual de falha e o instante de falha anterior $i_{t_{i-1}}$;
2. O número de itens que falharam ou foram censurados anteriormente ($nfca$) e calcule N_{t_i}:
$$N_{t_i} = \frac{N + 1 - i_{t_{i-1}}}{N + 1 - nfca}$$
3. Para cada falha, calcule i_{t_i}: $i_{t_i} = i_{t_{i-1}} + N_{t_i}$

Com todos os i_{t_i} calculados, podemos calcular o ranqueamento mediano para cada i-ésimo item que falhou utilizando o ranqueamento mediano aproximado:

$$r_{med}(i) = \frac{i_{t_i} - 0.3}{N + 0.4}$$

Ilustrando: Vamos considerar os mesmos 5 itens, porém com os itens 2 e 4 censurados (não foram observadas as falhas e estes foram removidos do teste respectivamente com 200 e 400 horas):

$$N = 5 \text{ e } \mathbf{t} = \{100, 200^*, 300, 400^*, 500\}$$

Vamos calcular o ranqueamento ajustado para esta amostra aleatória com dados censurados.

$$N_{t_i} = \frac{N + 1 - i_{t_{i-1}}}{N + 1 - nfca} \qquad i_{t_i} = i_{t_{i-1}} + N_{t_i} \qquad r_{med}(i) = \frac{i_{t_i} - 0.3}{N + 0.4}$$

$$N = 5 \text{ e } t = [100, 200^*, 300, 400^*, 500]$$

A primeira observação não censurada é $t_1 = 100$:

$$N_{100} = \frac{5 + 1 - 0}{5 + 1 - 0} = 1.0$$
$$i_{100} = i_0 + N_{100} = 0 + 1.0$$
$$i_{100} = 0 + 1.0 = 1.0$$
$$r_{med}(i_{100}) = \frac{1 - 0.3}{5 + 0.4} = 0.1296$$

$$N_{t_i} = \frac{N+1-i_{t_{i-1}}}{N+1-nfca} \qquad i_{t_i} = i_{t_{i-1}} + N_{t_i} \qquad r_{med}(i) = \frac{i_{t_i}-0.3}{N+0.4}$$

Vamos fazer para as duas próximas observações não censuradas $t_3 = 300$ e $t_5 = 500$:

$$N_{300} = \frac{5+1-1}{5+1-2} = 1.25$$

$$i_{300} = i_{100} + N_{300}$$

$$i_{300} = 1.0 + 1.25 = 2.25$$

$$r_{med}(i_{300}) = \frac{2.25-0.3}{5+0.4} = 0.361$$

$$N_{500} = \frac{5+1-2.25}{5+1-4} = 1.875$$

$$i_{500} = i_{300} + N_{500}$$

$$i_{500} = 2.25 + 1.875 = 4.125$$

$$r_{med}(i_{500}) = \frac{4.125-0.3}{5+0.4} = 0.708$$

Comparação entre o ranqueamento considerando a censura e sem considerar:

i	t_i	Cens.	N_{t_i}	i_{t_i}	$r_{med}(i_{t_i})$	$r_{med}(i)$ sem os tempos cens.
1	100	Não	1.0	1.0	12.96%	20.59%
2	200	Sim	-	-	-	-
3	300	Não	1.25	2.25	36.11%	50%
4	400	Sim	-	-	-	-
5	500	Não	1.875	4.125	70.83%	79.41%

Ajuste por Ranqueamento: Exemplificando com a Weibull

Vamos ilustrar como utilizar os ranques estimados para estimar os parâmetros de uma distribuição Weibull.

Relembrando:

$$F(t) = 1 - \exp\left[-(t/\eta)^{\beta}\right]$$

Onde t é o tempo, β é o parâmetro de forma (*shape* ou *slope*) e η é o parâmetro de escala.

O η também é chamado de **tempo de vida característico**, pois ele indica o instante em que 63.2 % dos itens estarão em falha.

Vamos transformar $F(t)$ em uma expressão de uma reta: $y = ax + b$:

$$F(t) = 1 - \exp\left[-(t/\eta)^{\beta}\right]$$

$$1 - F(t) = \exp\left[-(t/\eta)^{\beta}\right]$$

$$\frac{1}{1 - F(t)} = \exp\left[(t/\eta)^{\beta}\right]$$

$$\ln\left(\frac{1}{1 - F(t)}\right) = (t/\eta)^{\beta}$$

$$\ln\ln\left(\frac{1}{1 - F(t)}\right) = \ln\left[(t/\eta)^{\beta}\right]$$

$$\underbrace{\ln\ln\left(\frac{1}{1 - F(t)}\right)}_{y} = \underbrace{\beta \ln t}_{ax} + \underbrace{(-\beta \ln \eta)}_{b}$$

No gráfico de probabilidade:

$$F(t) = 1 - \exp\left[-(t/\eta)^{\beta}\right]$$

$$\ln\ln\left(\frac{1}{1-F(t)}\right) = \beta \ln t - \beta \ln \eta$$

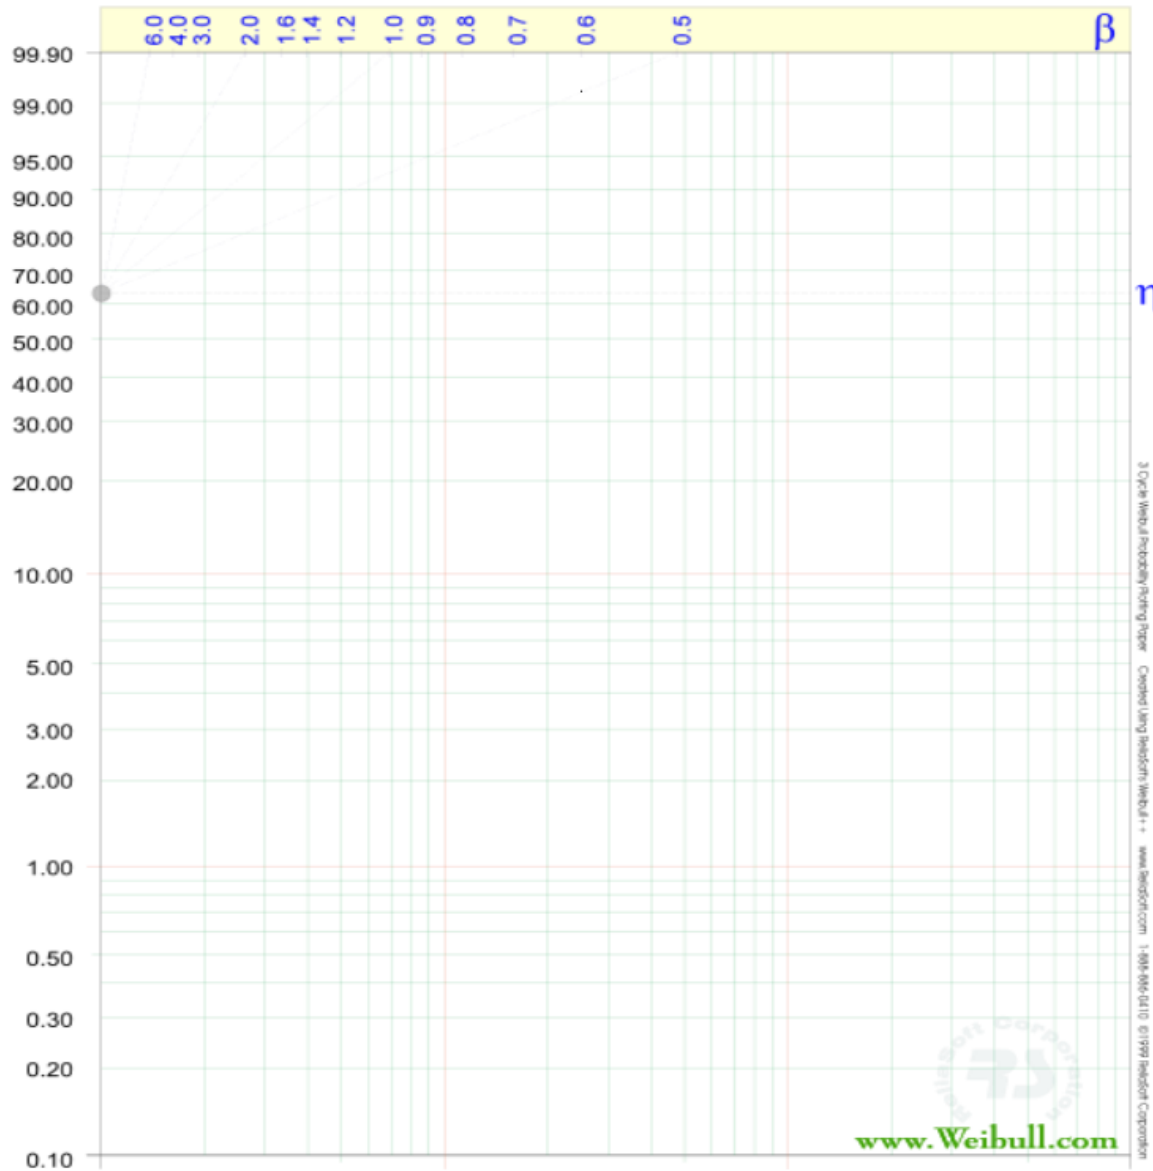
$$y = ax + b$$

$$y = \ln\ln\left(\frac{1}{1-F(t)}\right)$$

$$a = \beta,\ x = \ln t \text{ e } b = -\beta \ln \eta$$

$$F(\eta) = 1 - \exp\left[-(\eta/\eta)^{\beta}\right]$$

$$F(\eta) = 1 - \exp(-1) = 0.632$$



Vamos estimar os parâmetros da Weibull para o exemplo de cinco unidades que falharam em 100, 200, 300, 400 e 500 horas.

Primeiro calculamos o ranqueamento mediano:

$$r_{med}(i) = \frac{i - 0.3}{N + 0.4}$$

- 100 horas: 12.94%;
- 200 horas: 31.47%;
- 300 horas: 50.00%;
- 400 horas: 68.53%;
- 500 horas: 87.06%.

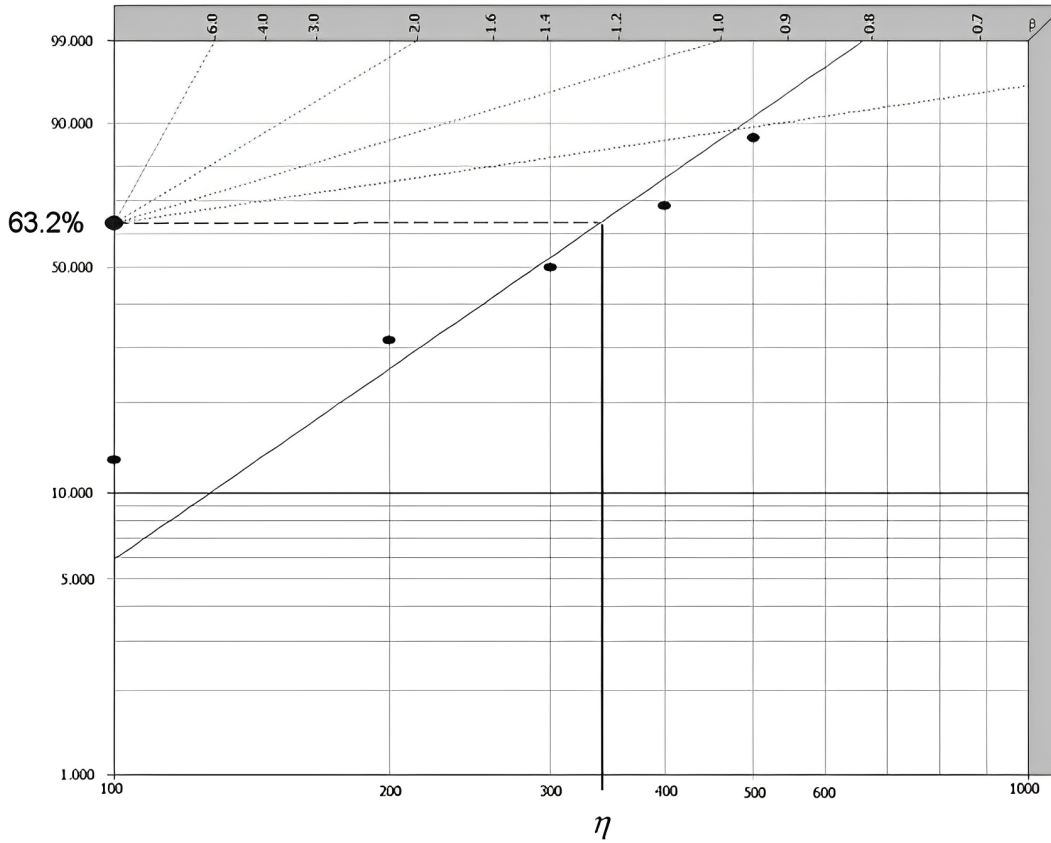
Marcar os pontos no gráfico Weibull e estimar os parâmetros:

- 100 horas: 12.94%;
- 200 horas: 31.47%;
- 300 horas: 50.00%;
- 400 horas: 68.53%;
- 500 horas: 87.06%.

$$y = ax + b$$

$$a = \beta$$

$$F(\eta) = 1 - \exp\left[-(\eta/\eta)^{\beta}\right] = 0.632$$



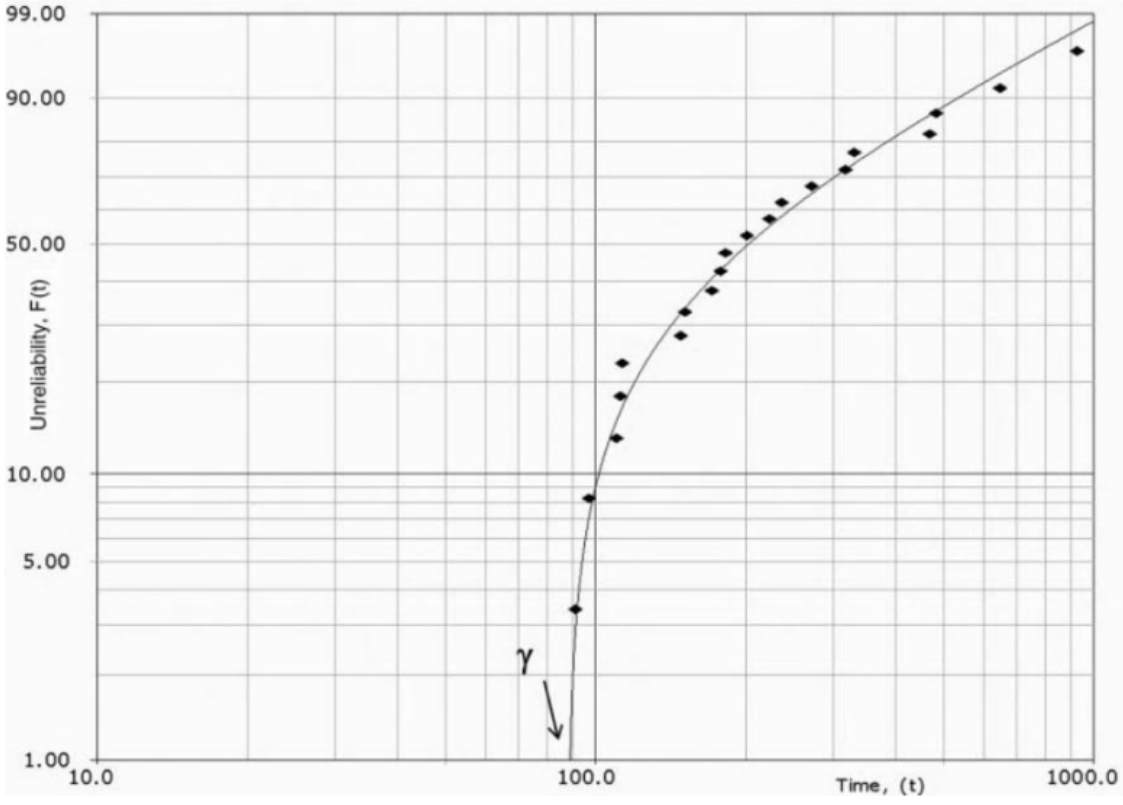
Weibull de Três Parâmetros:

$$F(t) = 1 - \exp\left[-\left(\frac{t-\gamma}{\eta}\right)^{\beta}\right]$$

Onde:

- t é o tempo;
- β é o parâmetro de forma, associado ao comportamento da função de risco;
- η é o parâmetro de escala, ou tempo de vida característico que é o instante em que 63.2% dos itens estão em falha;
- O parâmetro γ é um parâmetro de localização, conhecido como **tempo mínimo de vida esperado**.

Recomendada apenas se for possível afirmar, com muita segurança, que o sistema ou produto possui uma **vida mínima garantida** γ.



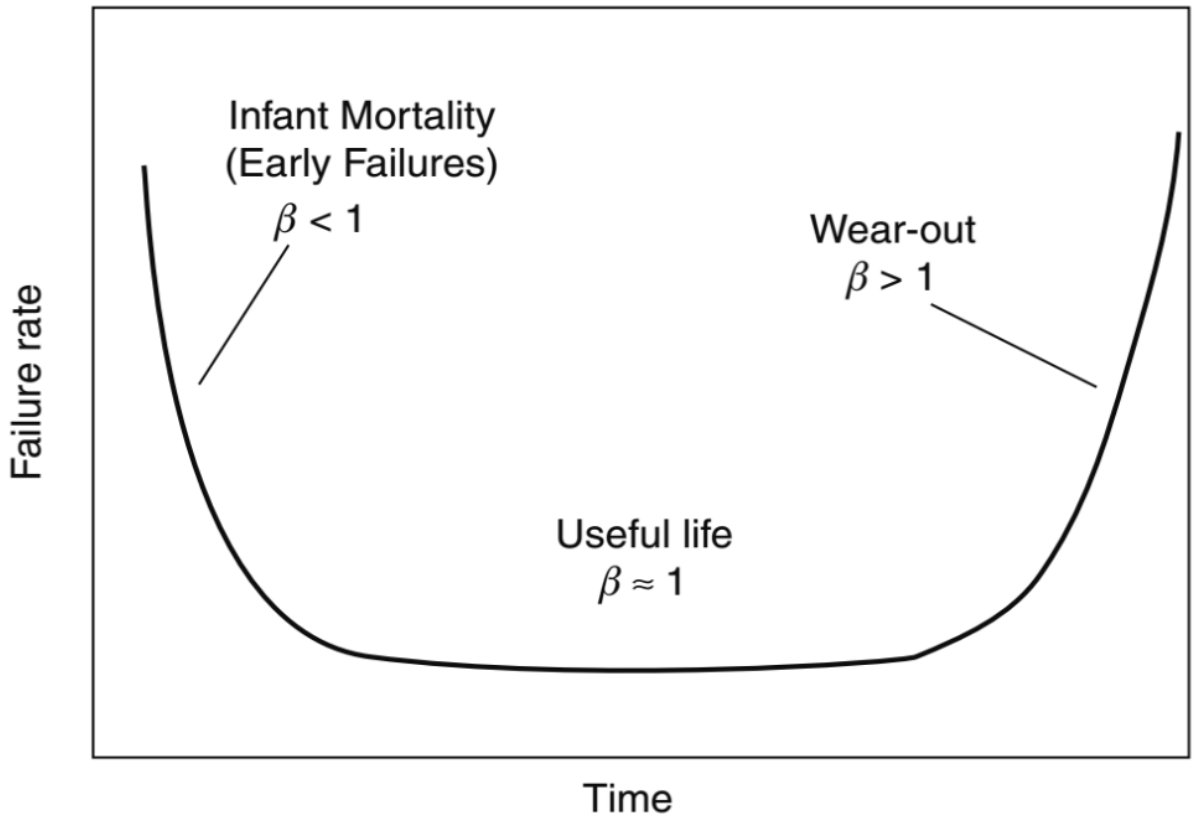
Situações onde ocorreram extensa inspeção previamente ao uso ou comercialização do sistema.

O β reflete o comportamento da taxa de falha, ou função de risco $h(t)$, esperada:

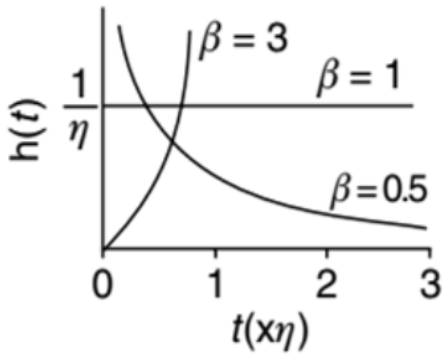
$$h(t) = \frac{f(t)}{R(t)} = \frac{f(t)}{1 - F(t)} \qquad h(t) = \frac{\beta}{\eta^{\beta}} t^{\beta - 1}$$

Uma vez estimado o β da Weibull, podemos inferir sobre o comportamento de falhas de uma população, em especial o estágio do ciclo de vida, através do valor ajustado $\hat{\beta}$.

Curva da Banheira



Weibull



$$h(t) = \frac{\beta(t-\gamma)^{\beta-1}}{\eta^{\beta}}$$

Ajuste por Métodos Computacionais

Os métodos computacionais utilizam os mesmos princípios discutidos anteriormente.

Queremos ajustar, de forma ótima, os parâmetros de uma distribuição de probabilidade (nosso modelo) para termos o melhor valor possível de alguma função de qualidade de ajuste.

Por exemplo:

- Minimizar o erro ao se representar as observações em um gráfico de probabilidade (**Mínimos Quadrados**);
- Maximizar a probabilidade de observar os dados com um conjunto de parâmetros (**Máxima Verossimilhança**).

Ajuste por Métodos Computacionais: Estimação por Mínimos Quadrados

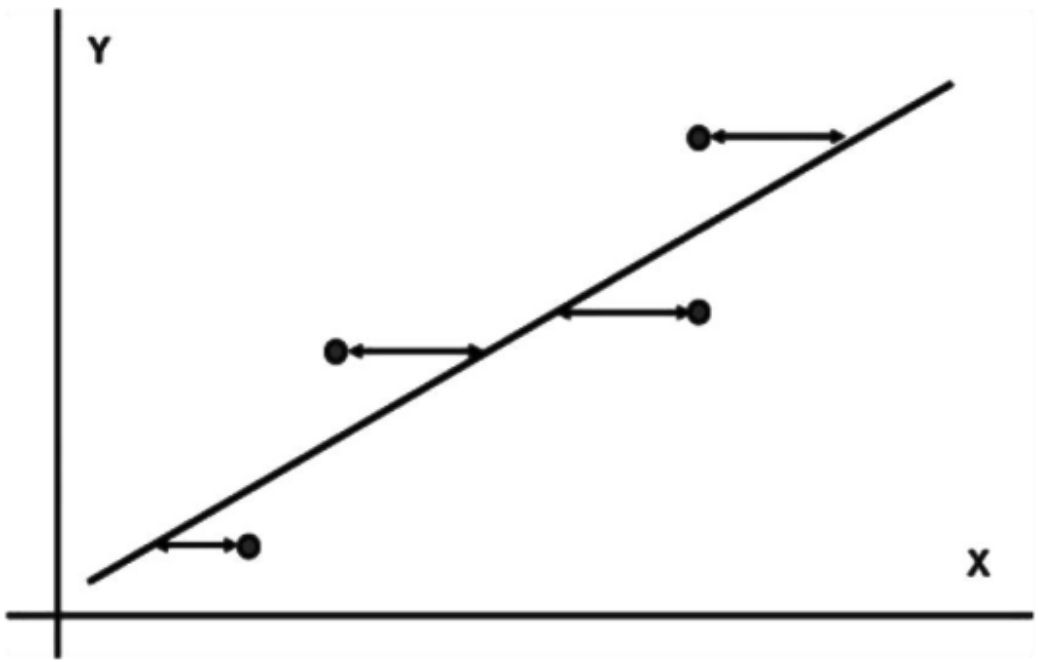
Regressão por Ranqueamento e Estimação por Mínimos Quadrados.

Quando fazemos a regressão por ranqueamento dos tempos, podemos ajustar diferentes retas que irão representar distribuições com diferentes parâmetros.

A forma mais aceita para ajustar tal reta é escolher os parâmetros que minimizam a soma dos quadrados dos desvios (erro quadrático) verticais ou horizontais.

- Princípio dos Mínimos Quadrados.

Considerando os pares de observações $(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$ obtidos e representados no gráfico, o princípio dos mínimos quadrados é ajustar uma reta que minimize a distância entre a reta e os pontos.



Regressão por Ranqueamento e Estimação por Mínimos Quadrados.

Ajustar uma reta:$x = \hat{a} + \hat{b}y$

Métrica de ajuste: $L = \sum_{i=1}^{n} \epsilon^2 = \sum_{i=1}^{n} \left(x_i - \hat{a} + \hat{b}y_i \right)^2$

Ajuste dos parâmetros a e b : $\frac{dL}{da} = 0$ e $\frac{dL}{db} = 0$

O que resulta em: $\hat{b} = \frac{\sum_{i=1}^{n} x_i y_i - \frac{\sum_{i=1}^{n} x_i \sum_{i=1}^{n} y_i}{n}}{\sum_{i=1}^{n} y_i^2 - \frac{\left(\sum_{i=1}^{n} y_i\right)^2}{n}}$

$$\hat{a} = \frac{\sum_{i=1}^{n} x_i}{n} - \hat{b}\frac{\sum_{i=1}^{n} y_i}{n} = \overline{x} - \hat{b}\overline{y}$$

Ajuste por Métodos Computacionais: Estimação por Máxima Verossimilhança

A ideia deste método é encontrar os **parâmetros** que **maximizam** a verossimilhança (**probabilidade conjunta**) dos **dados** amostrados se ajustarem à uma dada **distribuição** (modelo para $f(x)$).

- Aplicável se existir a função de verossimilhança, além de ser, em geral, mais robusto que o ajuste por ranqueamento.

A Estimação por Máxima Verossimilhança (*Maximum Likelihood Estimation*, MLE) está implementada em vários pacotes computacionais para ajuste de distribuições.

Dada uma amostra aleatória $\mathbf{x} = [x_1, x_2, \ldots, x_n]$, resultado da observação da v.a. X contínua com uma PDF com k parâmetros θ_j:

$$f(x; \theta_1, \ldots, \theta_k)$$

A função de verossimilhança é dada por:

$$L(\mathbf{x}; \theta_1, \ldots, \theta_k) = f(x_1, x_2, \ldots, x_n; \theta_1, \ldots, \theta_k)$$

$$L(\mathbf{x}; \theta_1, \ldots, \theta_k) = \prod_{i=1}^{n} f(x_i; \theta_1, \ldots, \theta_k)$$

ou o log da função verossimilhança:

$$\Lambda = \ln(L) = \sum_{i=1}^{n} \ln[f(x_i; \theta_1, \ldots, \theta_k)]$$

Pode-se estimar os valores de $\theta_1, \theta_2, \ldots, \theta_k$ por meio da maximização de L ou Λ.

A maximização de Λ é consideravelmente mais simples que a de L, e pode ser obtida por meio da solução simultânea de k equações:

$$\frac{d\Lambda}{d\theta_j} = 0, \quad j = 1, 2, \ldots, k$$

Exemplo: Dada uma amostra aleatória $\mathbf{t} = \{t_1, t_2, \ldots, t_n\}$ que bem de uma v.a. T que segue uma distribuição exponencial.

Vamos estimar o λ da exponencial pelo método da MLE:

$$f(t) = \lambda \exp(-\lambda t)$$

$$L(\lambda) = \prod_{i=1}^{n} f(t_i; \lambda) = \prod_{i=1}^{n} \lambda \exp(-\lambda t_i) = \lambda^n \exp\left(-\lambda \sum_{i=1}^{n} t_i\right)$$

$$\Lambda(\lambda) = \ln[L(\lambda)] = n \ln(\lambda) - \lambda \sum_{i=1}^{n} t_i$$

$$\frac{d\Lambda}{d\lambda} = \frac{n}{\lambda} - \sum_{i=1}^{n} t_i = 0$$

$$\hat{\lambda} = \frac{n}{\sum_{i=1}^{n} t_i} = \frac{1}{\bar{t}}$$

Regressão por Ranqueamento ou Estimação por Máxima Verossimilhança?

Cada um dos dois métodos resultará em estimativas diferentes para os parâmetros.

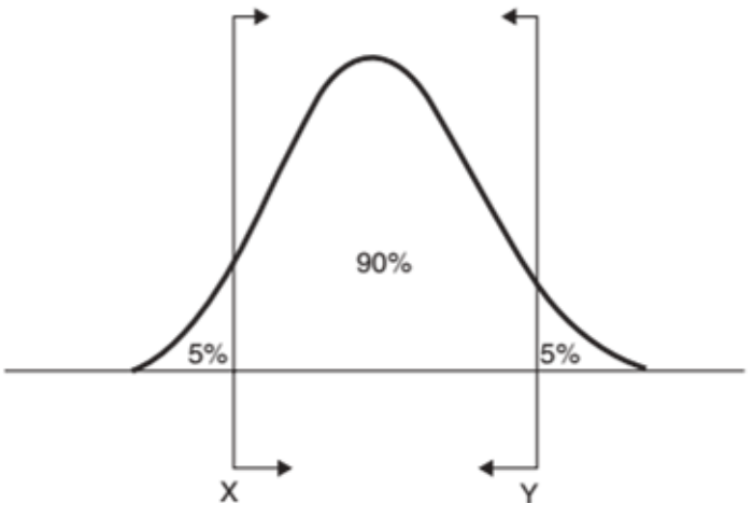
- A Regressão por Ranqueamento é recomendada para conjuntos de dados pequenos ($n < 30$) de dados completos.
- A Estimação por Máxima Verossimilhança é recomendada quando se possui muitos dados ou caso exista uma proporção razoável de dados censurados.

Intervalos de Confiança

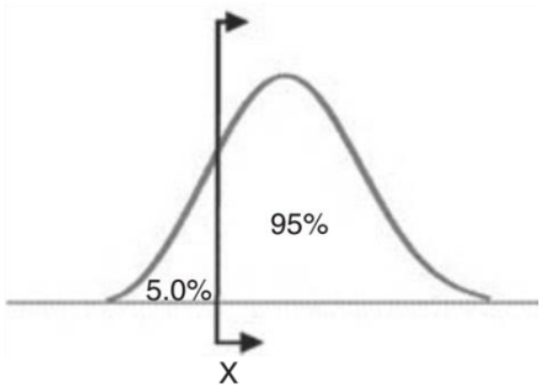
Como os resultados de análises de dados de sobrevivência utilizam observações de tempo até um evento, existe uma incerteza inerente devido ao tamanho limitado das amostras.

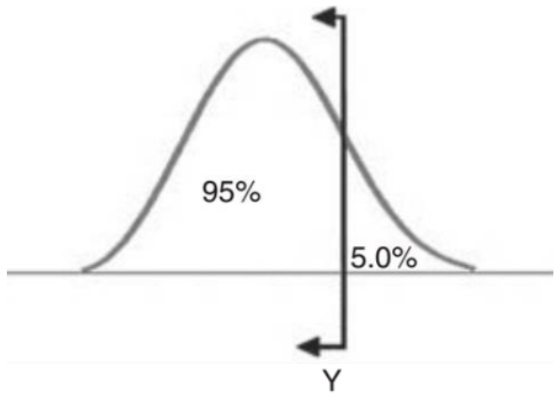
Uma forma de quantificar essa incerteza é utilizando os intervalos de confiança.

Quando se utiliza um intervalo de confiança bilateral $[X, Y]$, se busca por um intervalo fechado em que podemos observar futuras estimativas do processo.



Quando se utiliza um intervalo de confiança unilateral, se busca um limite superior ou inferior para a maior parte dos resultados observados em futuras estimativas do processo.





As diferenças entre os tipos de intervalos de confiança merecem atenção:

- Um intervalo unilateral com limite inferior pode ser utilizado para representar a confiabilidade mínima esperada ($R(t) > L$).
- Um intervalo unilateral com limite superior pode ser utilizado para representar a % máxima de falhas esperadas durante o período de garantia t de um produto ($F(t) < U$).
- Um intervalo bilateral pode ser utilizado para representar a faixa esperada de valores de um parâmetro de uma distribuição, e.g., ($L < \hat{\beta} < U$).

Intervalos de Confiança: Para o Ranqueamento

Quando realizamos a regressão por ranqueamento mediano, o $r_{med}(i)$ é obtido através da resolução da equação abaixo para encontrar o Z, o qual será o valor do $r_{med}(i)$, utilizado um nível de confiança de 50% referente à mediana:

$$0.50 = \sum_{k=i}^{N} \frac{N!}{k!(N-k)!} Z^k (1-Z)^{N-k}$$

Pode-se também calcular utilizando outros níveis, por exemplo, como 5% e 95%, os quais resultarão nas estimativas de Z que serão os limites $r_{5\%}$ e $r_{95\%}$ do intervalo de confiança de 90%.

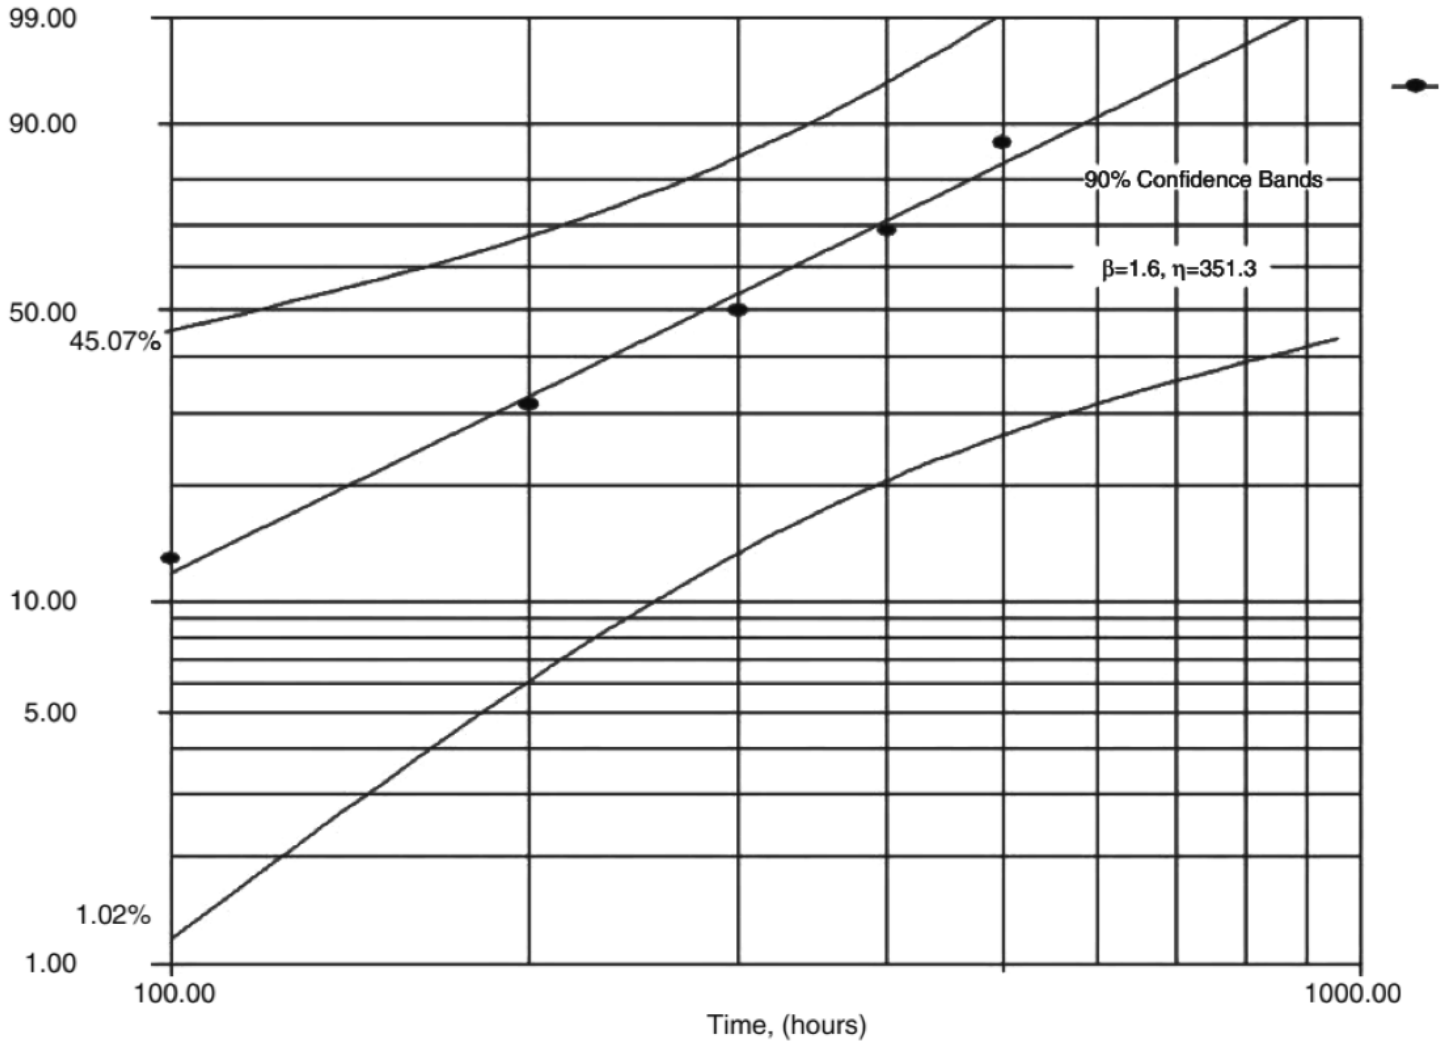
$$0.05 = \sum_{k=i}^{N} \frac{N!}{k!(N-k)!} Z^k (1-Z)^{N-k}$$

$$0.95 = \sum_{k=i}^{N} \frac{N!}{k!(N-k)!} Z^k (1-Z)^{N-k}$$

Para o nosso exemplo de 5 itens que falharam com 100 h, 200 h, 300 h, 400 h e 500 h:

i	1	2	3	4	5
$r_{5\%}(i)$ 5%	0.0102	0.0764	0.1892	0.3425	0.5492
$r_{med}(i)$ 50%	0.1294	0.3138	0.5000	0.6862	0.8706
$r_{95\%}(i)$ 95%	0.4507	0.6574	0.8107	0.9236	0.9898

Representando esse intervalo para um ajuste com a distribuição Weibull:



Intervalos de Confiança: Para os Parâmetros das Distribuições

É importante encontrar o intervalo de confiança das estimativas dos parâmetros da distribuição, uma vez que decisões podem ser tomadas com base nesses valores.

Por exemplo, o valor de $\hat{\beta}$ em uma distribuição Weibull indica o comportamento da função de risco, ou em que estágio do ciclo de vida o sistema se encontra.

Os pacotes computacionais geralmente estimam estes intervalos juntamente com a tendência central do parâmetro.

Uma outra possibilidade é estimar estes intervalos de forma numérica.

A ideia central é:

1. Gerar várias amostras sintéticas seguindo uma distribuição com parâmetros ajustados;
2. A partir dessas amostras estimar o intervalo de confiança da estimação desses parâmetros.

Esta abordagem numérica pode ser utilizada para calcular limites razoáveis dos IC para as estimativas dos parâmetros da distribuição de interesse.

Escolha de uma Distribuição

Considerações de Engenharia:

- Maturidade do sistema ou equipamento: Afeta a taxa de falha;
- Modos de falha e física da falha:
  - Entender os modos de falha (causas) está diretamente ligado a ações da engenharia;
  - A física da falha pode fornecer resultados úteis;
  - Utilizar dados de consumo de peças para reparo;
  - Analisar cada modo de falha em separado.

Sempre confrontar resultados estatísticos com o conhecimento específico sobre o sistema analisado (explicações plausíveis).

Soluções estatísticas:

- Métodos Gráficos:
  - Utilizar um Gráfico de Probabilidade (Q-Q Plot) para verificar a adequação do modelo;
  - Verificar se ocorre a representação por uma reta no espaço linearizado.

Soluções estatísticas:

- Teste da Razão da Verossimilhança:

$$RVS = -2 \log \left[\frac{L(\hat{\theta}_A)}{L(\hat{\theta}_B)} \right]$$

  - Essa razão é distribuída de acordo com uma χ^2 com graus de liberdade igual a diferença entre o número de parâmetros dos modelos A e B;
  - Testa-se a seguinte H_0: Modelo A (mais reduzido) é suficiente; H_1: Modelo B melhora o ajuste.
- Comparação das métricas AIC/BIC;

Exemplo

Sabe-se que os parâmetros de uma Weibull são $\beta = 1.86$ e $\eta = 21620$ h.

Para uma população de 1600 unidades determine:
a) Quantas falhas podem ser esperadas quando as 1600 unidades funcionarem por 1500 horas?
b) E para 3000 horas?

$$R(t) = \exp\left[-\left(\frac{t}{\eta}\right)^{\beta}\right]$$

Exemplo

Sabe-se que os parâmetros de uma Weibull são $\beta = 1.86$ e $\eta = 21620$ h.

Para uma população de 1600 unidades determine:
a) Quantas falhas podem ser esperadas quando as 1600 unidades funcionarem por 1500 horas?

$$R(1500) = \exp\left[-(1500/21620)^{1.86}\right] = 0.993$$
$$n(1500) = (1 - R(1500)) \times 1600 = 0.007 \times 1600 = 11.2 = 11 \text{ unidades}$$

b) E para 3000 horas?

$$R(3000) = \exp\left[-(3000/21620)^{1.86}\right] = 0.975$$
$$n(3000) = (1 - R(3000)) \times 1600 = 0.025 \times 1600 = 40 \text{ unidades}$$

Referências

Referências bibliográficas


P. D. T. O'Connor; A. Kleyner, *Practical Reliability Engineering*, 5a Ed., Wiley, 2012;


E. Colosimo, *Análise de sobrevivência aplicada*, Blucher, 2006;


D. C. Montgomery & G. C. Runger, *Applied statistics and probability for engineers*, 6th ed., Willey, 2013;


U. Genschel & W. Q. Meeker, *A comparison of maximum likelihood and median-rank regression for Weibull estimation*, Quality Engineering, 22.4 (2010): 236-255.