EEE 017 Confiabilidade de Sistemas

5 - Análise de Valores Extremos

Michel Bessani
https://orcslab.github.io/
Departamento de Engenharia Elétrica - DEE

Engenharia de Sistemas



Belo Horizonte

Sumário

1. Introdução

2. Modelagem por Blocos

3. Teorema dos Tipos Extremos

4. Modelagem por Limiar

5. Conclusões

6. Referências

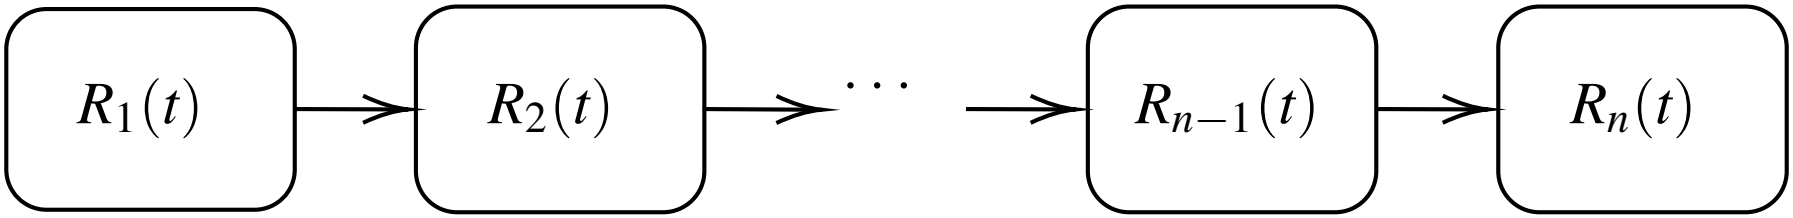
Introdução

A maior parte do que foi discutido até agora foi relacionado ao comportamento **médio** de sistemas.

Entretanto, existem situações em que a análise de confiabilidade deverá tratar os **comportamentos extremos**.

- Pior desempenho de um componente;
- Máxima carga imposta à um sistema;
- Mínima resistência de um certo material.

Considere um sistema com n **elementos em série**, cada qual com uma $R_i(t)$:



Neste caso, o sistema falha se qualquer elemento falhar.

Assim, o tempo até falha do sistema será o *mínimo* dos n tempos até falha que seguem as funções de confiabilidade $R_i(t)$, esse é o **princípio do elo mais fraco**.

Estamos interessados em modelar o comportamento dos extremos, neste exemplo, o extremo inferior, que é o mínimo dos n tempos até falha.

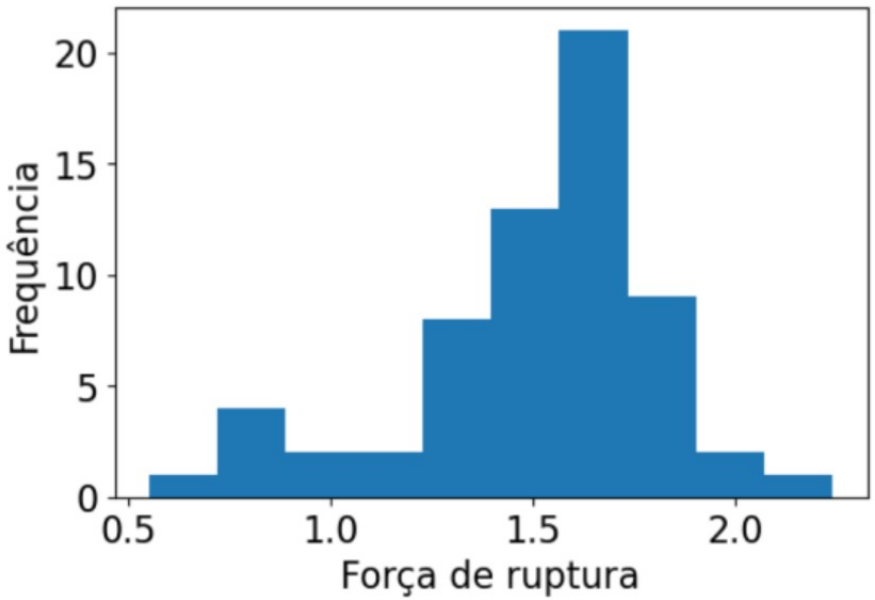
Nestas situações, as abordagens usuais baseadas no comportamento médio de populações aproximadamente normais não são adequadas.

Uma forma específica de análise, denominada análise de valores extremos, se faz necessária para lidar com as especificidades destas situações:

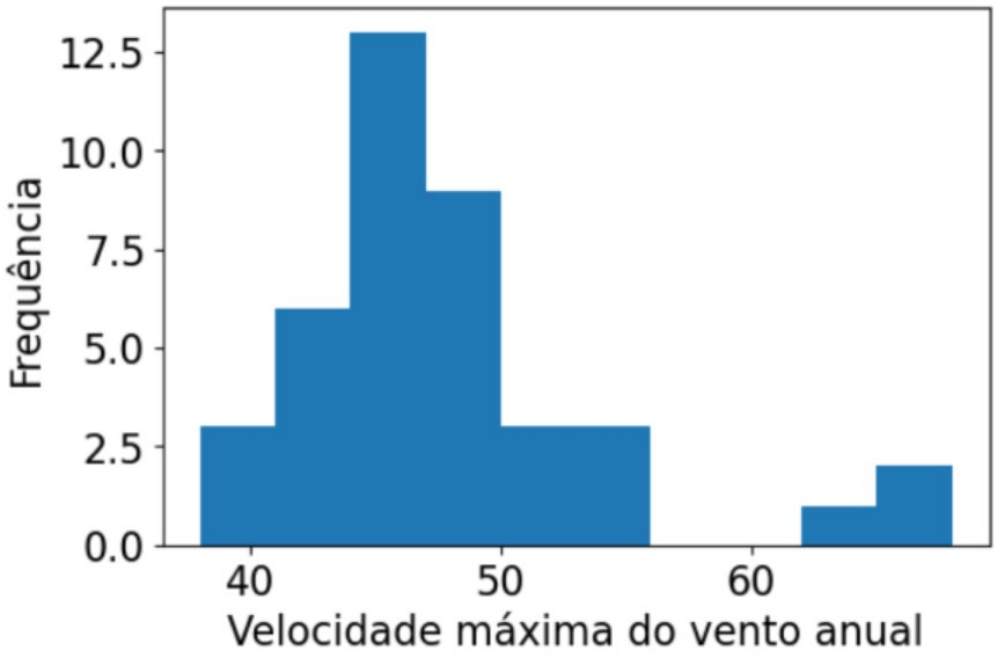
1. **Baixa disponibilidade de observações**: valores extremos são de difícil observação em comparação a valores próximos à média, para a maioria das distribuições usuais de probabilidade;

2. **Distribuições específicas**: a distribuição dos valores extremos usualmente não segue a distribuição geral dos dados.

Exemplo: Força de ruptura em fibras de vidro (Smith & Naylor, 1987).



Exemplo: Velocidade máxima do vento anual (Coles, S. G., 2001).



Introdução:
Valores Extremos

Valores Extremos

Conceito probabilístico relacionado com o comportamento de eventos de cauda.

- Baixa probabilidade;
- Grande incerteza;
- Geralmente acompanhados de grandes consequências.

Nosso interesse é nos valores que não são observados usualmente.

Os quais são distantes dos valores centrais de uma distribuição de probabilidade.

Modelagem por Blocos

Primeira abordagem para modelar os eventos extremos.

A Modelagem por Blocos foi desenvolvida no final da primeira metade do Séc. XX com estudos relacionados a projetos de estruturas na Engenharia Civil.

Tratamento dos **valores máximos (ou mínimos) por blocos de observação**:

- Máximos anuais de eventos meteorológicos;
- Desempenhos mínimos de lotes de componentes;

Modelos utilizados para descrever os valores máximos[1] de sequências aleatórias.

Tem como foco o comportamento estatístico de variáveis do tipo:

$$M_n = \max\{x_1, ..., x_n\}$$

onde os x_i são observações iid.

Os x_i geralmente representam os valores de um processo monitorado periodicamente, e o M_n representa o máximo observado em n unidades de tempo.

[1] Modelos de mínimos podem ser desenvolvidos de forma análoga

Dadas as n observações x_i, queremos modelar M_n

$$M_n = \max\{x_1, ..., x_n\}$$

Se os x_i seguem uma distribuição acumulada

$$F(x) = P(X \leq x),$$

podemos definir a distribuição de M_n como:

$$P(M_n \leq z) = P(x_1 \leq z, x_2 \leq z, \ldots, x_n \leq z)$$

Como $\{x_1, ..., x_n\}$ são iid:

$$P(M_n \leq z) = P(x_1 \leq z, \ldots, x_n \leq z) = P(x_1 \leq z) \ldots P(x_n \leq z)$$

Podemos escrever então:

$$P(M_n \leq z) = \{F(z)\}^n$$

Desta maneira, pequenos erros na estimação de $F(x)$ resultam em grandes erros para $P(M_n \leq z) = \{F(z)\}^n$.

Nossa variável aleatória é $M_n = \max\{x_1, ..., x_n\}$ e queremos um modelo para $P(M_n \leq z)$.

Para $\forall z < z^+$, onde $F(z^+) = 1$, a $P(M_n \leq z) = \{F(z)\}^n \to 0$ sempre que $n \to \infty$.

Dessa forma, a distribuição $\{F(z)\}^n$ sempre será degenerada, i.e., $P(M_n \leq z) = 0 \quad \forall z$.

Uma outra abordagem é modelar diretamente a $P(M_n \leq z)$, resultando em um modelo específico para a distribuição de probabilidade dos valores extremos.

Para que seja possível tratar esse valores utilizando modelos assintóticos, é necessário realizar uma normalização linear:

$$M_n^* = \frac{M_n - b_n}{a_n}$$

Onde $\{a_n\} > 0$ e $\{b_n\}$ são sequências de constantes reais e finitas.

Feita a transformação linear, iremos buscar uma distribuição que modela satisfatoriamente os máximos amostrais normalizados M_n^*.

Teorema dos Tipos Extremos

O Teorema dos Tipos Extremos é um resultado estatístico bastante útil, sendo considerado o análogo do Teorema Central do Limite para valores extremos.

Este teorema dita que se existirem as sequências de constantes $\{a_n\} > 0$ e $\{b_n\}$ de forma que:

$$P\left(\frac{M_n - b_n}{a_n} \leq z\right) \to G(z) \quad \text{se } n \to \infty$$

Onde $G(z)$ é uma distribuição de probabilidade não-degenerada.

Então $G(z)$ pertence a uma de três famílias de distribuições, independente da distribuição original dos $\{x_1, ..., x_n\}$ que geram os M_n.

Essas distribuições são conhecidas como **Distribuições de Valores Extremos** (EVDs).

Teorema dos Tipos Extremos: Distribuições de Valores Extremos

Distribuições de valores extremos do Tipo I, ou Distribuição de Gumbel, são modelos para as caudas inferior e superior de distribuições com característica exponencial:

- Gaussiana;
- Lognormal;
- Exponencial;
- ....

A pdf para a Distribuição de Gumbel é dada por:

$$G(z) = \exp\left\{-\exp\left[-\left(\frac{z-b}{a}\right)\right]\right\}, \quad -\infty \leq z \leq \infty$$

onde $a > 0$ e b são, respectivamente, os parâmetros de escala e localização.

Distribuições de valores extremos do Tipo II, ou Distribuição de Fréchet, são utilizadas quando a distribuição não possui um limite superior (z^+).

A Distribuição de Fréchet é descrita por:

$$G(z) = \begin{cases} 0 & , z \leq b \\ \exp\left\{-\left(\frac{z-b}{a}\right)^{-\alpha}\right\} & , z > b \end{cases}$$

onde $a > 0$ e b são, respectivamente, os parâmetros de escala e localização e $\alpha > 0$ é o parâmetro de forma.

Distribuições de valores extremos do Tipo III são modelos para os mínimos de distribuições que possuem limite superior.

Estes valores são descritos pela Distribuição de Weibull:

$$G(z) = \begin{cases} \exp\left\{-[-\left(\frac{z-b}{a}\right)]^{\alpha}\right\} & , z < b \\ 1 & , z \geq b \end{cases}$$

onde $a > 0$ e b são, respectivamente, os parâmetros de escala e localização e $\alpha > 0$ é o parâmetro de forma.

Cada uma das distribuições reflete uma perspectiva diferente dos valores extremos:

- Tipo I, ou de Gumbel, para comportamento exponencial;
- Tipo II, ou de Fréchet, para máximos ilimitados;
- Tipo III, ou Weibull, para máximos limitados.

Dessa forma, é necessário:

1. Assumir um desses comportamentos, i.e., escolher uma das três famílias de distribuição de probabilidade;
2. Estimar os parâmetros;
3. Realizar as análises necessárias.

Essa escolha de uma das três distribuições de probabilidade acaba por inserir mais uma fonte de erros e de viés na análise.

Uma alternativa para obter análises menos enviesadas foi reformular o Teorema dos Tipos Extremos de forma que ele generalize os três tipos de distribuições para valores extremos.

Isso resultou na Distribuição Generalizada de Valores Extremos.

Teorema dos Tipos Extremos: Distribuição Generalizada de V.E.

A Distribuição Generalizada de Valores Extremos é da seguinte forma:

$$G(z) = \exp\left\{-\left[1+\xi\left(\frac{z-\mu}{\sigma}\right)\right]^{-\frac{1}{\xi}}\right\}$$

definida nos valores $\{z \in \mathbb{R} | 1+\xi\left(\frac{z-\mu}{\sigma}\right) > 0\}$, e com parâmetros satisfazendo:

- Parâmetro de localização $-\infty < \mu < \infty$;
- Parâmetro de escala $\sigma > 0$;
- Parâmetro de forma $-\infty < \xi < \infty$.

Esta unificação das três distribuições de valores extremos em uma única família simplifica o processo de escolha do modelo.

- A responsabilidade pela escolha do modelo repousa nos dados, e não mais no analista.

O parâmetro de forma ξ determina o tipo da distribuição:

- $\xi < 0$ - Weibull (Tipo III);
- $\xi > 0$ - Fréchet (Tipo II);
- $\xi \to 0$ - Gumbel (Tipo I).

Além disso, a incerteza associada à definição deste parâmetro quantifica a falta de dados para a escolha de uma das três distribuições.

No caso da necessidade de modelagem de valores mínimos, a distribuição GEV pode ser descrita como:

$$\tilde{G}(z) = 1 - \exp\left\{-\left[1 - \xi\left(\frac{z-\tilde{\mu}}{\sigma}\right)\right]^{-\frac{1}{\xi}}\right\}$$

definida nos valores $\{z \in \mathbb{R} | 1 - \xi\left(\frac{z-\tilde{\mu}}{\sigma}\right) > 0\}$, e com parâmetros satisfazendo:

- Parâmetro de localização $-\infty < \tilde{\mu} < \infty$;
- Parâmetro de escala $\sigma > 0$;
- Parâmetro de forma $-\infty < \xi < \infty$.

Alternativamente, pode-se utilizar a seguinte transformação nos dados $\tilde{M}_n = -\max\{-x_1, \ldots, -x_n\}$ e aplicar diretamente o modelo de máximos.

A estimação dos parâmetros μ, σ e ξ da distribuição generalizada de valores extremos pode ser realizada de diferentes formas (assim como a estimativa dos parâmetros das outras distribuições).

Uma das formas mais usuais de realizar esta estimação é a utilização do método de máxima verossimilhança.

Este método é baseado na maximização da função *likelihood* ou de seu logaritmo, que quantifica a probabilidade de se obter os dados observados utilizando uma distribuição de probabilidade específica com k parâmetros;

$$L(\theta_1, \ldots, \theta_k) = \prod_{i=1}^{n} f(x_i; \theta_1, \ldots, \theta_k)$$

$$\Lambda(\theta_1, \ldots, \theta_k) = \ln[L(\theta_1, \ldots, \theta_k)] = \sum_{i=1}^{n} \ln[f(x_i; \theta_1, \ldots, \theta_k)]$$

Supondo que $\mathbf{Z} = \{z_1, \ldots, z_m\}$ é uma amostra aleatória de uma variável aleatória que segue a GEV, a função log-verossimilhança para os parâmetros da GEV com $\xi \neq 0$ é dada por:

$$\Lambda(\mu, \sigma, \xi) = -m \ln(\sigma) - (1 + 1/\xi) \sum_{i=1}^{m} \ln \left[1 + \xi \left(\frac{z_i - \mu}{\sigma} \right) \right] - \sum_{i=1}^{m} \left[1 + \xi \left(\frac{z_i - \mu}{\sigma} \right) \right]^{-1/\xi}$$

sob a condição de que:

$$1 + \xi \left(\frac{z - \mu}{\sigma} \right) > 0, \ \forall i \in \{1, \ldots, m\}$$

Para o caso onde $\xi = 0$, a função é obtida a partir da distribuição limite de Gumbel:

$$l(\mu, \sigma) = -m \ln(\sigma) - \sum_{i=1}^{m} \left(\frac{z_i - \mu}{\sigma} \right) - \sum_{i=1}^{m} \exp \left\{ - \left(\frac{z_i - \mu}{\sigma} \right) \right\}$$

A maximização destas equações em relação ao vetor de parâmetros (μ, σ, ξ) conduz às estimativas de máxima verossimilhança dos parâmetros do modelo.

Embora não haja solução analítica para esta maximização, a mesma é realizada a partir de algoritmos usuais de otimização não linear restrita, haja vista a necessidade de obter valores que respeitem à restrição:

$$1 + \xi \left(\frac{z - \mu}{\sigma} \right) > 0, \ \forall i \in \{1, \ldots, m\}$$

e que evitem a avaliação da primeira equação na vizinhança de pontos onde $\xi \approx 0$

Esta última condição pode ser atendida através da modificação da função avaliada pela $l(\mu, \sigma)$ do slide anterior para uma dada ϵ-vizinhança de $\xi = 0$.

Teorema dos Tipos Extremos: Nível de Retorno

Uma vez que os parâmetros da GEV tenham sido obtidos, a mesma pode ser utilizada para a realização de análises dos valores extremos.

Um conceito fundamental neste tipo de análise é o nível de retorno:

Nível de retorno z_p

Um nível de retorno z_p, associado a um período de retorno $1/p$, $p \in [0, 1]$, representa um valor da variável observada (valores extremos) que se espera que seja excedido uma vez a cada $1/p$ observações.

Neste contexto, cada observação representa o valor máximo de blocos do tamanho originalmente utilizado, normalmente mensal ou anual.

Por exemplo, em inferências sobre máximos meteorológicos anuais, $1/p$ é um valor em anos.

Para este caso, o nível de retorno z_p com $p = 0.01$ ocorrerá com um período de retorno $1/0.01 = 100$ anos.

Dadas as estimativas de máxima verossimilhança $\left(\hat{\mu}, \hat{\sigma}, \hat{\xi}\right)$, a estimativa correspondente para um dado nível de retorno z_p pode ser calculada por:

$$\hat{z}_p = \begin{cases} \hat{\mu} - \frac{\hat{\sigma}}{\hat{\xi}}\left[1 - y_p^{-}\hat{\xi}\right] & , \text{ se } \hat{\xi} \neq 0 \\ \hat{\mu} - \hat{\sigma}\ln(y_p) & , \text{ se } \hat{\xi} = 0 \end{cases}$$

com $y_p = -\ln(1-p)$.

Pode-se obter intervalos de confiança nesta predição.

Um forma é através do *método delta*, onde o erro padrão do estimador é utilizado para definir o IC.

Apesar da possibilidade de derivar os valores dos níveis de retorno analiticamente, soluções computacionais são mais simples e diretas para tratar problemas de valores extremos.

Pacotes do software estatístico R (recomendado):

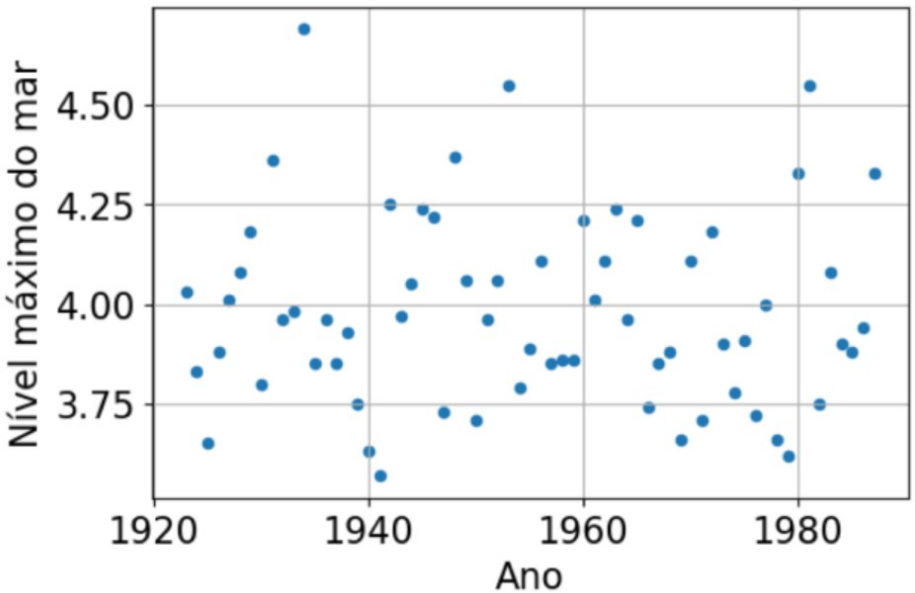
- ismev, evir, extRemes, evd.

Outras opções:

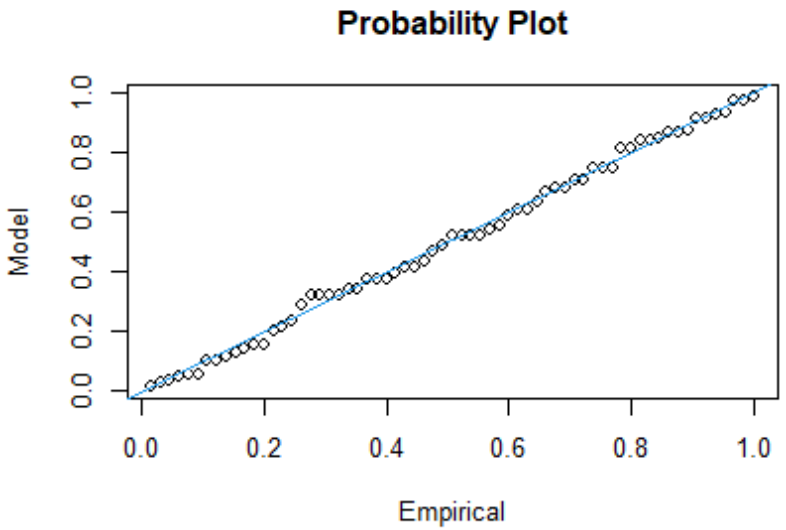
- scipy.stats no Python
- distribuição GEV no MATLAB

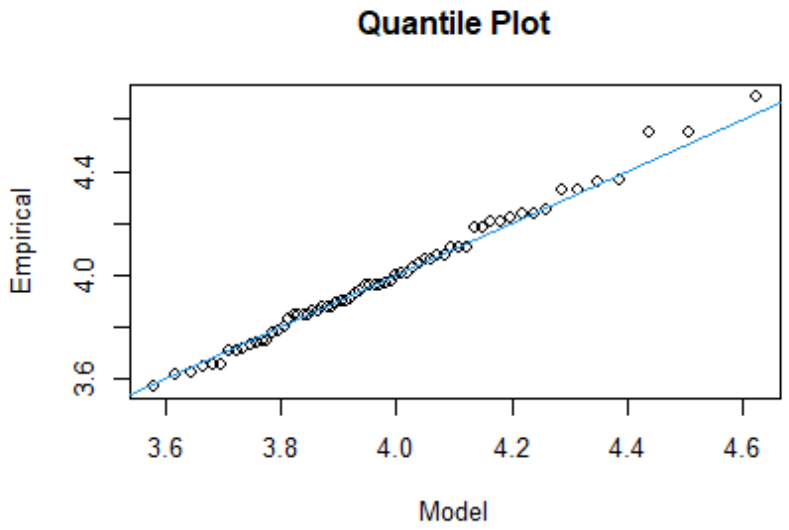
Exemplo Computacional (Coles, S. G. (2001))

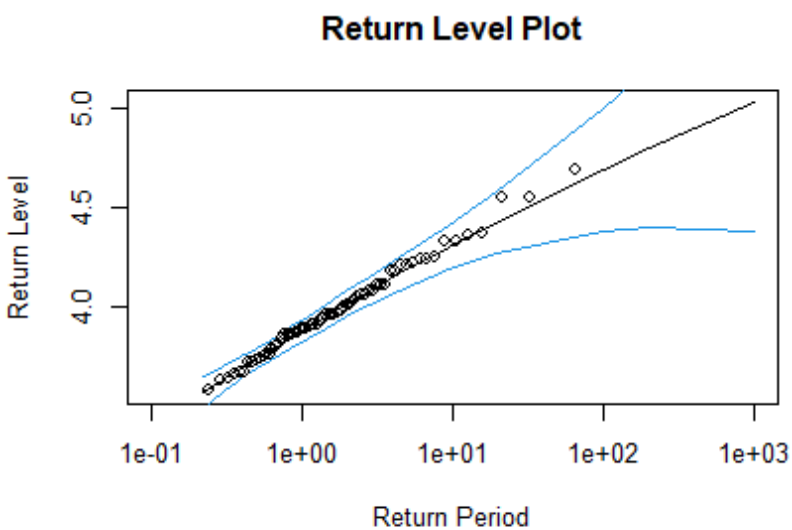
Suponhamos que para a especificação de um sistema de escoamento de dejetos líquidos em uma cidade litorânea seja necessário estimar o nível máximo do mar nos próximos 50 anos. Suponha ainda que tenhamos dados dos máximos anuais dos últimos 64 anos.

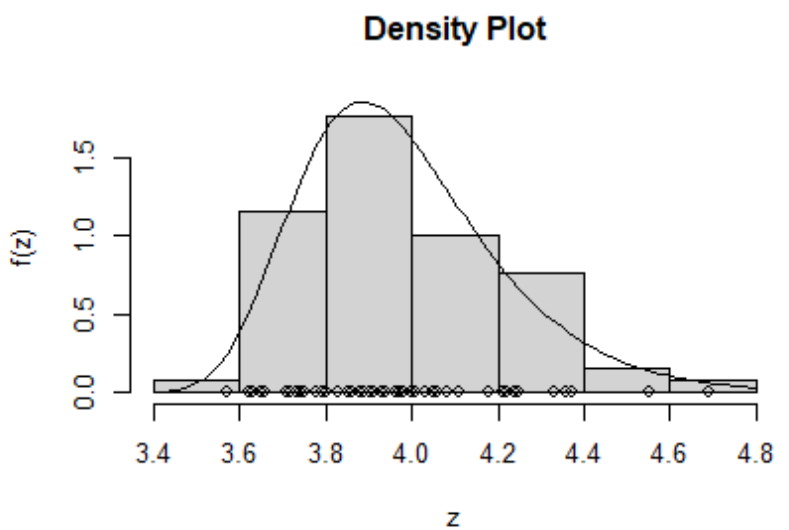


Ver *Aula5_Valores_Extremos.R*.



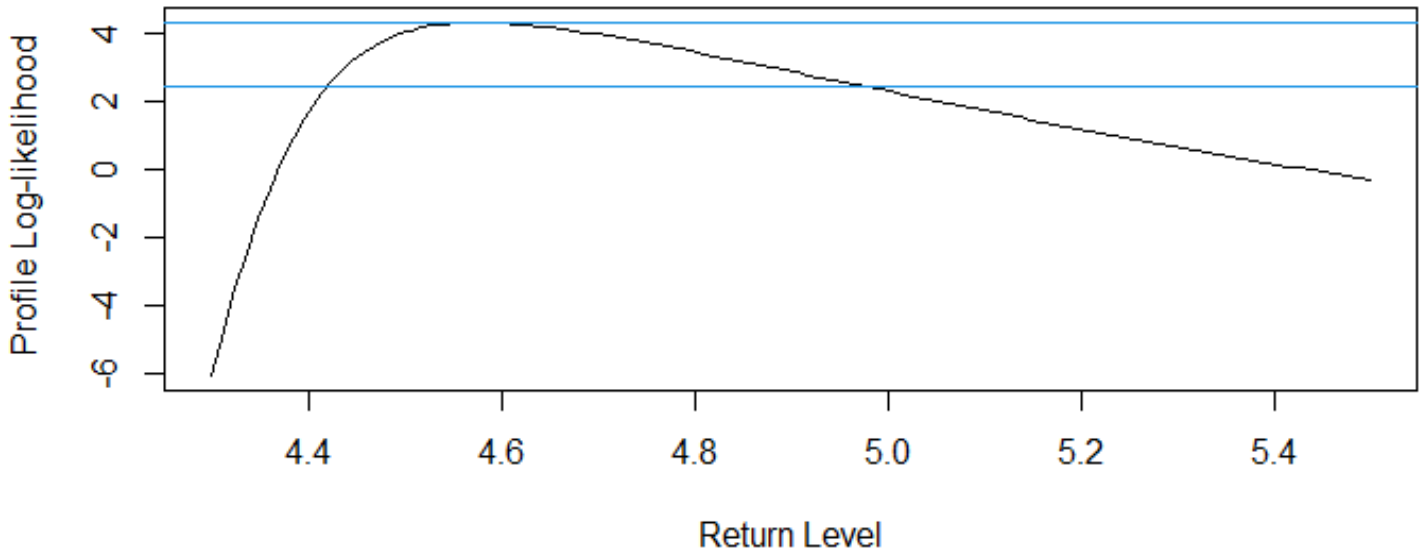






Ver *Aula5_Valores_Extremos.R*.

Nível de retorno para 50 anos:



Modelagem por Limiar

Embora útil, a modelagem de extremos utilizando pontos máximos de blocos de observações é uma abordagem que leva ao desperdício de informações.

Principalmente em casos onde outros dados relativos a comportamentos extremos estão disponíveis.

Por exemplo, se um bloco contém muitas observações mais extremas que outros, a informação sobre este comportamento é perdida ao se utilizar apenas o extremo do bloco.

Se uma sequência de valores está disponível, um uso mais eficaz dos dados pode ser obtida evitando-se o procedimento de agrupamento em blocos.

Seja $\mathbf{X} = \{x_1, x_2, \ldots, x_n\}$ uma sequência de observações iid de acordo com uma dada distribuição $F(x)$.

Uma interpretação natural de observações extremas é considerá-los como valores que excedem um determinado limiar elevado u.

De acordo com esta definição, o comportamento de observações extremas pode ser descrito por:

$$P(x_i > u + y | x_i > u) = \frac{1 - F(u + y)}{1 - F(u)}, \quad y > 0.$$

Se a distribuição F for conhecida, a distribuição de valores acima do limiar u também será.

Um outro resultado, entretanto, dispensa o conhecimento da distribuição exata de X.

Para a amostra aleatória $\mathbf{X}$ descrita anteriormente, a distribuição dos valores $(x_i - u)$ condicional a $x_i > u$ pode ser aproximada por:

$$H(y) = 1 - \left(1 + \frac{\xi y}{\tilde{\sigma}}\right)^{-\frac{1}{\xi}}$$

para $y > 0$ e com $1 + \frac{\xi y}{\tilde{\sigma}} > 0$, onde:

$$\tilde{\sigma} = \sigma + \xi(u - \mu)$$

Esta família de distribuições é conhecida como Distribuição de Pareto Generalizada (GPD).

Assim como no caso da GEV, o parâmetro de forma ξ possui um papel central na determinação do comportamento da GPD:

$$H(y) = 1 - \left(1 + \frac{\xi y}{\tilde{\sigma}}\right)^{-\frac{1}{\xi}}$$

- $\xi < 0$, então a distribuição de excessos possui um limite superior dado por $u - \hat{\sigma}/\xi$;
- $\xi > 0$, então a distribuição de excessos não possui limite superior;
- $\xi \to 0$, então a distribuição se torna uma exponencial,

$$H(y) = 1 - \exp\left\{-\frac{y}{\tilde{\sigma}}\right\}, \quad y > 0.$$

A escolha do valor de limiar u é um ponto crítico para uma boa modelagem de valores extremos:

- Valores baixos de u tendem a violar as propriedades assintóticas que formam a base do modelo, levando à ocorrência de erros sistemáticos (bias);
- Valores muito elevados de u resultam na ocorrência de poucas observações classificadas como extremos, levando a um aumento na incerteza dos parâmetros (elevação na variância).

O procedimento padrão envolve tentar escolher um valor de u o mais baixo possível, sujeito à condição de que o modelo resultante seja capaz de gerar boas aproximações dos dados.

Um método frequentemente utilizado para a seleção do valor de u é baseado no valor da média da distribuição generalizada de Pareto.

Supondo uma variável aleatória Y que siga uma GPD com parâmetros σ e ξ, sabe-se que:

$$E[Y] = \frac{\sigma}{1-\xi}$$

para $\xi < 1$.

Valores de $\xi \geq 1$ levam a valores esperados infinitos.

Assumindo que a GPD seja um modelo adequado para os valores em excesso de um dado limiar u_0 gerados por uma a.a. $\{x_1, \ldots, x_n\}$. De acordo com a equação anterior, temos que:

$$E[x_i - u_0 | x_i > u_0] = \frac{\sigma_{u_0}}{1 - \xi}, \text{ para } \xi < 1$$

Pode-se mostrar que se a GPD é um modelo adequado para um limiar u_0, também será para qualquer limiar $u > u_0$, sujeito a mudanças no fator de escala σ_u e que, para $u > u_0$:

$$E[x_i - u | x_i > u] = \frac{\sigma_u}{1 - \xi} = \frac{\sigma_{u_0} + \xi u}{1 - \xi}$$

representa a média dos valores de excesso em relação à u.

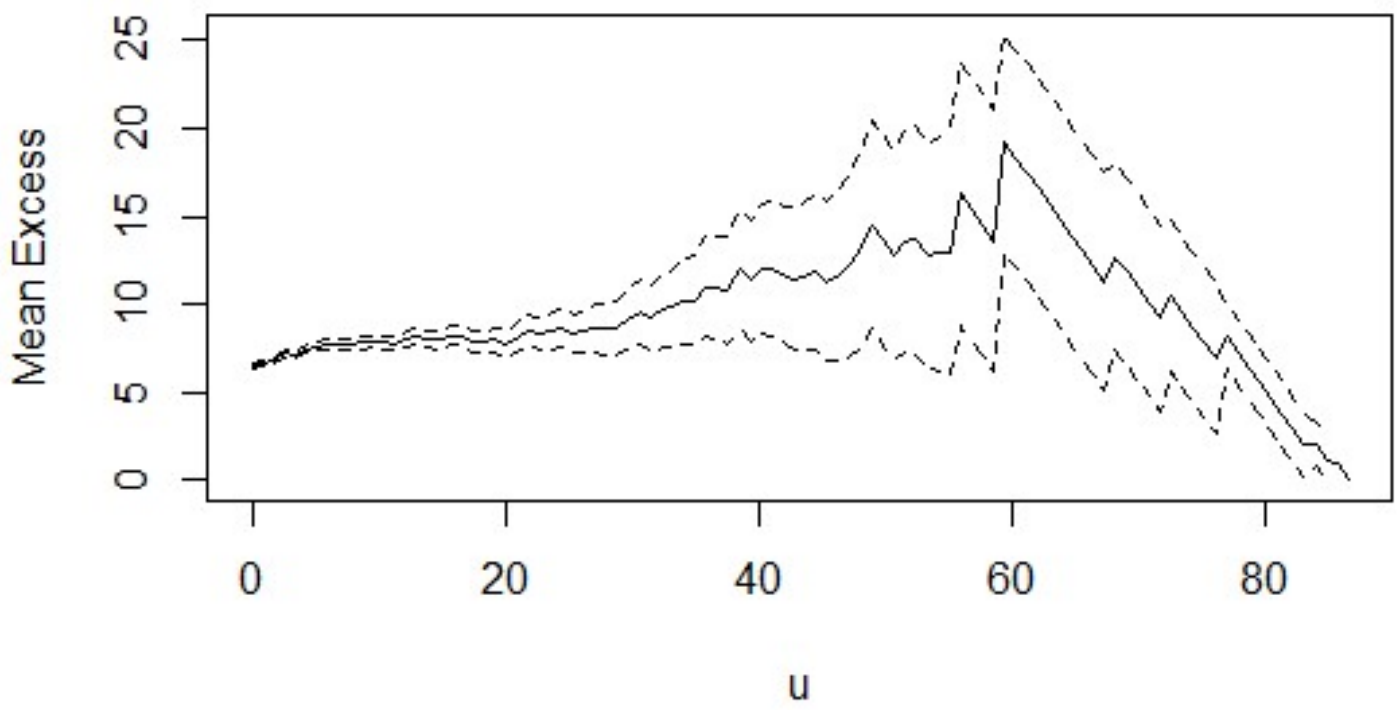
De acordo com este último resultado, tem-se que o valor da média dos valores de excesso em relação à u tende a crescer linearmente com o aumento no valor de u para faixas de valores nas quais a GPD seja apropriada.

Isto sugere um procedimento baseado no gráfico de valores de u versus:

$$\frac{1}{n_u}\sum_{i=1}^{n_u}(x_{(i)} - u)$$

onde $x_{(i)}$ representa as n_u observações que excedem o limiar u, $u < x_{\max}$ onde $x_{\max} = \max\{x_1, x_2, \ldots, x_n\}$.

Gráfico conhecido como gráfico de vida média residual (*mean residual life plot*) e observaremos um comportamento aproximadamente linear em relação a u acima de um u_0 para o qual a GPD passa a ser um modelo válido.



$u_0 = 30$ é uma boa escolha?

Os parâmetros do modelo GPD podem ser estimados da mesma forma que os da GEV, ou seja, através da maximização da função ln-verossimilhança (l).

Para $\xi \neq 0$:

$$l(\sigma, \xi) = -k \ln(\sigma) - (1 + 1/\xi) \sum_{i=1}^{k} \ln(1 + \xi y_1/\sigma)$$

Para $1 + \xi y_1/\sigma > 0$ e $i = 1, \ldots, k$.

Para $\xi = 0$

$$l(\sigma) = -k \ln(\sigma) - \frac{1}{\sigma} \sum_{i=1}^{k} y_i$$

Novamente, métodos numéricos de otimização são utilizados para encontrar os pontos de ótimo destas funções.

Assim como nos modelos GEV, os níveis de retorno x_m quantificam valores que se espera serem excedidos a cada m observações. Pode-se mostrar que estes níveis de retorno são calculáveis a partir de:

$$\hat{x}_m = \begin{cases} \hat{u} + \frac{\hat{\sigma}}{\hat{\xi}} \left[\left(\frac{mk}{n} \right)^{\xi} - 1 \right] & , \text{ se } \hat{\xi} \neq 0 \\ \hat{u} + \hat{\sigma} \ln \left(\frac{mk}{n} \right) & , \text{ se } \hat{\xi} = 0 \end{cases}$$

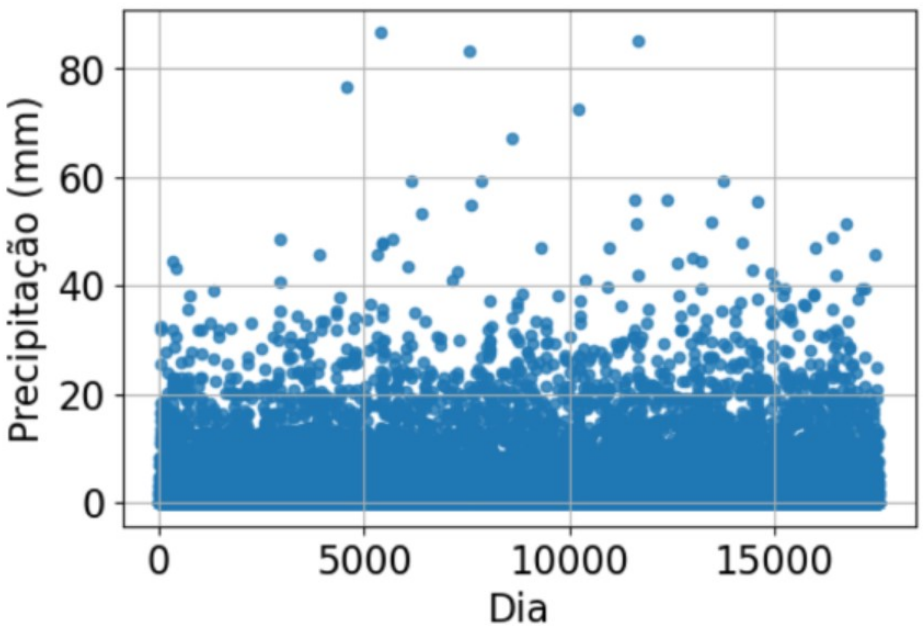
com k/n representando a proporção de observações que excedem o limiar u, e assumindo $x_m > u$.

Por construção, o valor de x_m pode ser considerado como o nível de retorno após m observações.

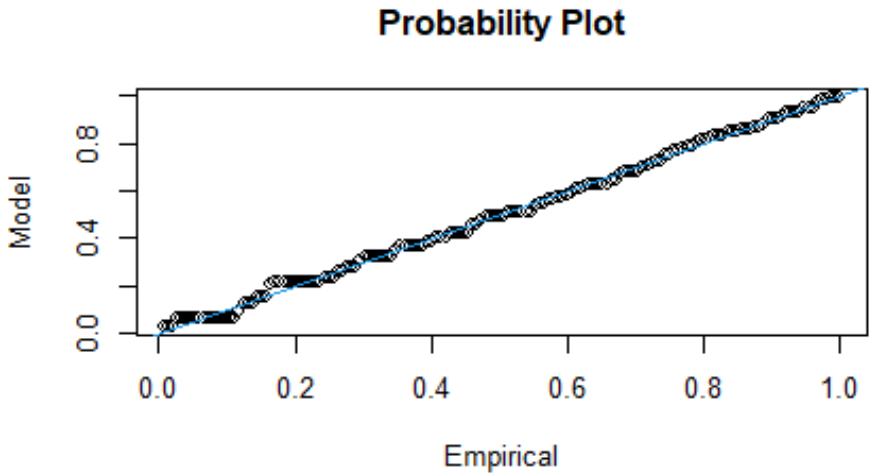
Intervalos de confiança podem ser facilmente obtidos através de softwares estatísticos.

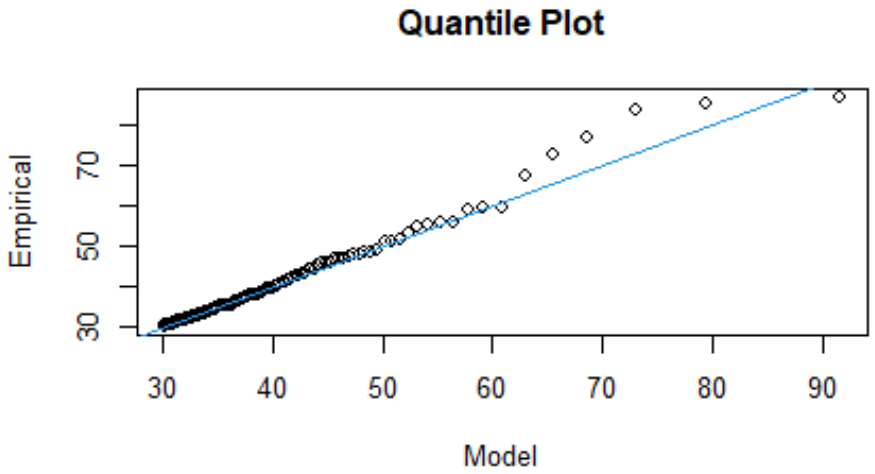
Exemplo Computacional (Coles, S. G. and Tawn, J. A. (1996))

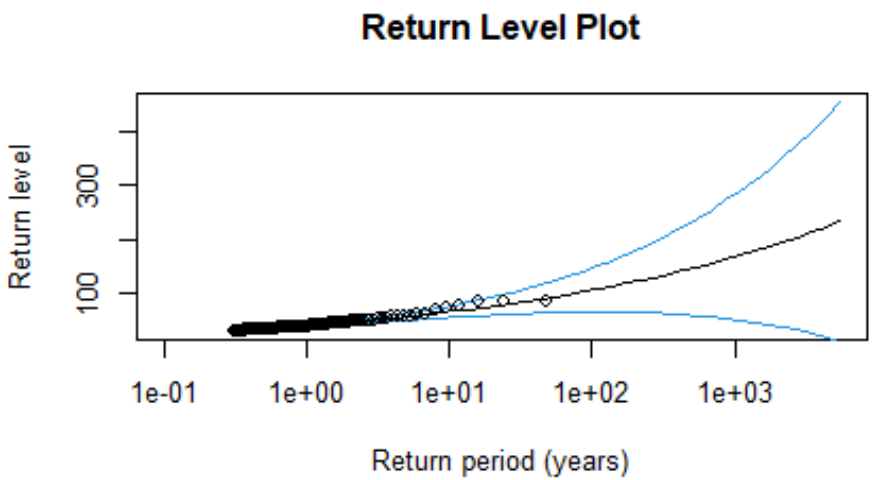
Suponhamos agora que seja necessário projetar um sistema de escoamento pluvial capaz de suportar o máximo de precipitação diária previsível para uma dada região da cidade. Posto que obras deste porte são custosas e raras, deseja-se projetar o sistema de forma a possibilitar o escoamento da maior precipitação esperada para os próximos 100 anos.

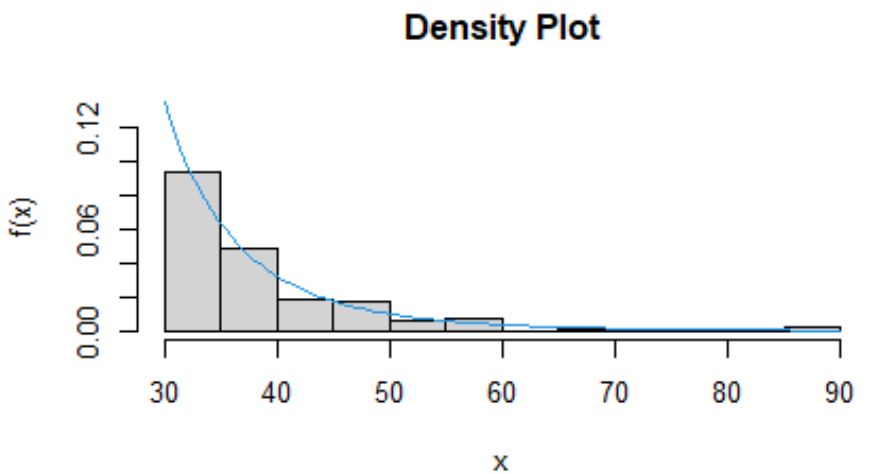


Ver *Aula5_Valores_Extremos.R*.



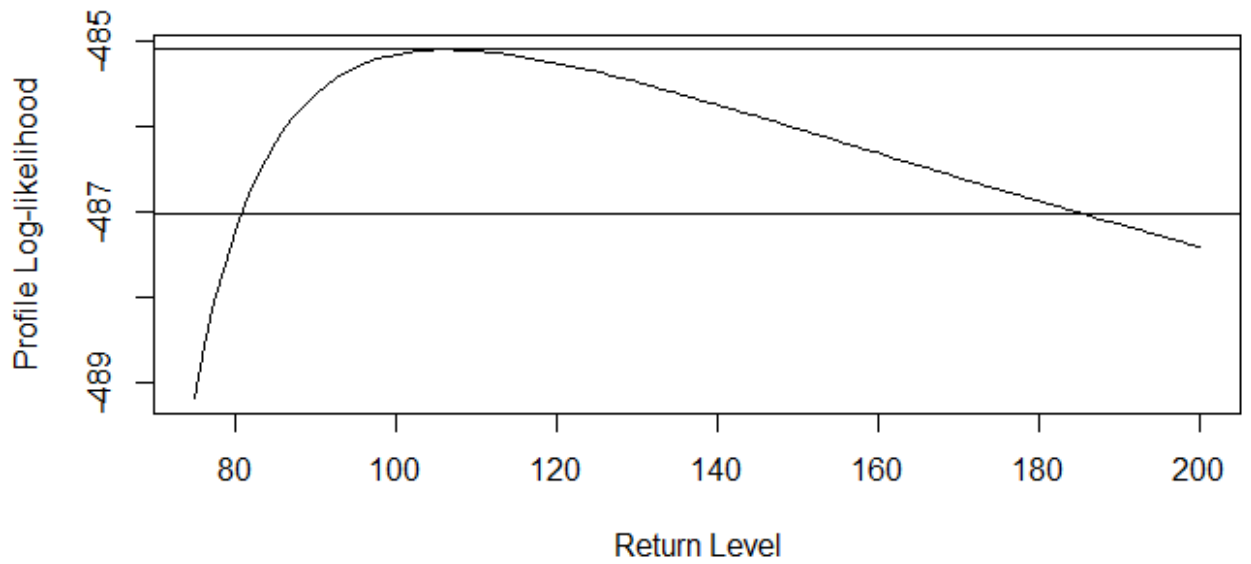






Ver *Aula5_Valores_Extremos.R*.

Nível de retorno para 100 anos:



Conclusões

As abordagens apresentadas aqui assumem que o processo que estamos interessados é *estacionário*, o que nem sempre é verdade.

Nossas análises devem ser interpretadas da seguinte maneira:

Sob as condições atuais, espera-se que um dado nível de retorno z_p ocorrerá com um tempo de retorno $1/p$.

Existem formas de tratar processos não estacionários, mas não serão abordados aqui.

A modelagem de valores extremos, embora aparentemente complexa, pode ser realizada de forma relativamente simples através da utilização de ferramentas computacionais.

Este tipo de modelagem é extremamente útil para a estimativa de comportamentos de pior caso, sejam mínimos ou máximos, o que representa uma tarefa essencial em problemas de confiabilidade e de outras áreas de aplicação.

Sugestão de estudo: realizar a modelagem dos valores mínimos de resistência mecânica de fibras de vidro contidas no dataset glass do pacote ismev.

Referências

Referências

- P. D. T. O'Connor, A. Kleyner, *Practical Reliability Engineering*, 5a Ed., Wiley, 2012;
- S. Coles, *An introduction to the statistical modeling of extreme values*, 1a ed., Springer 2001 - Caps. 1 - 4;
- S. Coles, A. Davison, *Statistical Modeling of Extreme Values*, 2008;
- Pacote ismev, `http://CRAN.R-project.org/package=ismev`;