EEE 017 Confiabilidade de Sistemas

6 - Métodos de Reamostragem

Michel Bessani
https://orcslab.github.io/
Departamento de Engenharia Elétrica - DEE

Engenharia de Sistemas

UFMG
UNIVERSIDADE FEDERAL
DE MINAS GERAIS

Belo Horizonte

Sumário

1. Introdução
2. Métodos de Reamostragem
2.1 Reamostragem Paramétrica
2.2 Reamostragem Não Paramétrica
3. Intervalos de Confiança via *Bootstrap*
4. Testes de Hipóteses por *Bootstrap*
5. Referências

Introdução

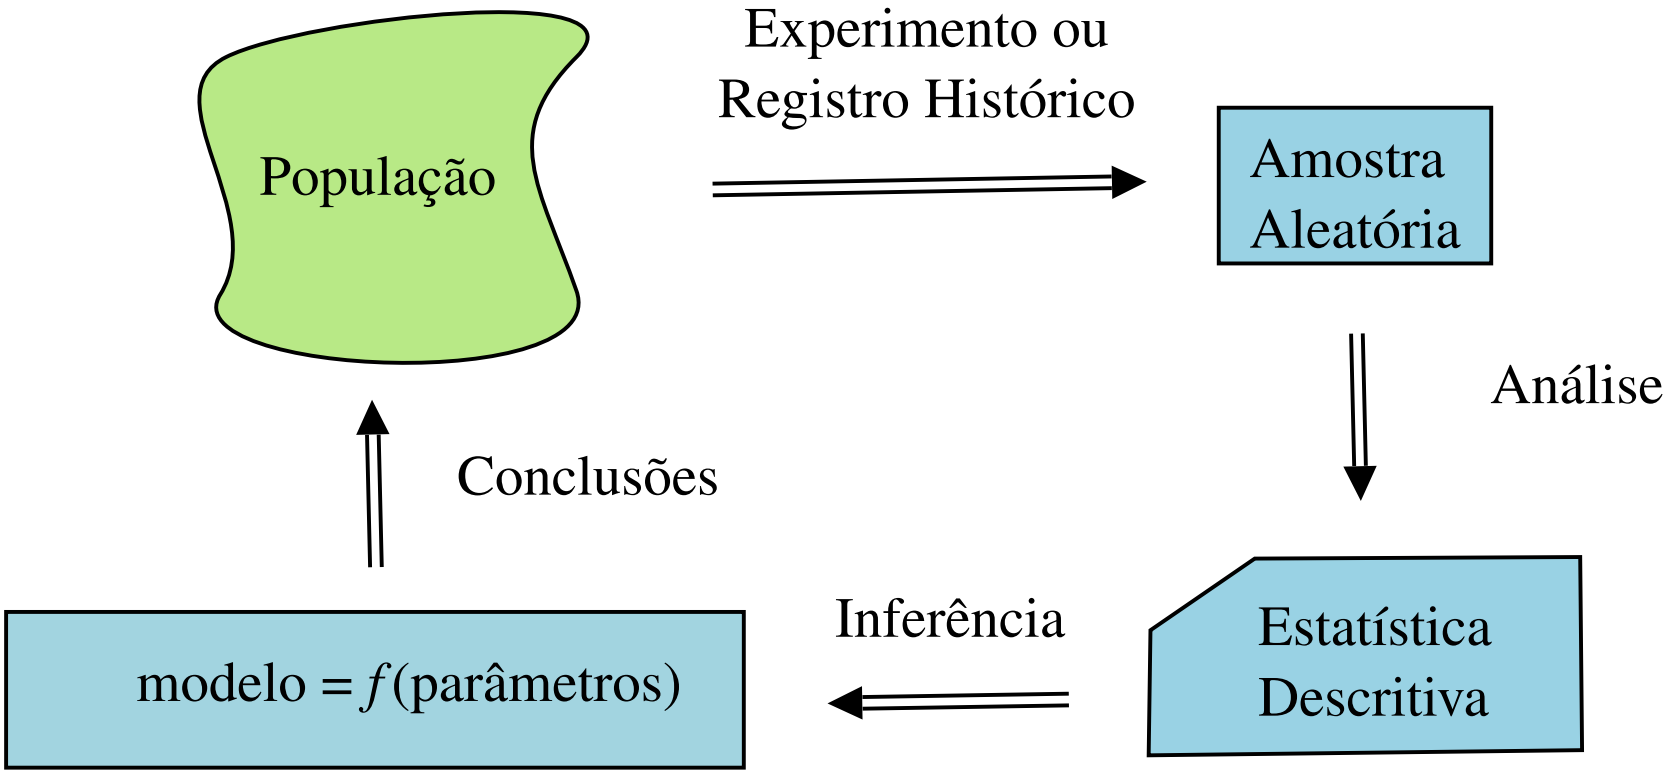
Até agora vimos diferentes ferramentas para visualização, descrição e inferência:

- Gráficos de Probabilidade;
- Histogramas;
- Diagramas de caixa;
- Diagramas de dispersão;
- Estimadores pontuais de posição e de variabilidade;
- Intervalos de Confiança;
- Testes de Hipóteses;

Além destas ferramentas gerais, também vimos ferramentas específicas de Confiabilidade:

- Definição da Função de Confiabilidade,
  $R(t) = P(T > t) = 1 - P(T \leq t) = 1 - F(t)$;
- Modelos usuais para a $R(t)$;
- Verificação do comportamento da função risco $h(t) = f(t)/R(t)$;
- Interpretação da função de risco pela perspectiva do Ciclo de Vida.

Podemos sumarizar o processo de experimentação e inferência da seguinte forma:



Considere agora a seguinte situação, você realizou um experimento e coletou os dados:

1. Os dados atendem às premissas das diferentes técnicas de inferência estatística:
   - Os testes fornecem resultados com significância estatística, permitindo subsidiar respostas para a questão que motivou o experimento;
   - Os testes realizados não forneceram significância estatística;
2. Os dados não atendem às premissas das técnicas de inferência, usualmente a de normalidade.

O que fazer?
Utilizar outros métodos, como os de **reamostragem**.

Dada uma amostra aleatória $\mathbf{x} = \{x_1, x_2, \ldots, x_n\}$, i.e., os x_i seguem uma mesma distribuição de probabilidade f e são independentes, podemos realizar inferências sobre os parâmetros da população, θ_i, utilizando alguma estatística t calculada como $t = T(\mathbf{x})$.

Se $\mathbf{x}$ pode ser ajustada por um modelo matemático com parâmetros Ψ que descreve bem a f, temos então um modelo paramétrico para $\mathbf{x}$.

Sempre que utilizamos esse modelo para inferir sobre um parâmetro θ_i, estamos utilizando da **abordagem paramétrica**.

Caso não adotemos um modelo matemático com parâmetros específicos Ψ, estamos utilizando uma **abordagem não paramétrica**.

Métodos de Reamostragem

Os métodos de reamostragem, ou *bootstrap*, são métodos computacionais utilizados, em geral, para avaliar as propriedades dos estimadores amostrais ou realizar testes estatísticos.

Aplicações:

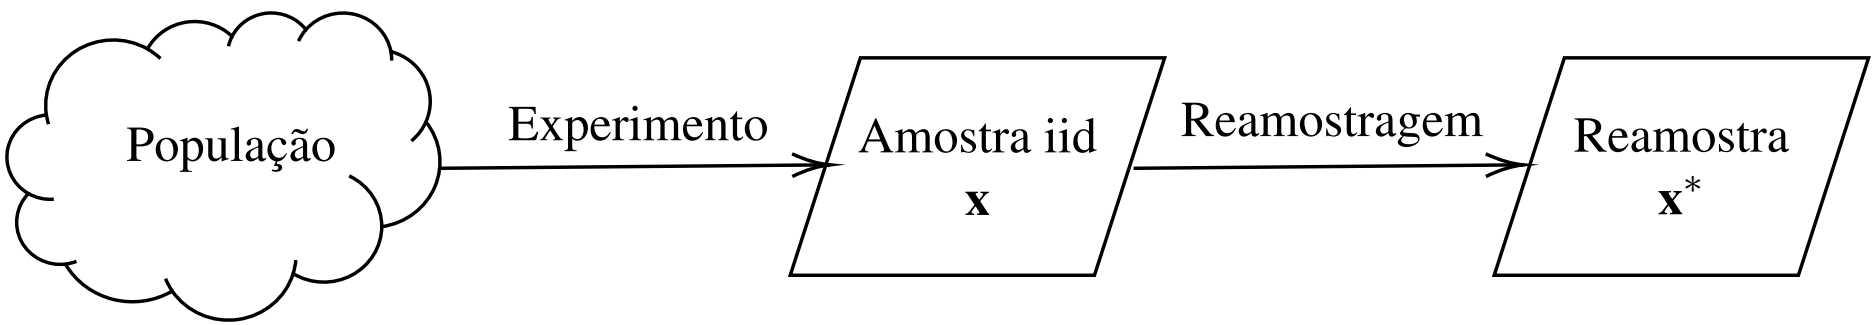
- Estimativa de intervalos de confiança;
- Polarização (tendência) do estimador;
- Variância;
- Regressão;
- Testes de Hipótese.

Foram introduzidos em 1979:

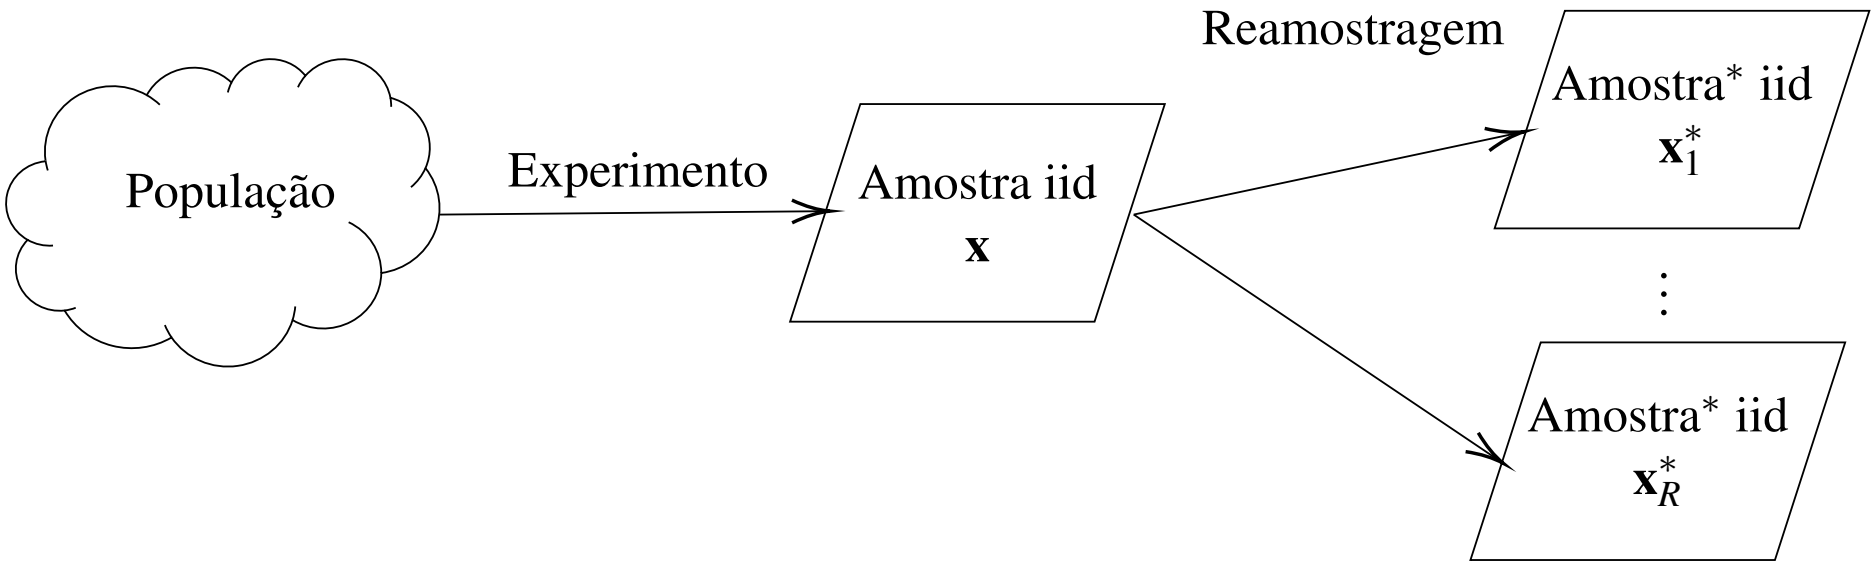
- Efron, B. "Bootstrap Methods: Another Look at the Jackknife." *The Annals of Statistics* 7.1 (1979): 1-26.

Ideia geral: Se a nossa **x** (iid), é representativa da população, então iremos gerar uma nova amostra aleatória $\mathbf{x}^*$ a partir de: *i)* a própria **x** ou *ii*) de um modelo ajustado em **x**.

Em *i)*, estamos tratando **x** como se fosse a própria população:



Se repetirmos esse processo R vezes, podemos utilizar as R amostras de bootstrap ($\mathbf{x}^*$, obtidas por reamostragem) para calcular R estimativas e a partir destas avaliar as propriedades de interesse.



Reamostragem Paramétrica

Considere que temos uma $f_\Psi(x)$ para uma amostra aleatória $\mathbf{x}$. Podemos obter uma estimativa dos parâmetros Ψ, denominada $\hat{\psi}$, a qual pode ser o EMV, e que resulta no modelo ajustado.

Nos casos em que:

- O modelo ajustado é não-trivial;
- Não existem aproximações disponíveis;
- Aproximações não confiáveis (poucas amostras).

Podemos obter R amostras aleatórias a partir da $f_{\hat{\psi}}(x)$ ajustada.

Vamos definir X^* como variável aleatória $\sim f_{\hat{\psi}}(x)$ e $\mathbf{x}^*$ como uma amostra aleatória dessa população.

Esse método é conhecido como ***Bootstrap* Paramétrico**.

Reamostragem Não Paramétrica

Caso não tenhamos um modelo paramétricos de X, i.e, $f_{\hat{\psi}}(x)$, teremos que utilizar apenas o fato de que **x** é composto por observações iid.

Podemos utilizar os x_i para obter uma estimativa da distribuição acumulada de probabilidade F da seguinte maneira:

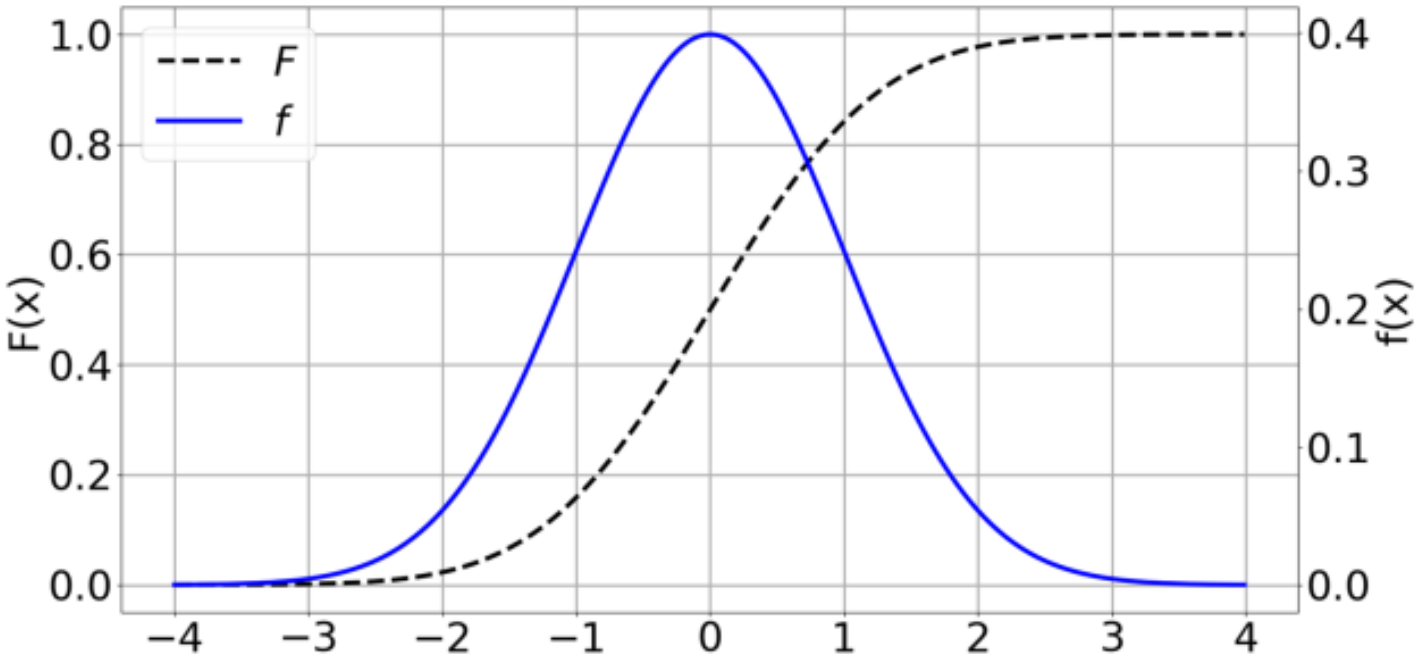
$$\hat{F}(x) = \frac{\#\{x_i \leq x\}}{n}$$

onde $\#\{x_i \leq x\}$ indica o número de ocorrências de observações menores ou iguais do que um x.

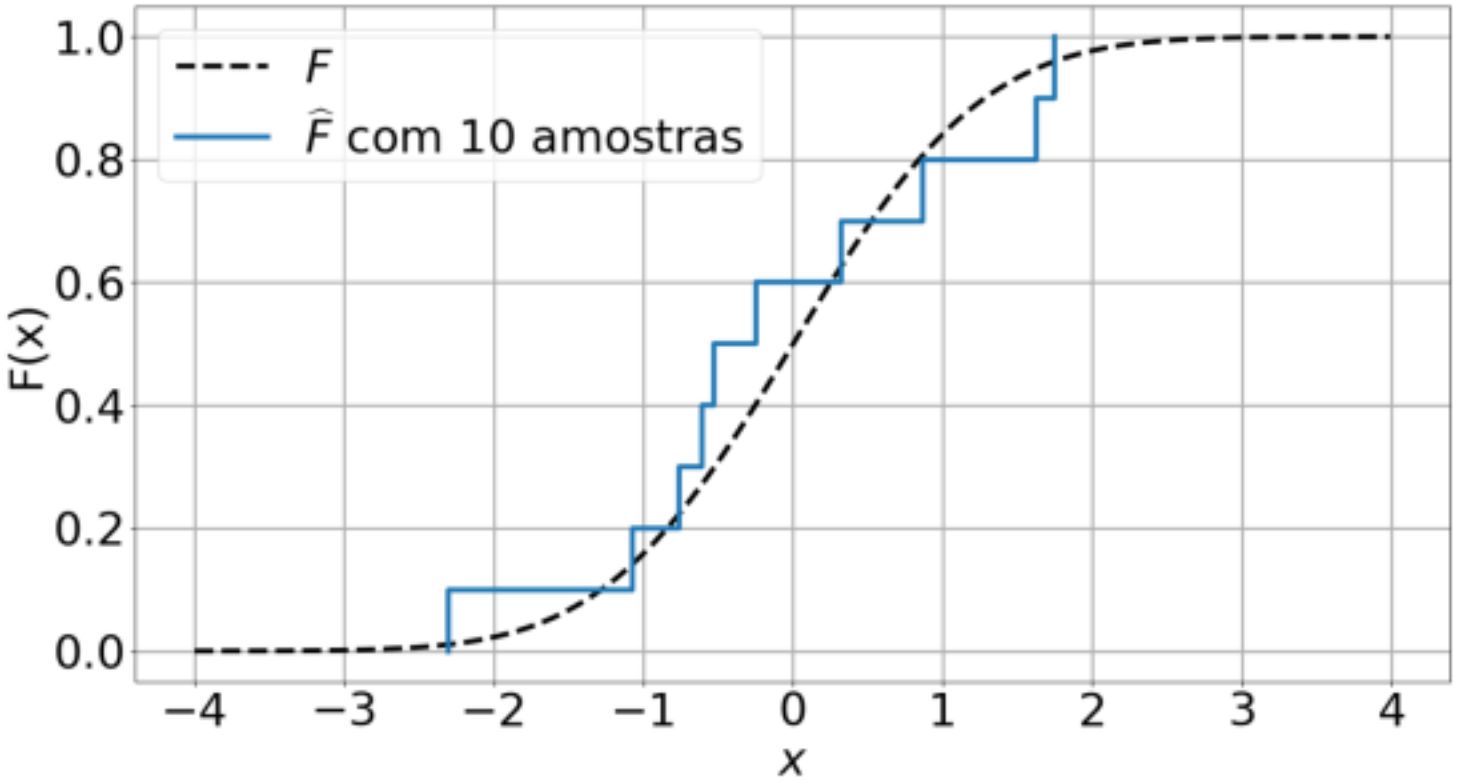
Esse estimador de F é conhecido Distribuição Empírica.

Ver o script *6_1_EstimativaF.py*

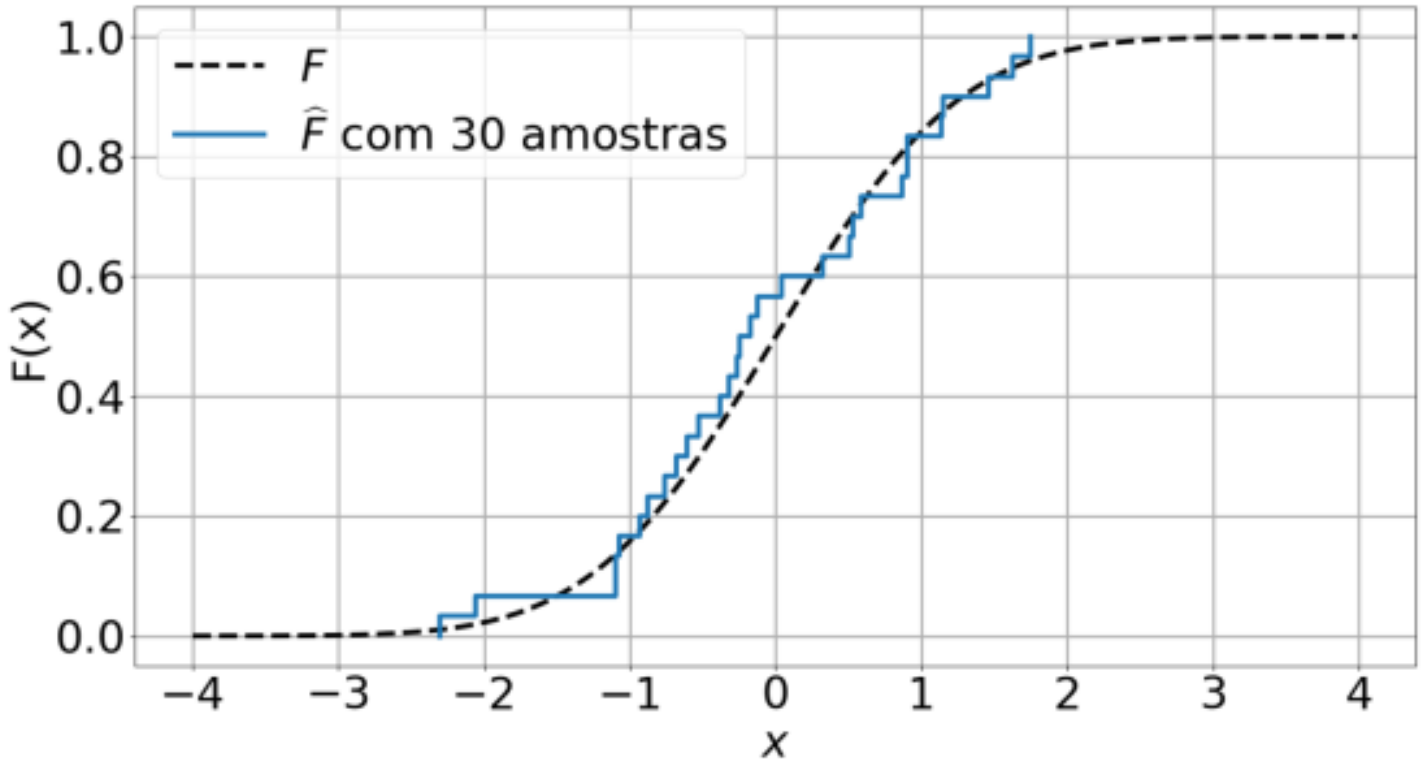
Vamos considerar a $f(x)$ e a $F(x)$ de uma Normal Padrão $\mathcal{N}(0, 1)$:



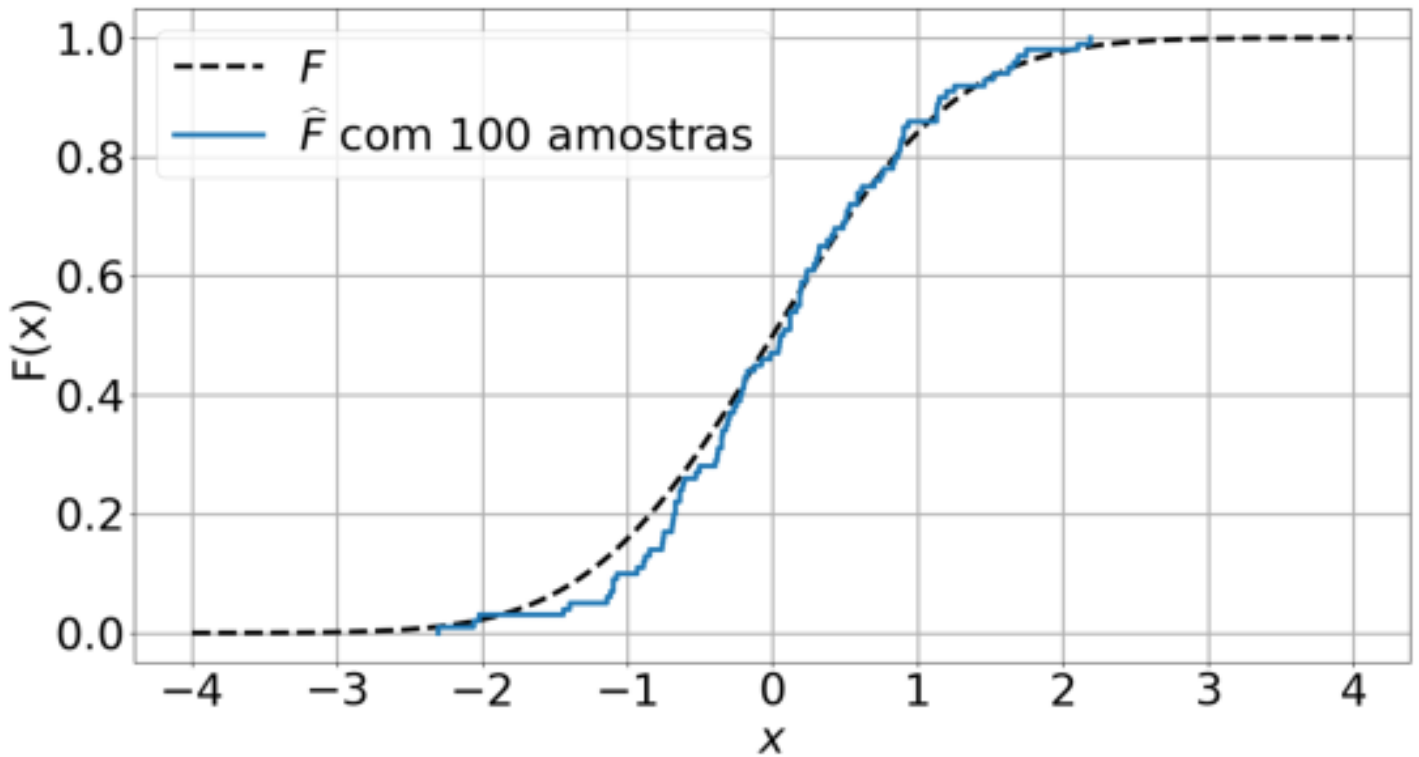
Exemplo de $\hat{F}$ para uma Normal Padrão $\mathcal{N}(0,1)$ com $n = 10$:



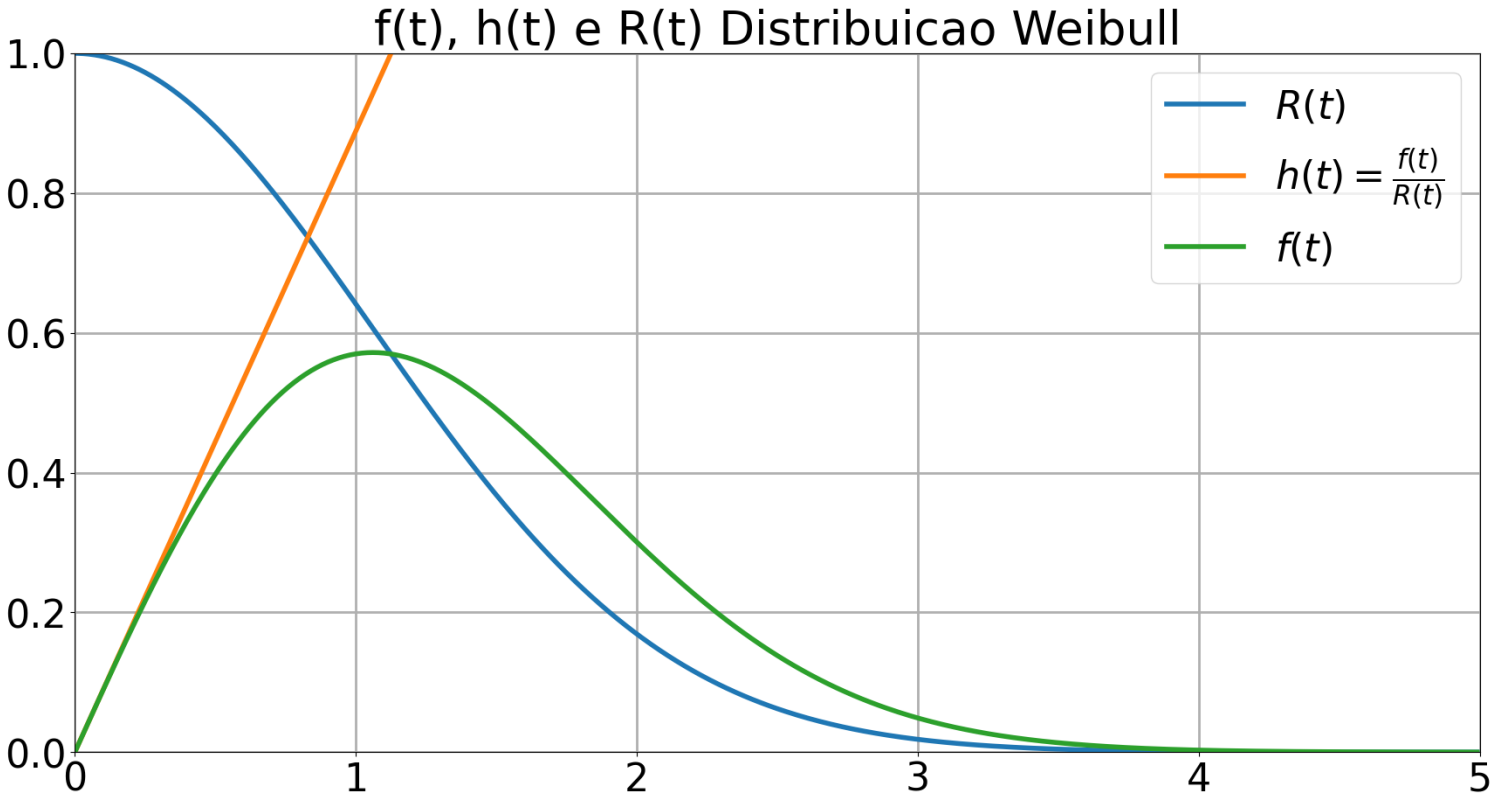
Exemplo de $\hat{F}$ para uma Normal Padrão $\mathcal{N}(0,1)$ com $n = 30$:



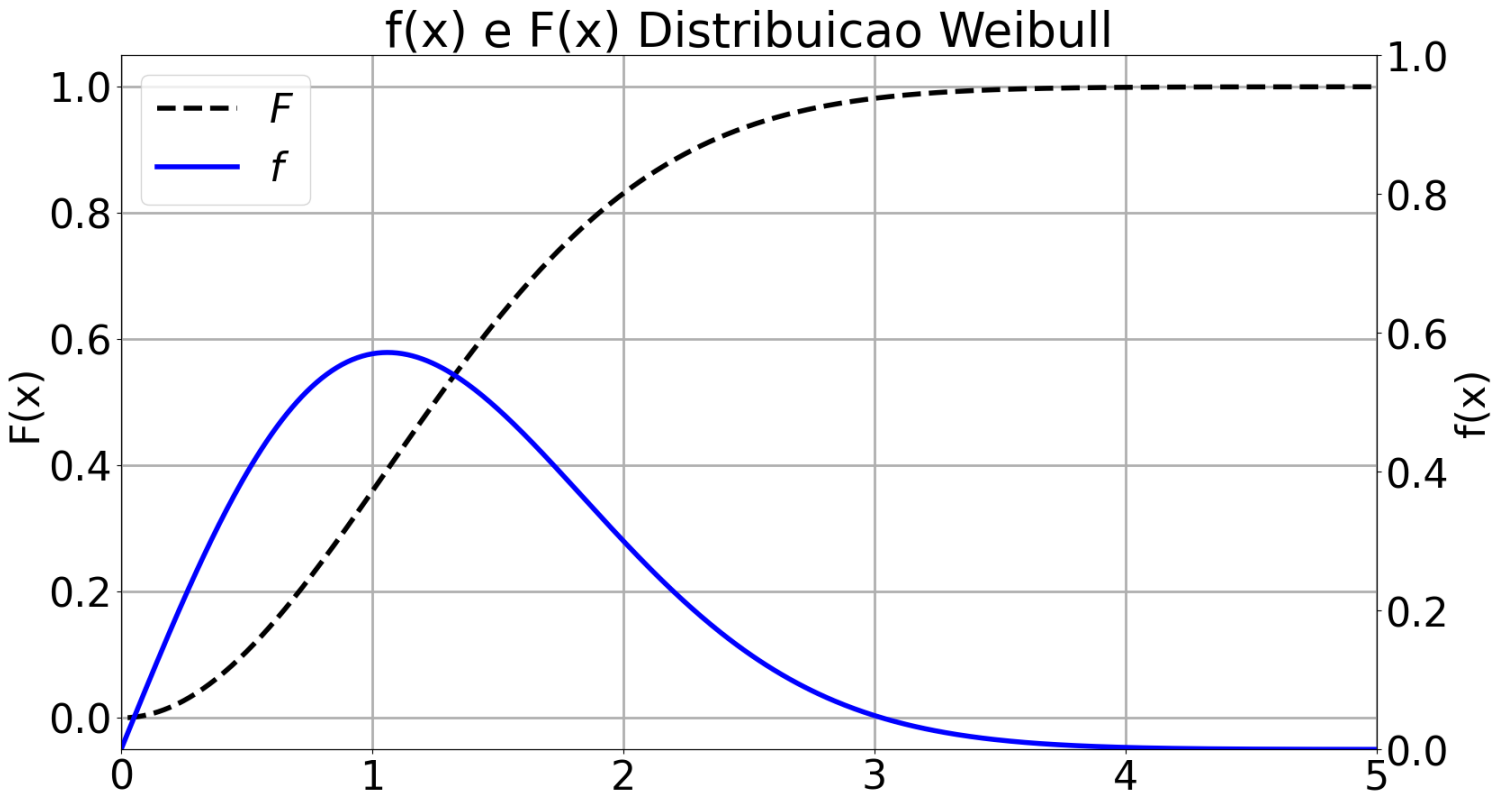
Exemplo de $\hat{F}$ para uma Normal Padrão $\mathcal{N}(0,1)$ com $n = 100$:



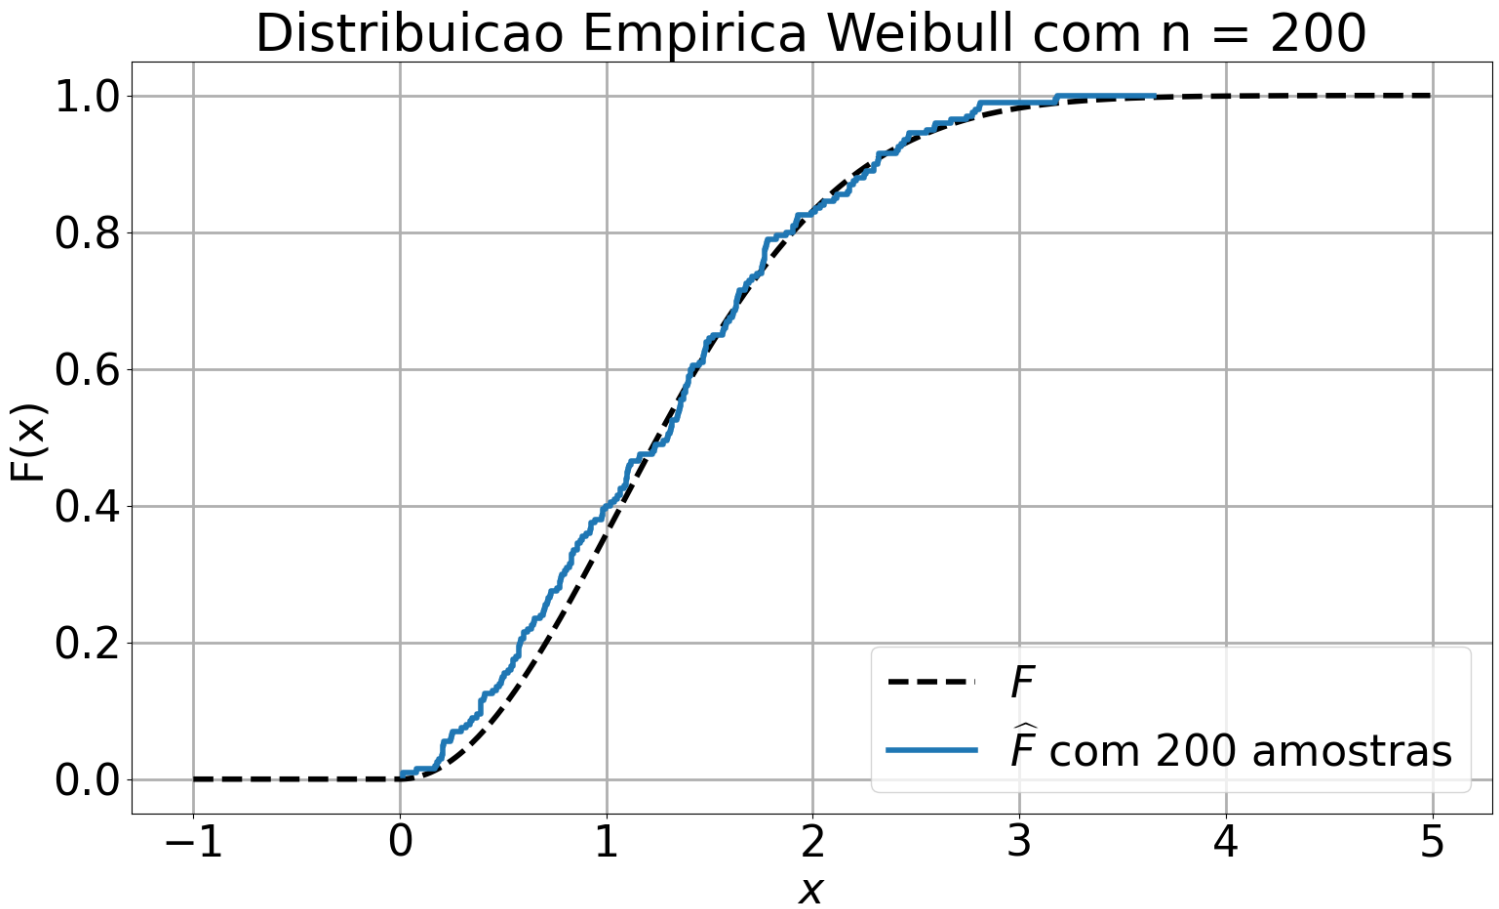
Vamos considerar a $f(x)$ e a $F(x)$ de uma Weibull com $\beta = 2$ e $\eta = 1.5$:



Exemplo de F para uma Weibull com $\beta = 2$ e $\eta = 1.5$:



Exemplo de $\hat{F}$ para uma Weibull com $\beta = 2$ e $\eta = 1.5$:



A **reamostragem não paramétrica** consiste em realizar a reamostragem através do processo de **sorteio com reposição** utilizando as observações em **x**.

A **reamostragem** é feita **com reposição** para que as amostras sorteadas sejam iid.

Esse método é conhecido como ***Bootstrap* não Paramétrico**.

Começamos com:

- A população de interesse X;
- Amostra aleatória (iid) $\mathbf{x} = \{x_1, x_2, \ldots, x_n\}$;
- O estimador de interesse $t = T(X)$;
- A estatística de interesse $\hat{t} = T(\mathbf{x})$.

Procedimento Padrão:

Dados $\mathbf{x} = \{x_1, x_2, \ldots, x_n\}$ e um critério de parada, e.g., R:

1. Para k de 1 até R:
   - 1.1 Realize o sorteio com reposição de n amostras de $\mathbf{x} = \{x_1, x_2, \ldots, x_n\}$, resultando em uma amostra aleatória $\mathbf{x}_k^*$;
   - 1.2 Calcule a estatística de interesse $\hat{t}_k^* = T(\mathbf{x}_k^*)$ e armazene.
2. Encontre $\hat{F}(\hat{t}^*)$ a partir dos R valores de $\hat{t}^*$

Podemos avaliar as características da estatística de interesse a partir de $\hat{F}(\hat{t}^*)$.

Problema: Definição de R.

Método exato, i.e., fazer todas as combinações possíveis em n amostras com reposição.

$$\binom{2n-1}{n}$$

n	N
5	1.26E+02
10	9.24E+04
20	6.89E+10
30	5.91E+16
40	5.38E+22
50	5.04E+28

Além do método exato, pode-se também adotar um critério de parada para o processo de reamostragem. Tal critério é, normalmente, associado à convergência do processo de reamostragem.

Uma forma de verificar a convergência é através de inspeção.

Outra forma é verificar se uma nova iteração não gera mudanças relevantes em alguma métrica, e.g., $|\bar{\hat{t}}_k^* - \bar{\hat{t}}_{k-1}^*| < \epsilon$. Se isso ocorrer, então foi observada a convergência.

Algumas informações sobre $\hat{F}(\hat{t}^*)$:

- **Forma**: a forma da distribuição empírica obtida no bootstrap se aproxima da forma da distribuição da estatística considerada a medida que $R \to \infty$.
- **Tendência central**: a estimativa tende a ser polarizada (tendenciosa) caso a distribuição da amostra **x** não esteja centrada no valor real do parâmetro.
- **Dispersão**: o erro padrão da estatística é o desvio padrão da distribuição do bootstrap.

$$se(\hat{t}) = \sqrt{\frac{\sum_{i=1}^{R}(t_i^* - \bar{t}^*)^2}{R-1}}$$

Observações importantes sobre o Bootstrap Não Paramétrico:

- O método de *bootstrap* não tem a capacidade de gerar novos dados;
- O método **estima** como a **estatística amostral** varia considerando as n observações disponíveis;
- Não depende de **normalidade** ou do **TCL**;

Vantagens:

- Simplicidade;
- Aplicável em casos complexos;
- Independente de premissas relativas a distribuições

Desvantagens:

- Alta demanda computacional[1];
- Estimativa geralmente otimista;
- Duas fontes de imprecisão, amostra aleatória e o conjunto de iterações do bootstrapping.

[1] Poder computacional crescente e cada vez mais acessível.

Quando utilizar o Bootstrap:

- Distribuição teórica da estatística de interesse é não-trivial;
- Não existe um modelo disponível;
- As amostras não permitem inferência direta:
  - Poucas amostras
  - **Não atendem às premissas.**

Intervalos de Confiança via *Bootstrap*

Relembrando: Um IC é o intervalo que, com uma dada probabilidade (nível de confiança), iremos observar o valor do parâmetro populacional de interesse.

$$P(L \leq \mu \leq U) = 1 - \alpha, \quad 0 \leq \alpha \leq 1$$

Então, existe uma probabilidade de $1 - \alpha$ de que, para uma nova amostra aleatória, uma estimativa ,por exemplo de μ, que será uma $\overline{\mathbf{X}}$, esteja contida no intervalo de confiança $[L, U]$.

Caso tenhamos uma **Distribuição Normal com Variância Conhecida**:

$$\overline{X} - z_{\alpha/2}\frac{\sigma}{\sqrt{n}} \leq \mu \leq \overline{X} + z_{\alpha/2}\frac{\sigma}{\sqrt{n}}$$

Apenas se os dados atenderem as **premissas**.

Vimos que através de uma reamostragem não paramétrica (sorteio com reposição) de $\mathbf{x}$, obtemos R amostras aleatórias $\mathbf{x}_k^*$.

Estimativa do IC (1-α) via bootstrap não paramétrico:

Dados $\mathbf{x}$ e o critério de parada:

1. Enquanto o critério de parada não for atendido:
   1.1. Realize o sorteio com reposição de n amostras de $\mathbf{x}$, resultando em uma amostra aleatória $\mathbf{x}_k^*$
   1.2 Calcule a estatística de interesse $\hat{t}_k^* = T(\mathbf{x}_k^*)$ e armazene;
2. Encontre $\hat{F}(\hat{t}^*)$ a partir dos valores observados $\hat{t}_k^*$.
3. Estime os percentis da $\hat{F}(\hat{t}^*)$ de acordo com o tipo de IC desejado e o nível de significância α.

O intervalo de $(1-\alpha)$ de confiança é obtido através dos percentis da distribuição $\hat{F}(\hat{t}^*)$ e de acordo com o tipo do intervalo:

- Bilateral: $\left[\hat{F}^{-1}(\alpha/2);\ \hat{F}^{-1}(1-\alpha/2)\right]$
- Unilateral Superior: $\left[-\infty;\ \hat{F}^{-1}(1-\alpha)\right]$
- Unilateral Inferior: $\left[\hat{F}^{-1}(\alpha);\ \infty\right]$

onde $\hat{F}^{-1}(\alpha)$ é o argumento que resulta no percentil α da distribuição empírica do estimador obtida via bootstrapping.

Ver o script *6_2_IC_Bootstrap.py*.

Testes de Hipóteses por *Bootstrap*

O objetivo de um Teste de Hipótese é inferir se os dados sustentam uma afirmação, a qual é chamada de Hipótese nula H_0.

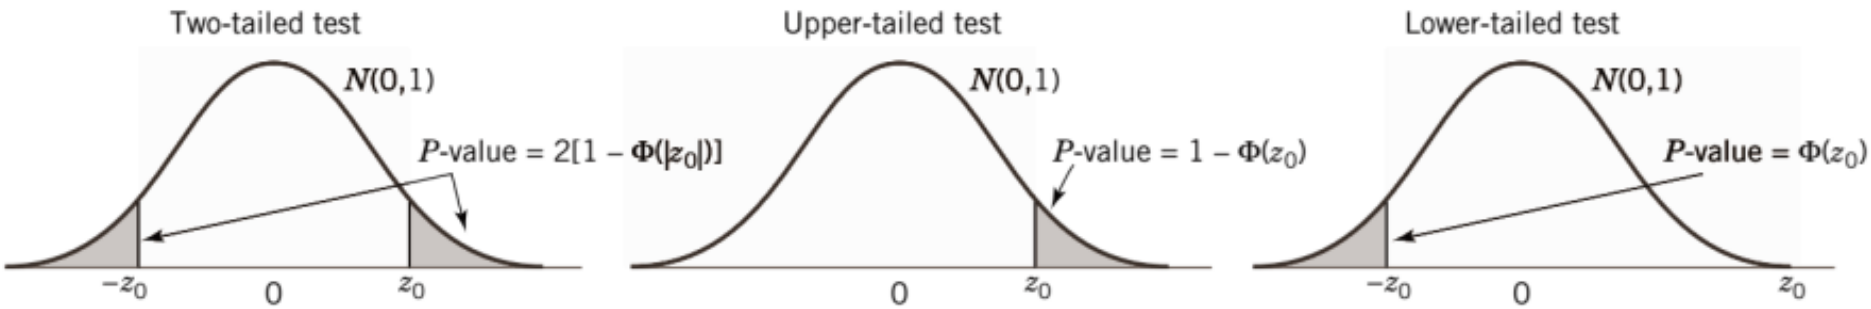
$$\text{p-valor} = P(T \geq t | H_0)$$

Quando os dados não sustentam H_0, i.e., o p-valor é inferior ao limiar α, essa hipótese é rejeitada e afirmamos que a Hipótese alternativa H_1 é mais plausível de acordo com as evidências.

Relembrando para o caso de Distribuição Normal e variância conhecida:

$$H_0 : \mu = \mu_0 \quad H_0 : \mu = \mu_0 \quad H_0 : \mu = \mu_0$$
$$H_1 : \mu \neq \mu_0 \quad H_1 : \mu > \mu_0 \quad H_1 : \mu < \mu_0$$

$$z_0 = \frac{\overline{X} - \mu_0}{\sigma / \sqrt{n}}$$



Utilizamos Testes não paramétricos quando a nossa **x** não atende às premissas dos testes paramétricos ou precisamos reforçar as conclusões de um teste paramétrico.

Os **testes não paramétricos**, também conhecidos como **métodos livres de distribuição**, não dependem da família da distribuição dos dados.

Um exemplo são os testes que utilizam o ranqueamento, ou posto, dos dados ordenados para o teste, como o Teste de Wilcoxon para comparar a medianas.

Aqui iremos falar de testes não paramétricos que utilizam de **reamostragem**.

Em situações onde as aproximações não se aplicam, ou os requisitos não são fortemente satisfeitos, podemos utilizar da reamostragem paramétrica.

Como queremos verificar $P(T \geq t|H_0)$, iremos realizar a reamostragem paramétrica utilizando o valor a ser testado, definido em H_0, e calcular t^*.

Tal método é conhecido como Teste de Monte Carlo.

Os R valores da estatística t obtidos a partir das reamostragens paramétricas são denotados como $t_1^*, t_2^*, \ldots, t_R^*$.

Caso H_0 seja um modelo aceitável frente os dados coletados $\mathbf{x}$, todos os $R+1$ valores de $t, t_1^*, t_2^*, \ldots, t_R^*$, são valores equiprováveis de T.

Uma forma de estimar o p-valor a partir das observações simuladas de t^* é:

$$\text{p-valor} = P(T \geq t|H_0) = \frac{K+1}{R+1}$$

onde K é o número de observações amostradas $\{t_1^*, t_2^*, \ldots, t_R^*\}$ que excedem t.

Numericamente temos para um **teste bilateral**[2]:

$$\text{p-valor} = \frac{\#\{|t^* - t_0| \geq |t - t_0|\} + 1}{R+1}$$

O número de amostragens R é muito importante, se o $R \to \infty$ encontramos o p-valor exato.

Deve-se utilizar pelo menos $R = 99$. Na prática adotamos valores maiores, como $R = 999$ ou 9999.

[2] $H_1 : t \neq t_0$

Vamos revisitar o exemplo da aula de inferência estatística.

Especificações exigem que a taxa média de consumo de um combustível deve ser de 50 ml/s.

Sabemos também que o desvio padrão desse consumo é $\sigma = 2$ ml/s.

O experimentador decide especificar uma probabilidade de Erro do Tipo I ou nível de significância de $\alpha = 0.05$ e seleciona uma amostra aleatória de tamanho $n = 25$.

Observou-se um consumo médio amostral de $\overline{X} = 51.3$ ml/s.

Que conclusões devem ser tiradas?

Exemplo: Parâmetro de Interesse: μ (consumo médio);

Hipótese nula: $\mu = 50$;

Hipótese alternativa: $\mu \neq 50$;

Estatística de teste: $z_0 = \frac{\overline{X} - \mu_0}{\sigma/\sqrt{n}} = \frac{51.3-50}{2/\sqrt{25}} = 3.25$

Rejeitar H_0 se o p-valor for menor que $\alpha = 0.05$.

p-valor$= 2[1 - \phi(3.25)] = 0.0012$

Como p-valor$< \alpha$, então **podemos rejeitar** H_0 com 0.05 de significância.

Vamos resolver por reamostragem paramétrica:

$H_0 : \mu = 50, \sigma = 2, t = 51.3$ e $n = 25$.

Realizaremos R reamostragens paramétricas utilizando a hipótese a ser testada definida por H_0, neste caso $\mathcal{N}(50, 4)$, e calculamos R estimativas da estatística de interesse t^*.

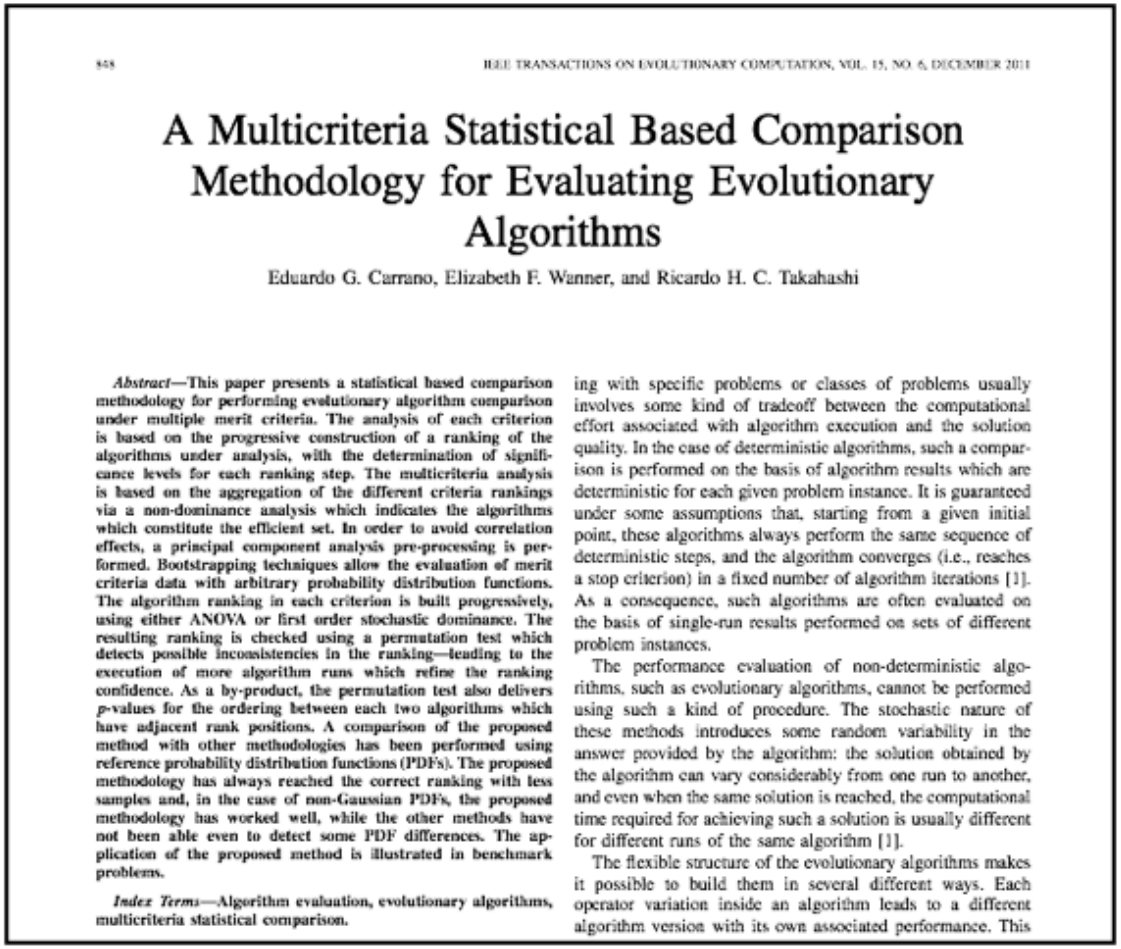
Devemos rejeitar H_0 com α de significância se o p-valor:

$$\text{p-valor} = \frac{\#\{|t^* - \mu_0| \geq |t - \mu_0|\} + 1}{R + 1}$$

For menor do que $\alpha = 0.05$.

Ver o script *6_3_Teste_Reamostragem_Parametrica.py*.

Exemplos de Aplicação: Comparação de algoritmos evolutivos.



848 IEEE TRANSACTIONS ON EVOLUTIONARY COMPUTATION, VOL. 15, NO. 6, DECEMBER 2011

A Multicriteria Statistical Based Comparison Methodology for Evaluating Evolutionary Algorithms

Eduardo G. Carrano, Elizabeth F. Wanner, and Ricardo H. C. Takahashi

Abstract—This paper presents a statistical based comparison methodology for performing evolutionary algorithm comparison under multiple merit criteria. The analysis of each criterion is based on the progressive construction of a ranking of the algorithms under analysis, with the determination of significance levels for each ranking step. The multicriteria analysis is based on the aggregation of the different criteria rankings via a non-dominance analysis which indicates the algorithms which constitute the efficient set. In order to avoid correlation effects, a principal component analysis pre-processing is performed. Bootstrapping techniques allow the evaluation of merit criteria data with arbitrary probability distribution functions. The algorithm ranking in each criterion is built progressively, using either ANOVA or first order stochastic dominance. The resulting ranking is checked using a permutation test which detects possible inconsistencies in the ranking—leading to the execution of more algorithm runs which refine the ranking confidence. As a by-product, the permutation test also delivers *p*-values for the ordering between each two algorithms which have adjacent rank positions. A comparison of the proposed method with other methodologies has been performed using reference probability distribution functions (PDFs). The proposed methodology has always reached the correct ranking with less samples and, in the case of non-Gaussian PDFs, the proposed methodology has worked well, while the other methods have not been able even to detect some PDF differences. The application of the proposed method is illustrated in benchmark problems.

Index Terms—Algorithm evaluation, evolutionary algorithms, multicriteria statistical comparison.

ing with specific problems or classes of problems usually involves some kind of tradeoff between the computational effort associated with algorithm execution and the solution quality. In the case of deterministic algorithms, such a comparison is performed on the basis of algorithm results which are deterministic for each given problem instance. It is guaranteed under some assumptions that, starting from a given initial point, these algorithms always perform the same sequence of deterministic steps, and the algorithm converges (i.e., reaches a stop criterion) in a fixed number of algorithm iterations [1]. As a consequence, such algorithms are often evaluated on the basis of single-run results performed on sets of different problem instances.

The performance evaluation of non-deterministic algorithms, such as evolutionary algorithms, cannot be performed using such a kind of procedure. The stochastic nature of these methods introduces some random variability in the answer provided by the algorithm: the solution obtained by the algorithm can vary considerably from one run to another, and even when the same solution is reached, the computational time required for achieving such a solution is usually different for different runs of the same algorithm [1].

The flexible structure of the evolutionary algorithms makes it possible to build them in several different ways. Each operator variation inside an algorithm leads to a different algorithm version with its own associated performance. This

IEEE Transactions on Evolutionary Computation
Vol. 15
No. 6
pp. 848-870
December, 2011

Referências

Referências bibliográficas



Efron, B. (1979). *Bootstrap Methods: Another Look at the Jackknife*. The Annals of Statistics, 7.1, pp. 1-26.



DiCiccio, T. D. and Efron, B. (1996). *Bootstrap confidence intervals*. Statistical Science, pp. 189-228.



Davison, A. C. and Hinkley, D. (2006). *Bootstrap Methods and their Application*. Cambridge Series in Statistical and Probabilistic Mathematics, 8th ed..



Moore, D. S., G. P. MacCabe and B. Craig (2012). *Introduction to the Practice of Statistics*. W. H. Freeman, 7th ed.