EEE 017 Confiabilidade de Sistemas

7 - Simulação de Monte Carlo

Michel Bessani
https://orcslab.github.io/
Departamento de Engenharia Elétrica - DEE

Engenharia de Sistemas



Belo Horizonte

Sumário

1. Introdução
2. Funcionamento
2.1 Distribuições Usuais
2.2 Abordagem Geral
2.3 Número de Simulações
2.4 Vantagens e Desvantagens
2.5 Exemplo de Aplicação Prática
3. Considerações Finais
4. Referências

Introdução

A simulação de Monte Carlo foi desenvolvida na década de 40, durante a WWII, como ferramenta probabilística para investigar o funcionamento de armas nucleares (projeto Manhattan).

Foi batizada com este nome em homenagem ao casino de Monte Carlo.

Para maiores detalhes históricos, veja Harrison RL. *Introduction to monte carlo simulation*. In AIP conference proceedings 2010 Jan 5 (Vol. 1204, No. 1, pp. 17-21). AIP.

A simulação de Monte Carlo é útil para a análise do comportamento de sistemas sujeitos a incertezas em seus parâmetros de entrada:

- Tempo até a ocorrência de eventos, falhas no caso da Confiabilidade;
- Duração de atividades, como a de reparo;
- Comportamento da geração e da carga em sistemas energéticos;
- Entradas e demandas em cadeias logísticas;
- Condições ambientais em estruturas;
- Turbulências atmosféricas em sistemas aeronáuticos;
- Variações de mercado em carteiras de investimento.

Funcionamento

A ideia central é, realizar uma **amostragem** das variáveis aleatórias que representem as incertezas nas **entradas** do sistema:

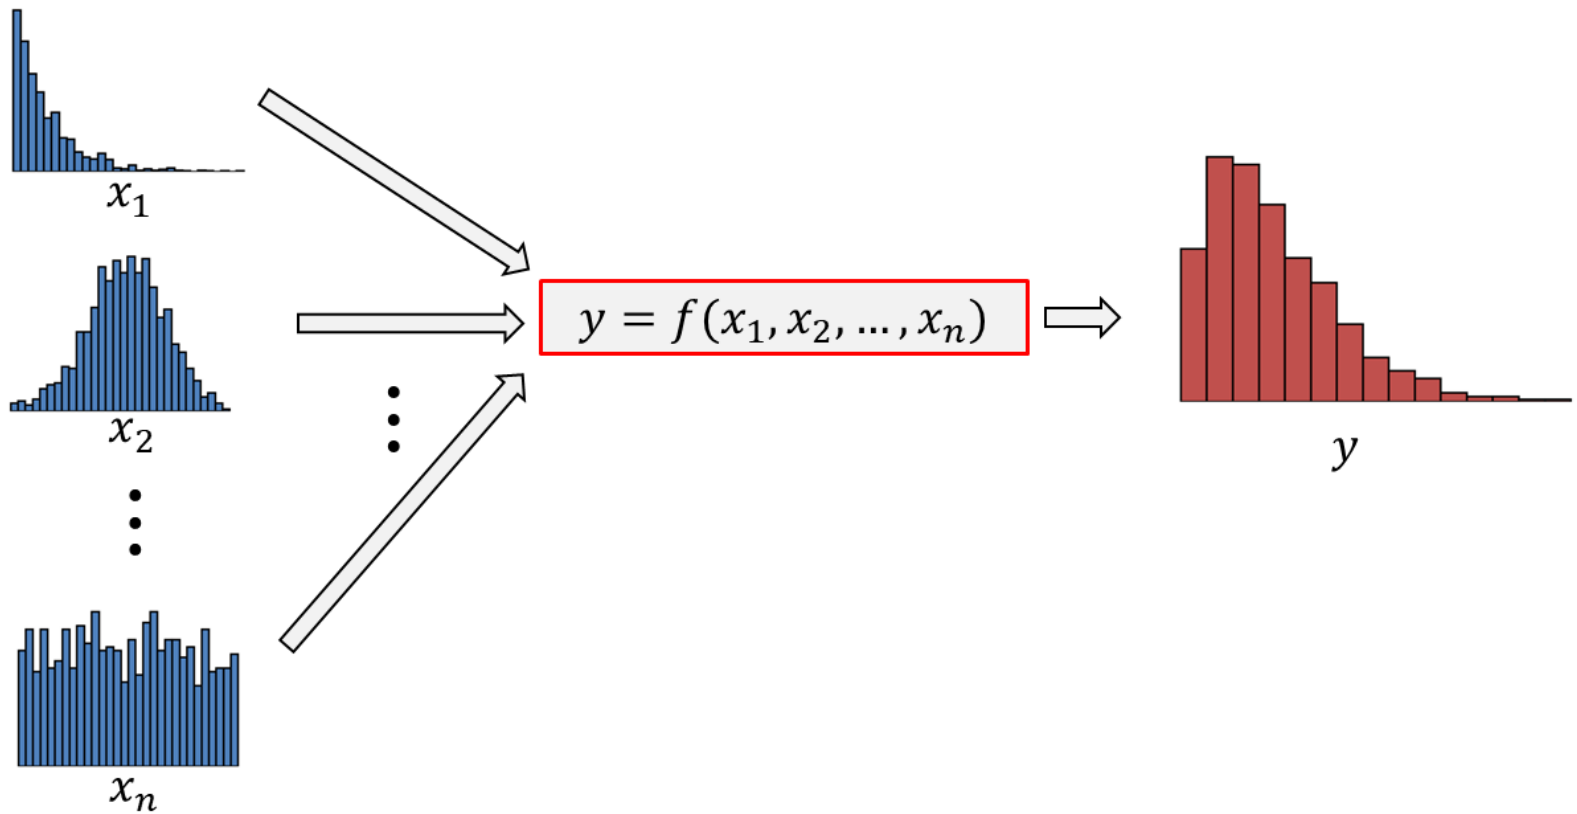
- Dadas as n entradas do sistema, $\{X_1, X_2, \ldots, X_n\}$ e suas respectivas distribuições de probabilidade, $f_{X_1}, f_{X_2}, \ldots, f_{X_n}$, deve-se gerar observações iid para cada entrada.

Em seguida, deve-se **avaliar** o **comportamento** do sistema para as entradas amostradas:

- Para cada conjunto i de observações, avaliar como será o comportamento da saída do sistema, $y^{(i)} = f(x_1^{(i)}, x_2^{(i)}, \ldots, x_n^{(i)})$.

Este processo é repetido até se atingir um critério de parada.

Avaliação da resposta do sistema (y) de acordo com o comportamento das entradas aleatórias $\{x_1, \ldots, x_n\}$ obtida por meio de amostragens:



Distribuições Usuais

São necessários modelos de distribuição de probabilidade para as entradas.

Já vimos:

- Normal;
- Lognormal;
- Weibull;
- Exponencial;
- Valores Extremos.

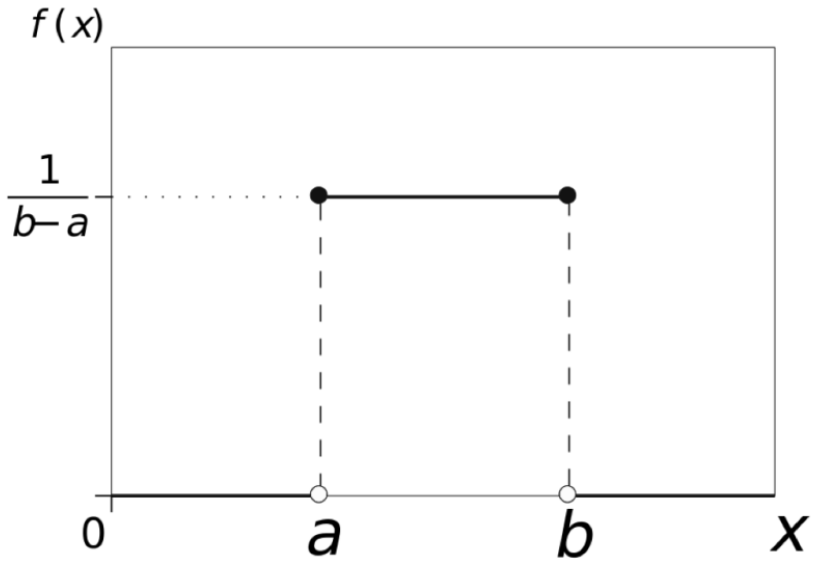
Existem mais duas distribuições que são muito importantes para a simulação de Monte Carlo:

- Uniforme;
- Triangular.

Distribuição Uniforme: Possui probabilidade constante no intervalo $[a,\ b]$:

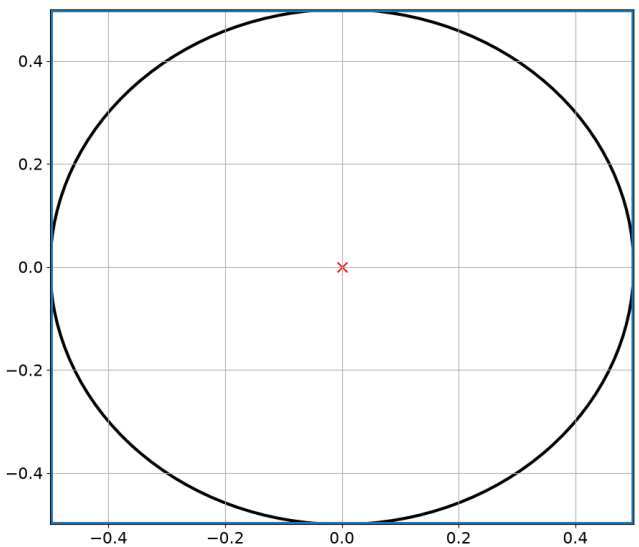
Útil quando sabemos apenas os valores máximos e mínimos de um processo com comportamento aleatório.

$$f(x) = \begin{cases} \dfrac{1}{b-a}, & a \leq x \leq b \\ 0, & c.c. \end{cases}$$



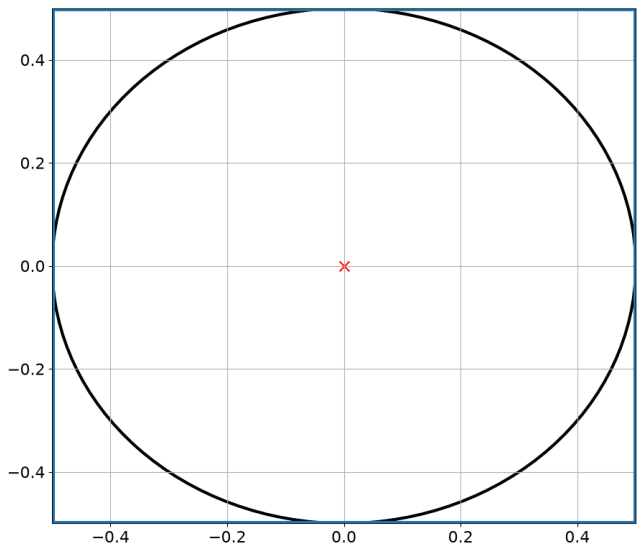
Exemplo de Aplicação da Distribuição Uniforme: Vamos estimar o valor de π numericamente.

Suponha um círculo de raio 0.5 inscrito em um quadrado de lado 1, ambos centrados em $(0,\ 0)$. Sabemos que a área do quadrado é $l^2 = 1$ e a área do círculo é $\pi r^2 = 0.25\pi$.



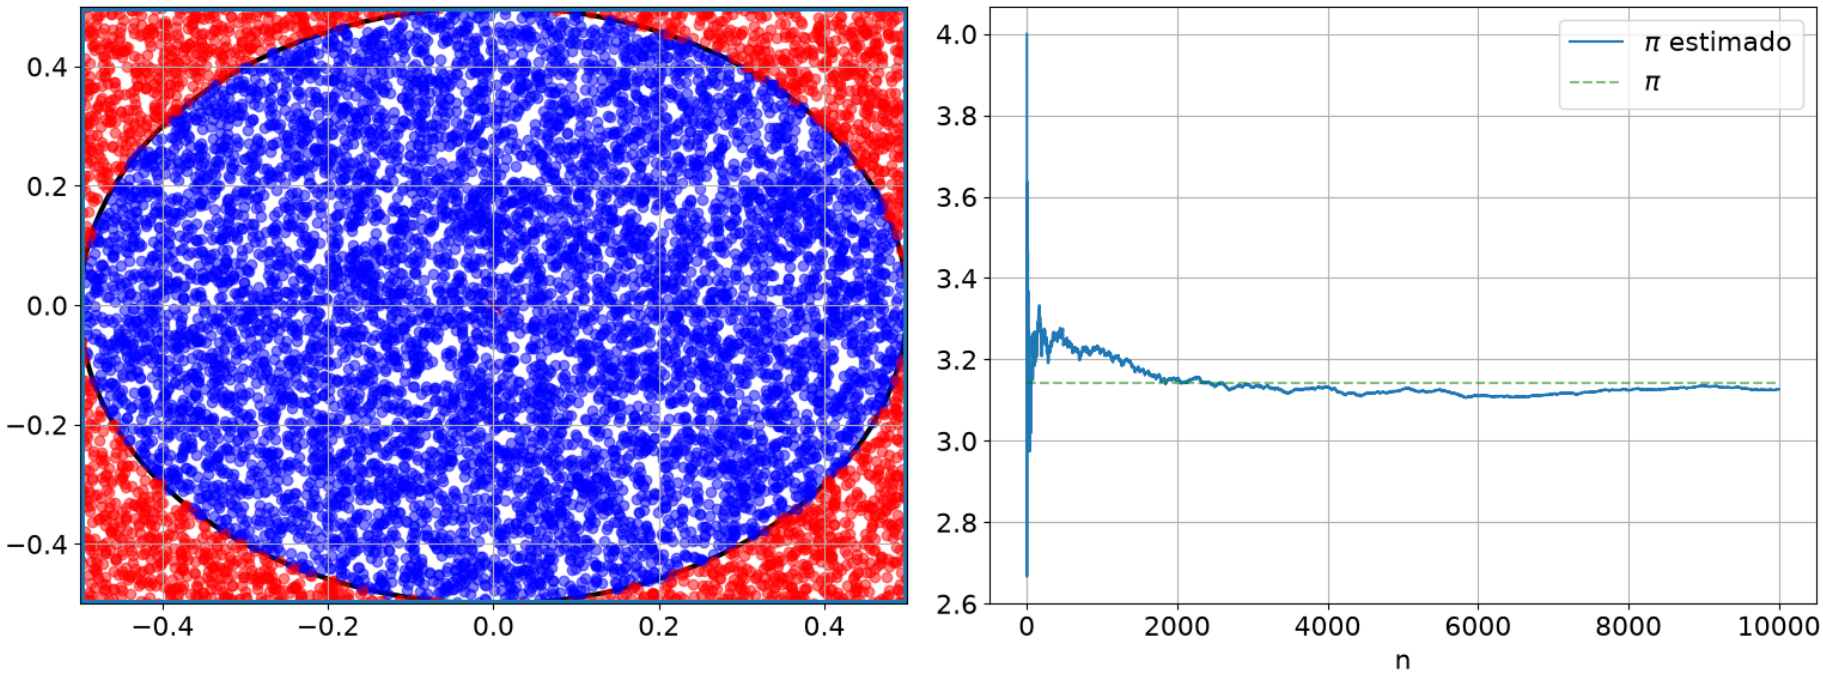
Sorteamos N números aleatórios internos ao quadrado e armazenamos a quantidade desses números que também são internos ao círculo (c).

A proporção entre c e N é a mesma que a proporção entre a área do círculo e a área do quadrado.



Podemos escrever $c/N = \pi r^2/l^2$, como $l = 2r$, então $c/N = \pi/4$ e chegamos que $\pi = 4c/N$.

Estimativa com $N = 10000$:

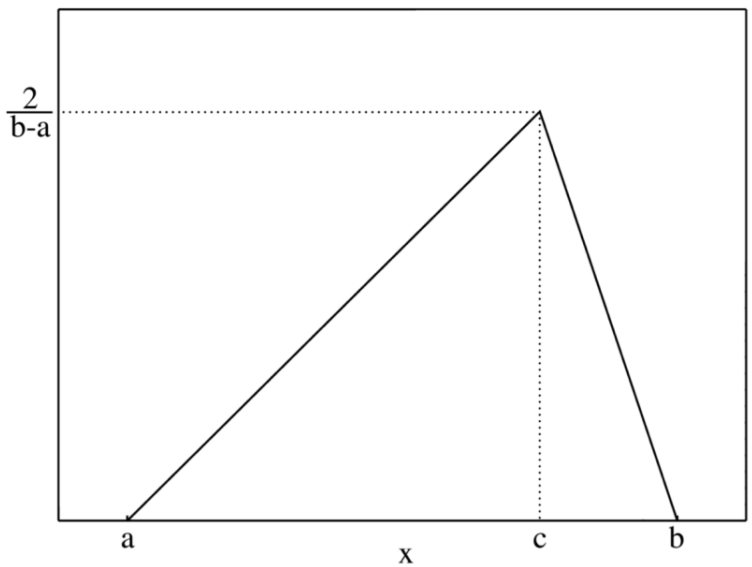


Ver o script *7_1_MC_pi.py*.

Distribuição Triangular: Útil para se definir uma distribuição aproximada.

Possui três parâmetros, um valor mínimo (a), máximo (b) e um mais provável (c).

$$f(x) = \begin{cases} \dfrac{2(x-a)}{(b-a)(c-a)}, & se\ a \leq x \leq c \\ \dfrac{2(b-x)}{(b-a)(b-c)}, & se\ c \leq x \leq b \\ 0, \quad c.c. \end{cases}$$



Com $c = (a+b)/2$ a distribuição triangular se torna simétrica.

Abordagem Geral

1. Definição do problema e do **objetivo** da análise;
2. Definição do **modelo** $y = f(x_1, x_2, \ldots, x_n)$;
3. Projetar a **simulação**, i.e., distribuições de probabilidade das entradas, número de simulações N ou outro critério de parada;
4. Para $i \in \{1, \ldots, N\}$ ou outro **critério de parada**:
   4.1. **Amostrar** as n entradas a partir das suas respectivas distribuições de probabilidade $\{x_1^{(i)}, x_2^{(i)}, \ldots, x_n^{(i)}\}$;
   4.2. **Calcular** o valor de $y^{(i)}$ utilizando o modelo $y^{(i)} = f(x_1^{(i)}, x_2^{(i)}, \ldots, x_n^{(i)})$ e armazene o resultado;
5. **Analisar** os valores de $y^{(i)}$ observados de acordo com o **objetivo** da análise.

Pode-se usar média, desvio padrão, intervalos de confiança, histograma, distribuição ajustada, quartis, entre outras estatísticas e visualizações.

Exemplo: Problema do sistema redundante com componentes dependentes (Exercício 2 - Aula 2e).

Dois componentes possuem probabilidade de funcionar de 0.85. Se um deles falhar, o segundo terá probabilidade de falhar de 0.2.

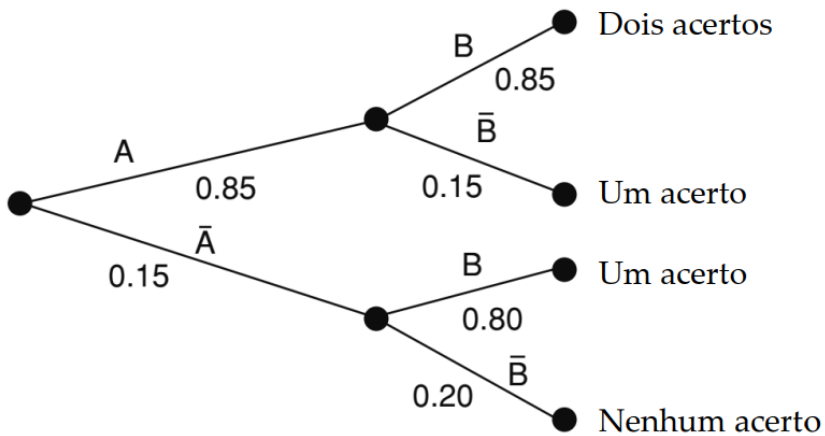
Qual a probabilidade de ao menos um componente funcionar?

$$P(A\overline{B}) + P(\overline{A}B) + P(AB)$$

$$P(A)P(\overline{B}|A) + P(\overline{A})P(B|\overline{A}) + P(A)P(B|A)$$

$$0.85 \times 0.15 + 0.15 \times 0.80 + 0.85 \times 0.85$$

$$0.1275 + 0.12 + 0.7225 = 0.97$$



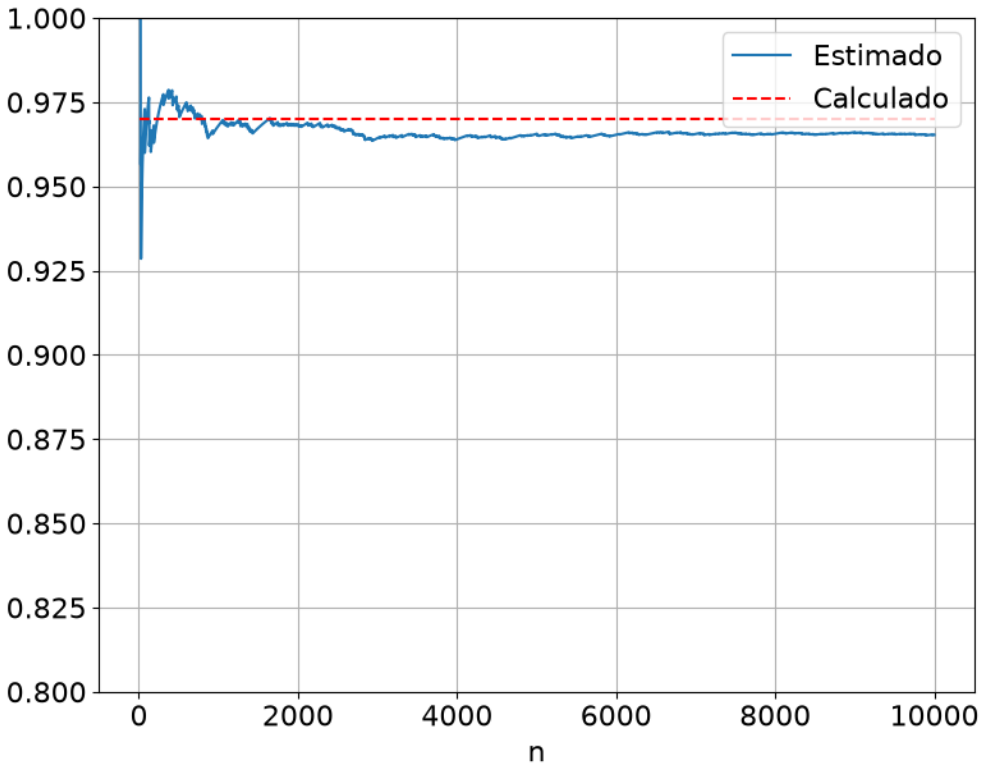
Como resolver através de Simulação de Monte Carlo?

1. Problema: Ao menos um componente funcionar;
2. Modelo: Se A falhar com $P(\overline{A}) = 0.15$, B pode funcionar com $P(B) = 0.8$;
3. Distribuição uniforme, $U(0,1)$ e $N = 10000$;
4. Para $i = 1$ até N:
   - 4.1. Amostre uma observação de entradas $\{x_A^{(i)}, x_B^{(i)}\}$ utilizando $P(A)$ e $P(B)$;
   - 4.2. Avalie se ocorreu ao menos um funcionamento, $y^{(i)} = 1$, utilizando $\{x_A^{(i)}, x_B^{(i)}\}$ e armazene;
5. Estime a probabilidade de ao menos um funcionar.

Ver o script *7_2_MC_sistema_dependencia.py*.

Exemplo: Problema do sistema redundante com componentes dependentes (Exercício 2 - Aula 2e).

Dois componentes paralelos possuem probabilidade de funcionar 0.85. Se o primeiro falhar, o segundo terá probabilidade de falhar 0.2. Qual a probabilidade do sistema funcionar?



Número de Simulações

Não há uma forma universal de definir o número de simulações N necessárias para obtermos uma acurácia pré-definida.

O N, também chamado de número de experimentos, número de execuções, número de iterações ou tamanho da amostra. Dependerá de:

- Complexidade do sistema (processo) simulado;
- Variabilidade das entradas;
- Precisão ou erro desejado.

Pode-se utilizar a acurácia da estimativa como critério de parada.

A estimativa de valores médios tende a ter acurácia maior que a estimação de comportamentos extremos para um mesmo tamanho amostral, e para a média, podemos estimar o **erro padrão da média**:

$$se(\hat{\mu}_y) = \frac{\hat{\sigma}_y Z_{\alpha/2}}{\sqrt{N}}$$

onde $\hat{\mu}_y$ e $\hat{\sigma}_y$ são, respectivamente, a média e o desvio padrão das N respostas y do sistema, $Z_{\alpha/2}$ é o valor da normal padrão que resulta em $\Phi(Z) = 1 - \alpha/2$ e $\alpha = 1 - C$, e C é o nível de confiança.

Outra estimativa interessante é o **Coeficiente de Variação** do valor médio após as N simulações:

$$CV = \frac{\hat{\sigma}_y}{\hat{\mu}_y \sqrt{N}}$$

Vantagens e Desvantagens

Vantagens:

- Simples conceitualmente;
- Simples computacionalmente;
- Útil para processos que possuem elevado nível de incerteza;
- Permite considerar diversas interações presentes no sistema;
- Fácil compreensão por tomadores de decisão;
- Fácil análise do efeito das premissas consideradas.

Desvantagens:

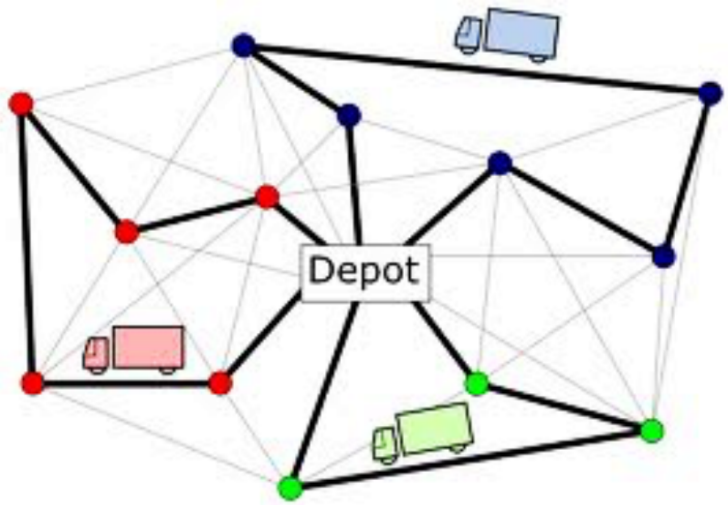
- Custo computacionall[1];
- Métodos tradicionais de Monte Carlo assumem que as entradas são todas independentes, o que pode gerar um viés nos resultados obtidos;
- Algoritmos se tornam complicados à medida que aumenta o detalhamento e a complexidade dos problemas;
- Forte dependência dos modelos assumidos para as entradas.

[1] Poder computacional crescente e cada vez mais acessível.

Exemplo de Aplicação Prática

Problema de Roteamento de Veículos (VRP) – É um problema clássico de otimização combinatória com várias aplicações reais.

Consiste de um **conjunto de veículos** que **partem** de um **depósito** e devem atender um **conjunto de clientes** e **retornarem** ao **depósito**.



Um dos possíveis objetivos do VRP é encontrar as rotas com o menor custo possível, normalmente assume-se o tempo da rota como custo.

Restrições comuns do problema incluem:

- Capacidade dos veículos;
- Janelas de atendimento;
- jornada de trabalho da equipe;
- ...

Existe uma variante do problema para casos onde se considera a **incerteza nos tempos** de viagem e de serviço.

Neste caso, podemos considerar que uma **falha no roteamento** ocorre em uma rota sempre que pelo menos uma das **restrições é violada**.

Considerando para uma instância do VRP:

- Uma rota já estabelecida;
- A jornada de trabalho das equipes em cada veículo;
- Distribuições de probabilidade conhecidas para os tempos de viagem e serviço.

Como estimar a chance de falha usando de Simulação de Monte Carlo?

Vamos estimar a probabilidade da rota resultar em uma violação das restrições, i.e., ocorrer uma falha, dada a aleatoriedade dos tempos.

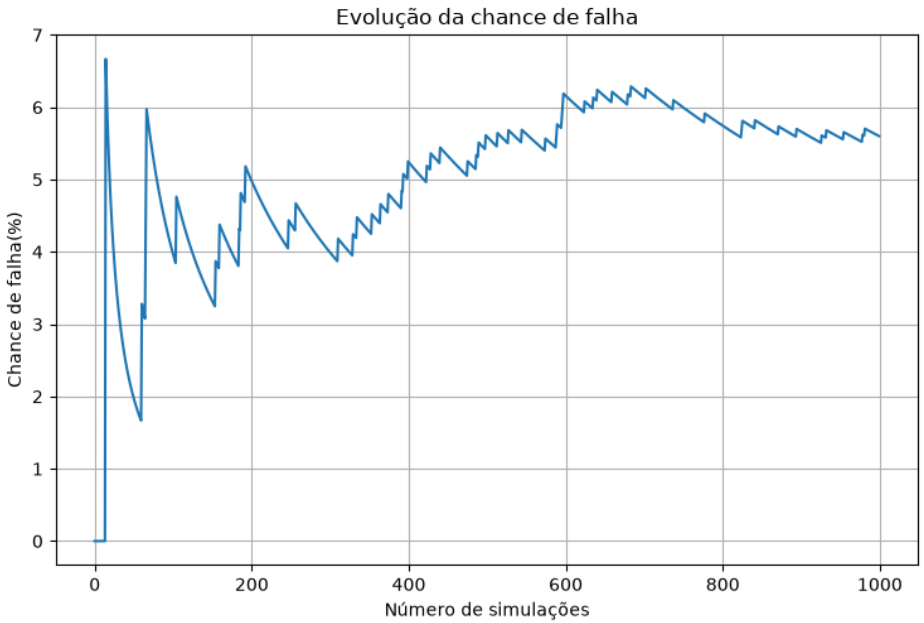
Temos uma rota com 7 clientes, jornada de trabalho de 8 h e os tempos de viagem e serviço seguem distribuições log-normais, a chance de falha é estimada da seguinte forma:

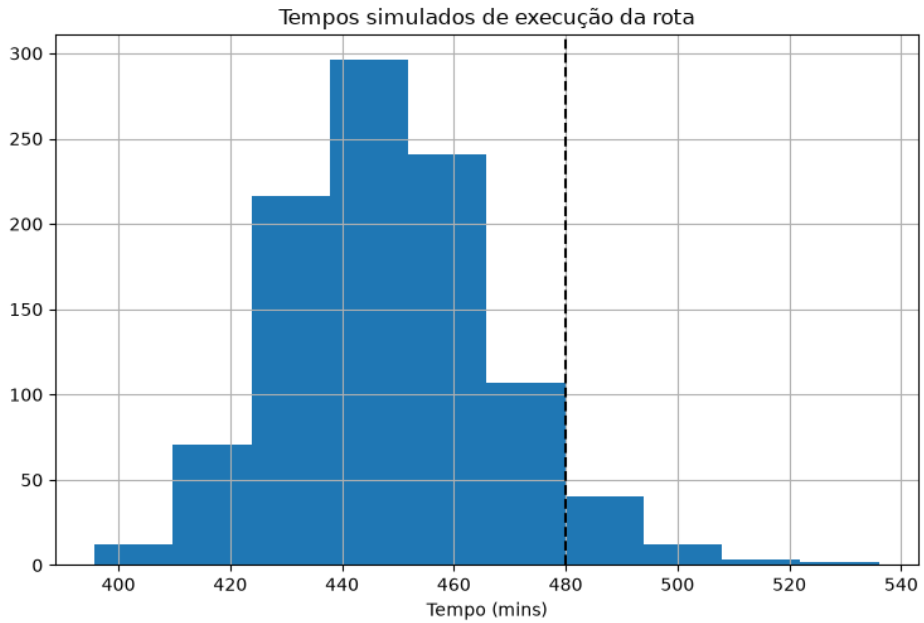
1. Problema: Atender todos os clientes e retornar ao depósito dentro da jornada de trabalho de 8h;
2. Modelo: Somatório de todos os tempos de viagem e de serviço para cada veículo;
3. Viagens com parâmetros específicos da Distribuição log-normal;
4. Para $i = 1$ até N:
   4.1. Amostre um tempo aleatório para cada viagem e serviço;
   4.2. Avalie se a rota respeita o limite de tempo e armazene;
5. Estime a probabilidade de falha para as N simulações.

Ver o script *7_3_MC_VRP.py*.

Considerando uma rota com 7 clientes, jornada de trabalho de 8 h e assumindo que os tempos de viagem e serviço sigam distribuições lognormais, qual a chance de falha na rota?

Estimação através de Simulação de Monte Carlo:





Considerações Finais

O método de Monte Carlo apresentado aqui é a versão mais simples, sendo útil para:

- Estimativa de integrais (cálculo da área);
- Análise da probabilidade de ocorrência de eventos de interesse;
- Investigação do comportamento de sistemas sujeitos a incertezas.

Existem outras variações do método de Monte Carlo:

- Monte Carlo sequencial;
- Monte Carlo por partes;
- Método da Entropia Cruzada;
- Monte Carlo em Cadeias de Markov;
- Método da Enumeração Estocástica;
- Amostragem por Importância;
- Método do Hipercubo Latino;
- ...

Cada um desses métodos possui suas vantagens e desvantagens.

Referências

Referências

- O'Connor, Patrick, and Andre Kleyner. *Practical reliability engineering*. John Wiley & Sons, 2012.
- Harrison RL. *Introduction to monte carlo simulation*. In AIP conference proceedings 2010 Jan 5 (Vol. 1204, No. 1, pp. 17-21). AIP.
- Kroese, D. P.; Brereton, T.; Taimre, T.; Botev, Z. I. (2014). *Why the Monte Carlo method is so important today*. WIREs Comput Stat. 6 (6): 386–392.
- Zio, Enrico. *The Monte Carlo simulation method for system reliability and risk analysis*. Vol. 39. London: Springer, 2013.
- Billinton, Roy, and Wenyuan Li. *Reliability Assessment of Electric Power systems Using Monte Carlo Methods*. Springer, Boston, MA, 1994.
- Rubinstein, Reuven Y., and Dirk P. Kroese. *Simulation and the Monte Carlo method*. John Wiley & Sons, 2016.