EEE 017 Confiabilidade de Sistemas

9 - Predição da Confiabilidade (Parte III)

Michel Bessani

Operations Research and Complex Systems (ORCS) Lab.
https://orcslab.github.io/

Departamento de Engenharia Elétrica - DEE

UFMG
UNIVERSIDADE FEDERAL
DE MINAS GERAIS

Belo Horizonte

Sumário

1. Introdução
2. Métodos de Predição da Confiabilidade
2.1 Análise de Espaço de Estados
2.2 Inteligência Artificial
2.3 Outros Métodos
3. Considerações Finais
4. Referências

Introdução

Já vimos os seguintes métodos de predição da confiabilidade:

1. Utilização de normas;
2. Abordagem Top-Down;
3. Diagrama de blocos para sistemas não reparáveis;
4. Diagrama de blocos para sistemas reparáveis;
5. Confiabilidade por decomposição de diagrama de blocos;
6. Análise por Árvore de Falha.

Métodos de Predição da Confiabilidade

Métodos de Predição da Confiabilidade: Análise de Espaço de Estados

Assume-se que um sistema, ou parte dele, pode estar apenas em **dois estados**: *i)* em **falha** ou *ii)* sem falha, i.e., **disponível**.

É possível avaliar a probabilidade do sistema estar em um destes estados no futuro com base em uma análise de espaço de estados.

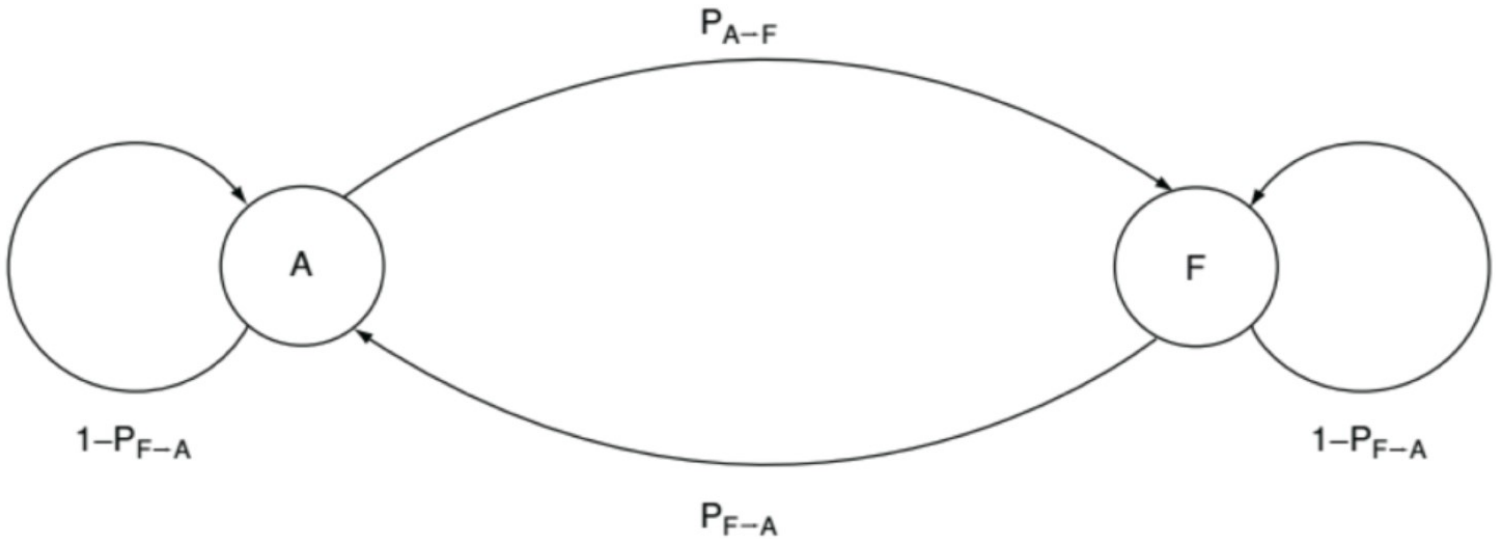
Um dos métodos mais conhecidos para realizar a análise em espaço de estados é a **Análise de Markov**, a qual segue as seguintes premissas:

- As probabilidades de transição de estados permanecem constantes (taxas de falha e reparo constantes).
- Estados futuros independem do histórico de estados anteriores, exceto do imediatamente precedente (toda manutenção leva o sistema a um estado de "como novo") - sistema sem memória.

Exemplo de um modelo de Markov discreto para um único elemento.

$P_{A \to F} = 0.1$

$P_{F \to A} = 0.6$



Como calcular a probabilidade do sistema estar em um dos estados após quatro intervalos de tempo?

Diagrama de Árvore

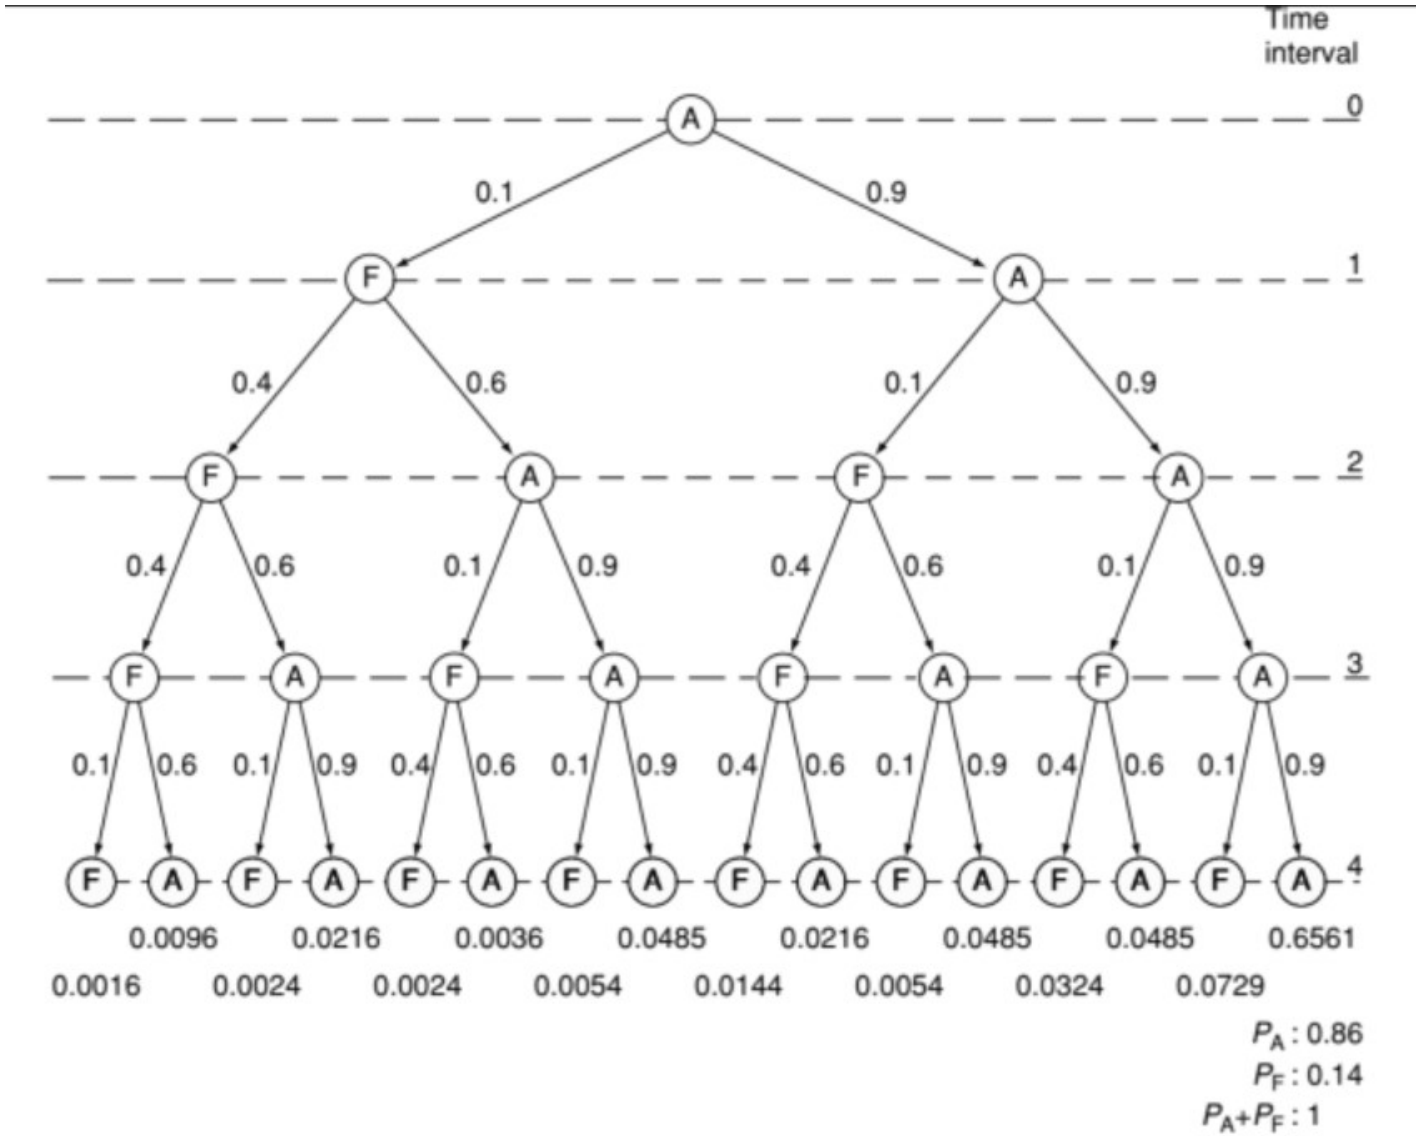
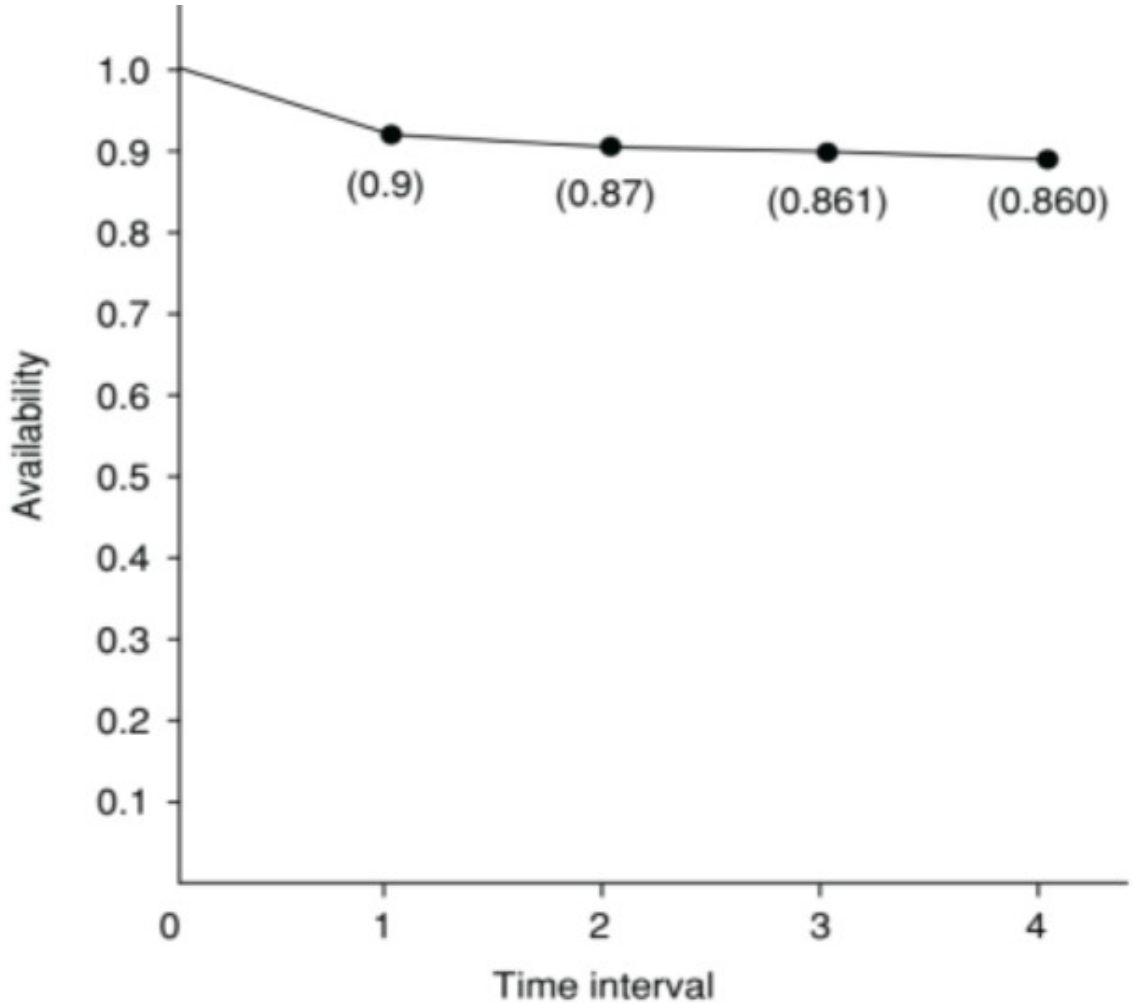


Diagrama de Árvore



Análise de Markov por Matrizes de Transição de Estados: Indicada para sistemas de larga escala, onde a montagem do diagrama de árvore é inviável.

$$P = \begin{bmatrix} P_{A\to A} & P_{A\to F} \\ P_{F\to A} & P_{F\to F} \end{bmatrix}$$

$P^n \to n$-ésimo estágio do sistema.

No exemplo:

$$P = \begin{bmatrix} P_{A\to A} & P_{A\to F} \\ P_{F\to A} & P_{F\to F} \end{bmatrix} = \begin{bmatrix} 0.9 & 0.1 \\ 0.6 & 0.4 \end{bmatrix}$$

- Para $t = 2$:
  P^2_{11} é a disponibilidade e P^2_{12} é a indisponibilidade em $t = 2$:

$$P^2 = \begin{bmatrix} 0.9 & 0.1 \\ 0.6 & 0.4 \end{bmatrix}^2 = \begin{bmatrix} 0.87 & 0.13 \\ 0.78 & 0.22 \end{bmatrix}$$

- Para $t = 4$:

$$P^4 = \begin{bmatrix} 0.8583 & 0.1417 \\ 0.8502 & 0.1498 \end{bmatrix}$$

Para dois componentes:

Estado	Componente	
	1	2
1	A	A
2	A	F
3	F	A
4	F	F

Para dois componentes:

$$P = \begin{bmatrix} P_{1\to1} & P_{1\to2} & P_{1\to3} & P_{1\to4} \\ P_{2\to1} & P_{2\to2} & P_{2\to3} & P_{2\to4} \\ P_{3\to1} & P_{3\to2} & P_{3\to3} & P_{3\to4} \\ P_{4\to1} & P_{4\to2} & P_{4\to3} & P_{4\to4} \end{bmatrix}$$

Utilizando as probabilidades de transição de estados do exemplo:

$$
\begin{aligned}
P_{1\to 1} &= 0.9 \times 0.9 = 0.81 \\
P_{1\to 2} &= 0.9 \times 0.1 = 0.09 \\
P_{1\to 3} &= 0.1 \times 0.9 = 0.09 \\
P_{1\to 4} &= 0.1 \times 0.1 = 0.01 \\
&\vdots \\
P_{4\to 4} &= 0.4 \times 0.4 = 0.16
\end{aligned}
$$

Chegamos na matriz de transição de estados;

$$P = \begin{bmatrix} P_{1\to1} & P_{1\to2} & P_{1\to3} & P_{1\to4} \\ P_{2\to1} & P_{2\to2} & P_{2\to3} & P_{2\to4} \\ P_{3\to1} & P_{3\to2} & P_{3\to3} & P_{3\to4} \\ P_{4\to1} & P_{4\to2} & P_{4\to3} & P_{4\to4} \end{bmatrix}$$

$$= \begin{bmatrix} 0.81 & 0.09 & 0.09 & 0.01 \\ 0.54 & 0.36 & 0.06 & 0.04 \\ 0.54 & 0.06 & 0.36 & 0.04 \\ 0.36 & 0.24 & 0.24 & 0.16 \end{bmatrix}$$

Observa-se que a análise em espaço de estados por Modelo de Markov rapidamente se torna complicada na perspectiva de álgebra matricial.

Entretanto, existem pacotes computacionais para lidar com problemas matriciais de grandes dimensões:

`https://en.wikipedia.org/wiki/Comparison_of_linear_algebra_libraries`

Métodos de Predição da Confiabilidade: Inteligência Artificial

Relembrando: A predição da confiabilidade é útil para:

1. **Identificar** fatores críticos para a confiabilidade e fatores de risco;
2. **Estimativa** do que irá acontecer no futuro:
   - Melhoria de projetos já existentes;
   - Decisão referente a novos projetos;
   - Custos de suporte e garantia;
   - Requisitos de peças de reposição;
3. Útil para diferentes áreas da engenharia:
   - Projetos;
   - Comercialização;
   - Gestão;
   - Operação;
   - Diagnóstico;
   - Manutenção.

Os métodos de inteligência artificial, ou aprendizado de máquina, podem ser organizados em três grandes grupos:

1. Métodos **supervisionados**;
2. Métodos **não supervisionados**;
3. Métodos **semi-supervisionados**.

Os métodos **supervisionados** consistem em aprender (ajustar) um modelo $\hat{y} = \hat{f}(\mathbf{x})$ a partir de observações no formato entrada e saída $(\mathbf{x}_i, y_i)$.

As entradas $\mathbf{x}_i$ são as características (medições) que permitem inferir a saída y_i (variável de interesse).

O modelo pode ser tanto de regressão, i.e., $y_i \in \mathbb{R}$, como de classificação, situação onde $y_i \in \mathbb{N}$.

Aplicações usuais de métodos **supervisionados**.

- Regressão:
  - Regressão da Vida Útil Restante (RUL, *Remaining Useful Life*);
  - Regressão da Degradação;
  - Regressão da Confiabilidade ($R(t)$);
- Classificação:
  - Classificação da importância de componentes;
  - Classificação do estado de degradação;
  - Classificação do estado de saúde*;

Os métodos **não supervisionados** utilizam um conjunto de dados em que apenas as características são conhecidas (**x**) para determinar como as observações se organizam.

Não é necessário existir uma variável de saída para ser estimada.

Usualmente, a tarefa é a de agrupamento, onde procura-se identificar padrões na organização dos dados;

Aplicações usuais de métodos **não supervisionados**.

- Agrupamento de componentes por criticalidade;
- Identificação de modos de operação;
- Identificação de falhas prematuras;
- Identificação de “sintomas” para diagnóstico ou prognóstico de falhas;

Os métodos **semi-supervisionados** utilizam dados em que uma parte é completamente rotulada, i.e., temos um valor de interesse y_i para cada observação das características $\mathbf{x}_i$, e a outra parte não é rotulada, temos apenas $\mathbf{x}_i$ sem os respectivos y_i.

Aprende-se um modelo para os dados rotulados para posteriormente estimar o y_i dos dados não rotulados.

Aplicações usuais de métodos **semi-supervisionados**.

- Detecção de falhas;
- Regressão do RUL;
- Identificação de falhas;
- Prognóstico do estado de saúde.

Áreas em que aplicações de modelos de inteligência artificial para predição da confiabilidade são usuais:

- Turbina de aeronaves;
- Baterias;
- Sistemas elétricos de potência;
- Componentes eletrônicos;
- Turbinas a Gás;
- Máquinas industriais;
- Sistemas de manufatura;
- Componentes mecânicos;
- Sistemas de monitoramento;
- Software;
- Redes de comunicação.

Métodos de Predição da Confiabilidade: Outros Métodos

Além do que foi mencionado aqui, ainda existem outros caminhos para realizar uma predição da confiabilidade de um sistema:

- Modelos de Markov para tempo contínuo;
- Redes de Petri - Modelo gráfico para descrever relações entre condições e eventos;
- Métodos de enumeração de estados (exaustiva e suas variações mais eficientes);
- Simulação de Monte Carlo (sequencial e suas variações mais eficientes);

Considerações Finais

A escolha dos métodos a serem utilizados na predição da confiabilidade deve ser ponderada de acordo com a finalidade da predição:

- Em aplicações dependentes ou críticas, i.e., com **risco elevado**, deve-se trabalhar com uma **visão pessimista** do sistema;
- Nos outros casos (sem risco elevado), pode-se utilizar uma visão menos pessimista. Usualmente para estimativas relacionadas com:
  - Estoque de peças sobressalentes de reposição;
  - Gastos de manutenção;

Um campo em que essas técnicas são muito relevantes é na gestão de ativos através da implantação de estratégias de manutenção preventiva e preditiva (manutenabilidade).

Referências

Referências



O'Connor, Patrick, and Andre Kleyner. *Practical reliability engineering*. John Wiley & Sons, 2012.



D. W. BENBOW AND H. W. BROOME, *The Certified Reliability Engineer Handbook*. Milwaukee: American Society of Quality / Quality Press, 2009.



XU, Zhaoyi; SALEH, Joseph Homer. **Machine learning for reliability engineering and safety applications: Review of current status and future opportunities.** Reliability Engineering & System Safety, v. 211, p. 107530, 2021.



PAYETTE, Mathieu; ABDUL-NOUR, Georges. **Machine Learning Applications for Reliability Engineering: A Review**. Sustainability, v. 15, n. 7, p. 6270, 2023.

Extra:



PAGE, Lawrence et al. **The pagerank citation ranking: Bring order to the web**. Technical report, stanford University, 1998.